



Εθνικό Μετσόβιο Πολυτεχνείο

Σχολή Ηλεκτρολόγων Μηχανικών &
Μηχανικών Υπολογιστών

Εξάμηνο 8^ο
Όραση Υπολογιστών

2η Εργαστηριακή Άσκηση

Εκτίμηση Οπτικής Ροής,
Εξαγωγή Χαρακτηριστικών σε Βίντεο
Αναγνώρισης Δράσεων,
Συνένωση Εικόνων

Μέλη Ομάδας

Καβαδάκης Σωτήρης 03122035

Δαλαμπέκης Ιγνάτιος 03122017

Αθήνα, Απρίλιος 2026

Περιεχόμενα

1 Παρακολούθηση Προσώπου και Χεριών με Χρήση της Μεθόδου Οπτικής Ροής των Lucas-Kanade	3
1.1 Υλοποίηση του Αλγορίθμου των Lucas-Kanade	3
1.2 Υπολογισμός της Μετατόπισης των Παραθύρων από τα Διανύσματα Οπτικής Ροής	13
1.3 Πολυ-Κλιμακωτός Υπολογισμός Οπτικής Ροής	20
2 Εντοπισμός Χωρο-χρονικών Σημείων Ενδιαφέροντος και Εξαγωγή Χαρακτηριστικών σε Βίντεο Ανθρωπίνων Δράσεων	23
2.1 Χωρο-χρονικά Σημεία Ενδιαφέροντος	23
2.1.1 Ανιχνευτής Harris3D	23
2.1.2 Ανιχνευτής Gabor	25
2.1.3 Απόρριψη Ομαλών Περιοχών και Επιλογή Σημείων	26
2.1.4 Απεικόνιση Σημείων Ενδιαφέροντος και Σχολιασμός	26
2.2 Χωρο-χρονικοί Ιστογραφικοί Περιγραφητές	30
2.2.1 Υπολογισμός Gradient και Οπτικής Ροής	31
2.2.2 Εξαγωγή HOG/HOF Περιγραφητών	31
2.3 Κατασκευή Bag of Visual Words και Ταξινόμηση με SVM	32
2.3.1 Διαχωρισμός Συνόλου Δεδομένων	33
2.3.2 Κατασκευή Λεξιλογίου visual words	33
2.3.3 Ταξινόμηση με SVM	33
2.3.4 Πειραματισμοί και Σχολιασμός	34
3 Ταξινόμηση Βίντεο με Χρήση Προεκπαιδευμένων Βαθιών Νευρωνικών Δικτύων	36
3.1 2D Χαρακτηριστικά με MobileNet	36
3.1.1 Φόρτωση Βίντεο UCF11	36
3.1.2 Εξαγωγή Χαρακτηριστικών με MobileNet_v3_small	37
3.1.3 Ταξινόμηση με SVM	37
3.2 3D Χαρακτηριστικά με x3d_xs	38
3.2.1 Φόρτωση Μοντέλου x3d_xs	38

3.2.2	Εξαγωγή Χαρακτηριστικών και Προετοιμασία Δεδομένων	38
3.2.3	Ταξινόμηση και Confusion Matrix	39
3.2.4	Σύγκριση 2D και 3D Προσεγγίσεων	46

1. Παρακολούθηση Προσώπου και Χεριών με Χρήση της Μεθόδου Οπτικής Ροής των Lucas-Kanade

1.1 Υλοποίηση του Αλγορίθμου των Lucas-Kanade

Στο πρώτο μέρος της άσκησης υλοποιήσαμε σύστημα παρακολούθησης του προσώπου και των δύο χεριών της νοσηματίστριας με βάση την οπτική ροή μεταξύ διαδοχικών καρέ. Ως αρχικά bounding boxes χρησιμοποιήσαμε ακριβώς εκείνα που μας δίνονται, δηλαδή πρόσωπο [154, 102, 67, 115], αριστερό χέρι [93, 272, 56, 83] και δεξί χέρι [201, 270, 56, 83]. Στη συνέχεια ακολουθεί μια συνοπτική θεωρητική παρουσίαση της μεθόδου Lucas-Kanade, καθώς και λεπτομέρειες για την υλοποίησή της.

Η θεωρητική βάση της μεθόδου Lucas-Kanade είναι η παραδοχή της εξίσωσης διατήρησης της φωτεινότητας σύμφωνα με την οποία ένα σημείο της εικόνας διατηρεί περίπου την έντασή του από frame σε frame γύρω από μια γειτονιά και απλώς αλλάζει θέση. Για μία ακολουθία εικόνων $I_n(x)$, όπου $n = 1, \dots, N$ και $x = (x, y)$, το πεδίο οπτικής ροής $-d$, με $d(x) = (d_x, d_y)$, ορίζει την αντιστοίχιση δύο διαδοχικών εικόνων σύμφωνα με

$$I_n(x) \approx I_{n-1}(x + d), \quad (1)$$

όπου το αρνητικό πρόσημο στη ροή οφείλεται στο γεγονός ότι εμείς υπολογίζουμε αρχικά τα σημεία ενδιαφέροντος στην εικόνα $I_n(x)$ αλλά θέλουμε να βρούμε την κίνηση τους στην εικόνα I_{n-1} στην I_n . Ο Lucas-Kanade υποθέτει ότι μέσα σε ένα μικρό γειτονικό παράθυρο γύρω από κάθε σημείο x η μετατόπιση d είναι τοπικά σταθερή και την υπολογίζει με ελαχιστοποίηση του σταθμισμένου τετραγωνικού σφάλματος

$$J_x(d) = \int_{x' \in \mathbb{R}^2} G_\rho(x - x') [I_n(x') - I_{n-1}(x' + d)]^2 dx', \quad (2)$$

όπου $G_\rho(x)$ είναι η συνάρτηση παραθύρωσης, την οποία επιλέγουμε γκαουσιανή με τυπική απόκλιση ρ . Η γκαουσιανή στάθμιση δίνει μεγαλύτερη βαρύτητα στα pixels κοντά στο κέντρο του παραθύρου και μειώνει την επίδραση πιο απομακρυσμένων σημείων.

Επειδή το πρόβλημα είναι μη γραμμικό ως προς το d , η λύση υπολογίζεται επαναληπτικά. Αν d_i είναι η τρέχουσα εκτίμηση της οπτικής ροής, αναζητούμε μια μικρή βελτίωση u ώστε

$$d_{i+1} = d_i + u. \quad (3)$$

Αναπτύσσοντας κατά Taylor το $I_{n-1}(x + d) = I_{n-1}(x + d_i + u)$ γύρω από το σημείο $x + d_i$, παίρνουμε την προσέγγιση πρώτης τάξης

$$I_{n-1}(x + d) \approx I_{n-1}(x + d_i) + \nabla I_{n-1}(x + d_i)^T u. \quad (4)$$

Αντικαθιστώντας την παραπάνω σχέση στο $J_x(d)$ και επιλύοντας το αντίστοιχο πρόβλημα

ελαχίστων τετραγώνων, προκύπτει η ενημέρωση

$$u(x) = \begin{bmatrix} (G_\rho * A_1^2)(x) + \epsilon & (G_\rho * (A_1 A_2))(x) \\ (G_\rho * (A_1 A_2))(x) & (G_\rho * A_2^2)(x) + \epsilon \end{bmatrix}^{-1} \begin{bmatrix} (G_\rho * (A_1 E))(x) \\ (G_\rho * (A_2 E))(x) \end{bmatrix}, \quad (5)$$

όπου

$$A(x) = \begin{bmatrix} A_1(x) & A_2(x) \end{bmatrix} = \begin{bmatrix} \frac{\partial I_{n-1}(x + d_i)}{\partial x} & \frac{\partial I_{n-1}(x + d_i)}{\partial y} \end{bmatrix}, \quad (6)$$

$$E(x) = I_n(x) - I_{n-1}(x + d_i). \quad (7)$$

Το σύμβολο $*$ δηλώνει συνέλιξη, ενώ η μικρή θετική σταθερά ϵ λειτουργεί ως regularization σε περιοχές χαμηλής υφής, όπου ο πίνακας του συστήματος γίνεται σχεδόν ιδιάζων. Η διαδικασία ενημέρωσης $d_{i+1} = d_i + u$ επαναλαμβάνεται μέχρι σύγκλισης.

Όπως φαίνεται και από τη παραπάνω θεωρία η μέθοδος λειτουργεί καλύτερα σε σημεία με έντονη τοπική δομή, όπως γωνίες και άκρα δηλαδή σε θέσεις όπου οι χωρικές παραγώγοι κατά x και y περιέχουν επαρκή πληροφορία για την επίλυση του τοπικού συστήματος. Για τον λόγο προτείνεται πρώτα και η εξαγωγή features με τη μέθοδο Shi-Tomasi, ώστε η εκτίμηση της οπτικής ροής να εφαρμόζεται σε κατάλληλα σημεία ενδιαφέροντος κάθε bounding box.

Στην υλοποίησή μας η συνάρτηση `lk(I1, I2, features, rho, epsilon, d_x0, d_y0)` ακολουθεί πιστά τα παραπάνω βήματα. Καταρχάς, είναι σημαντικό να ξανααναφέρουμε ότι στην υλοποίηση μας τα features είναι υπολογισμένα στο frame I_n και όχι στο I_{n-1} , δηλαδή κάνουμε backward tracking των χαρακτηριστικών της εικόνας. Για τα σημεία ενδιαφέροντος χρησιμοποιήσαμε τη `cv2.goodFeaturesToTrack`, δηλαδή τον ανιχνευτή Shi-Tomasi που προτείνεται. Στην τελική διαδικασία παρακολούθησης ανιχνεύουμε έως 200 γωνίες σε κάθε crop του επόμενου καρέ, με `qualityLevel=0.01` και `minDistance=5`. Για τη μονοκλιμακωτή εκδοχή του Lucas-Kanade χρησιμοποιήσαμε τελικά τις παραμέτρους `rho=5` και `epsilon=0.001` και ως είναι μικρότερο από τα προτεινόμενα όρια, καθώς αυτές έδωσαν εμπειρικά τα καλύτερα αποτελέσματα. Επίσης, οι εικόνες $I1$ και $I2$ αποτελούν τα cropped παραθύρα των αρχικών εικόνων γύρω από τα bounding boxes όπως αυτά έχουν ήδη οριστεί για το πρόσωπο και τα δύο χέρια. Αρχικά μετατρέπουμε τις εικόνες σε $[0, 1]$ για αριθμητική σταθερότητα και υπολογίζουμε τις χωρικές παραγώγους της πρώτης εικόνας με `numpy.gradient` όπως φαίνεται ότι χρειάζεται για την εξίσωση 6. Στη συνέχεια, δημιουργούμε ένα πλέγμα με τις διαστάσεις της εικόνας $I1$, το οποίο περιέχει τις συντεταγμένες κάθε pixel. Οι χάρτες μετατόπισης d_x, d_y έχουν μέγεθος όσο και το μέγεθος του παραθύρου της εικόνας ώστε να μπορούμε να διατηρούμε την οπτική ροή σε όλα τα pixels του παραθύρου και αρχικοποιούνται με τις τιμές που δίνονται ως είσοδο `d_x0, d_y0`, οι οποίες μπορούν να είναι είτε scalars είτε 2D arrays το οποίο θα μας βοηθήσει για την υλοποίηση του πολυκλιμακωτού Lucas Kanade, αλλά για τον απλό τις αρχικοποιούμε ως μηδενικές. Για να δειγματοληψήσουμε τις τιμές της $I_{n-1}(x + d_i)$ και των παραγώγων της, όπως φαίνεται ότι χρειάζεται για τις εξισώσεις 6 και 7, σε μη ακέραιες θέσεις χρησιμοποιούμε `scipy.ndimage.map_coordinates` με γραμμική παρεμβολή στις shifted συντεταγμένες.

Ουσιαστικά, αυτός είναι ένας τρόπος για να εκτιμήσουμε τη τιμή της εικόνας I_{n-1} στη δεκαδική θέση $(x + d_i)$ το οποίο γίνεται μέσω γραμμικής παρεμβολής. Τα γινόμενα A_1^2 , A_1A_2 , A_2^2 , A_1E , A_2E εξομαλύνονται με γκαουσιανό πυρήνα που κατασκευάζεται από την `cv2.getGaussianKernel`, ενώ η συνέλιξη γίνεται με `cv2.filter2D`. Στη συνέχεια, για να λύσουμε το τοπικό σύστημα για κάθε pixel του παραθύρου το οποίο φαίνεται στην εξίσωση 5, υπολογίζουμε την ορίζουσα του πίνακα και εφαρμόζουμε τον κανόνα του Cramer για να βρούμε την ενημέρωση u . Τέλος, προσθέτουμε την ενημέρωση u στις τρέχουσες εκτιμήσεις d_x , d_y και επαναλαμβάνουμε τη διαδικασία μέχρι σύγκλισης. Αναφέρουμε ξανά ότι μια ιδιαιτερότητα της δικής μας υλοποίησης είναι ότι, παρότι η συνάρτηση δέχεται ως είσοδο συγκεκριμένα feature points, διατηρεί και ενημερώνει πυκνούς χάρτες μετατόπισης d_x , d_y για όλα τα pixels του εκάστοτε παραθύρου (**dense optical flow**). Έτσι λύνουμε ταυτόχρονα το τοπικό σύστημα σε όλο το crop και στο τέλος κρατάμε μόνο τις τιμές στις θέσεις των χαρακτηριστικών σημείων που μας ενδιαφέρουν. Η επαναληπτική διαδικασία του Lucas-Kanade εκτελείται έως 150 επαναλήψεις και διακόπτεται νωρίτερα όταν η μέγιστη νόρμα της διόρθωσης στα features πέσει κάτω από κατώφλι 10^{-4} , δηλαδή όταν η εκτίμηση έχει πρακτικά συγκλίνει. Τέλος, η συνάρτηση επιστρέφει τους χάρτες μετατόπισης d_x , d_y για όλα τα σημεία ενδιαφέροντος εντός του παραθύρου, ωστόσο όπως ήδη αναφέραμε το πραγματικό διάνυσμα της οπτικής ροής είναι το αρνητικό τους, δηλαδή $-d_x$, $-d_y$ ακριβώς επειδή εμείς υπολογίζουμε τα σημεία ενδιαφέροντος στο δεύτερο καρέ. Επίσης, η συνάρτηση μας επιστρέφει πέρα από τις μετατοίσεις μόνο στα σημεία ενδιαφέροντος και τους χάρτες μετατόπισης κατά `d_x_map`, `d_y_map` για όλα τα σημεία της εικόνας καθώς όπως θα φανεί θα μας χρειαστεί για την υλοποίηση του πολυκλιμακωτού ώστε να χρησιμοποιήσουμε τη λύση της μικρής κλίμακας ως αρχική συνθήκη για τη μεγάλη κλίμακα, για αυτό κιόλας αλλάξαμε τον απλό αλγόριθμο ώστε να μπορεί να λάβει ως συνθήκη και ολόκληρο δισδιάστο πίνακα με όλες τις μετατοπίσεις της εικόνας.

Παράλληλα, στον κώδικά μας αφού υλοποιήσαμε τον δικό μας αλγόριθμο `lk()` για τον Lucas Kanade έχουμε, χρησιμοποιήσαμε και την έτοιμη μέθοδο πυκνής οπτικής ροής TV-L1 της OpenCV (`cv2.optflow.DualTVL1OpticalFlow_create`), δειγματοληπτώντας το πεδίο στα ίδια feature points, ώστε να μπορούμε να συγκρίνουμε και να εξετάσουμε ποιοτικά τις διαφορές ανάμεσα στις δύο προσεγγίσεις. Ειδικότερα, για τη σωστή υλοποίηση του TV-L1 αφού πάλι έχουμε υπολογίσει τα σημεία ενδιαφέροντος στην I_2 κάνουμε (`flow = tvl1_estimator.calc(crop_I2, crop_I1, None)`) με αυτή τη σειρά ώστε να είμαστε συνεπείς με το ποια εικόνα έχουμε εντοπίσει τα σημεία ενδιαφέροντος. Προφανώς, αυτός ο αλγόριθμος είναι global δηλαδή υπολογίζει την οπτική ροή σε όλα τα σημεία, στη συνέχεια κρατήσαμε μόνο την οπτική ροή στα σημεία ενδιαφέροντος και πήραμε τα αρνητικά τους ώστε να κρατήσουμε τη πραγματική οπτική ροή.

Παράλληλα, για να ελέγξουμε πιο άμεσα ότι η υλοποίηση του Lucas-Kanade λειτουργεί σωστά και είναι συγκρίσιμη με την αναφορά TV-L1 που προτείνεται πρώτου προχωρήσουμε στο βιντό μας, κάναμε ένα sanity check. Συγκεκριμένα, φορτώνουμε το πρώτο grayscale

frame 1.png ως I_1 και κατασκευάζουμε τεχνητά ένα δεύτερο frame I_2 μετατοπίζοντας όλη την εικόνα κατά ακριβώς +1 pixel στον οριζόντιο και κατά +1 pixel στον κατακόρυφο άξονα μέσω της `scipy.ndimage.shift`. Έτσι γνωρίζουμε εκ των προτέρων την "σωστή" ροή, δηλαδή αναμένουμε μέση μετατόπιση $(d_x, d_y) \approx (1, 1)$. Το test εκτελείται ξεχωριστά για τα τρία αρχικά bounding boxes (πρόσωπο, αριστερό χέρι, δεξί χέρι). Σε κάθε crop ανιχνεύουμε Shi-Tomasi features στο μετατοπισμένο παράθυρο I_2 και υπολογίζουμε πάνω στα ίδια ακριβώς σημεία τη μονοκλιμακωτή Lucas-Kanade, καθώς και την TV-L1 και στη συνέχεια παίρνουμε το μέσο όρο από τις μετατοπίσεις όλων των σημείων ενδιαφέροντος ώστε να βρούμε την εκτιμώμενη συνολική οπτική ροή για τον LK με `rho=5` και `epsilon=0.001`. Να ξανααναφέρουμε ότι πρέπει να πάρουμε τα αρνητικά τους, δηλαδή $(-d_x, -d_y)$ για να έχουμε την πραγματική ροή. Με αυτό το τρόπο δεν βασιζόμαστε μόνο σε ποιοτική οπτική επιθεώρηση της παρακολούθησης, αλλά και σε ένα test με γνωστή ground-truth μετατόπιση. Αν τόσο ο Lucas-Kanade όσο και ο TV-L1 επιστρέφουν τιμές κοντά στο $(1, 1)$ στα ίδια σημεία, τότε έχουμε ένδειξη ότι η υλοποίησή μας είναι αριθμητικά συνεπής και ότι οι αποκλίσεις που παρατηρούνται αργότερα στο πραγματικό βίντεο οφείλονται στις δυσκολίες του ίδιου του προβλήματος παρακολούθησης και όχι σε σφάλμα της υλοποίησης. Γενικά, αναμένουμε για μετατοπίσεις της τάξης του ενός pixel ότι ο Lucas-Kanade θα επιστρέφει εκτιμήσεις αρκετά κοντά στο $(1, 1)$, ενώ για μεγαλύτερες μετατοπίσεις ότι θα αποτυγχάνει. Τα αποτελέσματα απεικονίζονται στο πίνακα 1:

Περιοχή	Μέθοδος	mean d_x	mean d_y	Error
face (115 features)	Uni-scale LK	0.9954	0.9930	(0.0046, 0.0070)
	TV-L1	0.9990	0.9919	(0.0010, 0.0081)
	Expected	1.0000	1.0000	
left_hand (50 features)	Uni-scale LK	0.9974	0.9884	(0.0026, 0.0116)
	TV-L1	0.9957	1.0014	(0.0043, 0.0014)
	Expected	1.0000	1.0000	
right_hand (35 features)	Uni-scale LK	0.9902	1.0054	(0.0098, 0.0054)
	TV-L1	0.9599	1.0038	(0.0401, 0.0038)
	Expected	1.0000	1.0000	

Πίνακας 1. Αποτελέσματα sanity check: σύγκριση Uni-scale LK και TV-L1 με αναμενόμενη μετατόπιση $(1, 1)$ με `rho=5` και `epsilon=0.001`

Παρατηρούμε ότι πραγματικά ότι η υλοποίησή μας μας δίνει πολύ καλά αποτελέσματα πολύ κοντά στα αναμενόμενα για αυτές τις μικρές μετατοπίσεις και ότι ο TV-L1 δίνει επίσης πολύ κοντά αποτελέσματα, αν και γενικά έχει μεγαλύτερο σφάλμα. Αυτό μας δίνει εμπιστοσύνη ότι η υλοποίησή μας είναι σωστή και ότι οι αποκλίσεις που θα παρατηρήσουμε στο πραγματικό βίντεο οφείλονται στις δυσκολίες του ίδιου του προβλήματος παρακολούθησης και όχι σε σφάλμα της υλοποίησης.

Για να κάνουμε επίσης μία ποιοτική αναθεώρηση των τιμών των παραμέτρων που χρησιμοποιήσαμε δοκιμάσαμε και για $\rho=5$ και $\epsilon=0.01$. Τα αποτελέσματα φαίνονται στον παρακάτω πίνακα 2:

Περιοχή	Μέθοδος	mean d_x	mean d_y	Error
face (115 features)	Uni-scale LK	0.9065	0.8706	(0.0935, 0.1294)
	Expected	1.0000	1.0000	
left_hand (50 features)	Uni-scale LK	0.9398	0.9083	(0.0602, 0.0917)
	Expected	1.0000	1.0000	
right_hand (35 features)	Uni-scale LK	0.9499	0.9443	(0.0501, 0.0557)
	Expected	1.0000	1.0000	

Πίνακας 2. Αποτελέσματα sanity check: Uni-scale LK με αναμενόμενη μετατόπιση (1, 1) για $\rho=5$ και $\epsilon=0.01$

Όπως φαίνεται αυξάνοντας το ϵ σε 0.01 έχουμε χειρότερα αποτελέσματα για τον Lucas-Kanade, ενδεχομένως καθώς εισάγει μικρότερη αριθμητική ακρίβεια.

Στη συνέχεια δοκιμάσαμε και να μειώσουμε το $\rho=3$ διατηρώντας σταθερό το $\epsilon=0.01$ και τα αποτελέσματα φαίνονται στον παρακάτω πίνακα 3:

Περιοχή	Μέθοδος	mean d_x	mean d_y	Error
face (115 features)	Uni-scale LK	0.8810	0.8349	(0.1190, 0.1651)
	Expected	1.0000	1.0000	
left_hand (50 features)	Uni-scale LK	0.9062	0.8789	(0.0938, 0.1211)
	Expected	1.0000	1.0000	
right_hand (35 features)	Uni-scale LK	0.9323	0.9193	(0.0677, 0.0807)
	Expected	1.0000	1.0000	

Πίνακας 3. Αποτελέσματα sanity check: Uni-scale LK με αναμενόμενη μετατόπιση (1, 1) για $\rho=3$ και $\epsilon=0.01$

Παρατηρούμε ότι μειώνοντας το ρ σε 3 έχουμε σημαντικά χειρότερα αποτελέσματα για τον Lucas-Kanade, πιθανώς επειδή η μικρότερη απόκλιση της γκαουσιανής στάθμισης δίνει μεγαλύτερη βαρύτητα σε πιο κοντινά pixels, τα οποία μπορεί να μην περιέχουν αρκετή πληροφορία για την εκτίμηση της οπτικής ροής, ειδικά αν υπάρχουν περιοχές χαμηλής υψής ή θόρυβος.

Στη συνέχεια δοκιμάσαμε και να μειώσουμε και άλλο το $\rho=1$ αυξάνοντας ταυτόχρονα το $\epsilon=0.1$ και τα αποτελέσματα φαίνονται στον παρακάτω πίνακα 4:

Περιοχή	Μέθοδος	mean d_x	mean d_y	Error
face (115 features)	Uni-scale LK	0.4637	0.3906	(0.5363, 0.6094)
	Expected	1.0000	1.0000	
left_hand (50 features)	Uni-scale LK	0.5685	0.4466	(0.4315, 0.5534)
	Expected	1.0000	1.0000	
right_hand (35 features)	Uni-scale LK	0.6740	0.4938	(0.3260, 0.5062)
	Expected	1.0000	1.0000	

Πίνακας 4. Αποτελέσματα sanity check: Uni-scale LK με αναμενόμενη μετατόπιση (1,1) για $\rho=1$ και $\epsilon=0.1$

Παρατηρούμε ότι με αυτές τις παραμέτρους ο Lucas-Kanade δίνει πολύ χειρότερα αποτελέσματα, πιθανώς επειδή το πολύ μικρό ρ δίνει υπερβολική βαρύτητα σε πολύ κοντινά pixels, τα οποία μπορεί να μην περιέχουν αρκετή πληροφορία για την εκτίμηση της οπτικής ροής, ειδικά αν υπάρχουν περιοχές χαμηλής υφής ή θόρυβος. Επιπλέον, το μεγάλο ϵ μπορεί να εισάγει σημαντική αριθμητική αβεβαιότητα στην επίλυση του συστήματος, οδηγώντας σε λιγότερο ακριβείς εκτιμήσεις της ροής.

Τέλος, δοκιμάσαμε για τις αρχικές βέλτιστες τιμές $\rho=5$ και $\epsilon=0.001$ να αυξήσουμε τη μετατόπιση σε (3,3) και τα αποτελέσματα φαίνονται στον παρακάτω πίνακα 5:


Περιοχή	Μέθοδος	mean d_x	mean d_y	Error
face (112 features)	Uni-scale LK	2.5434	5.1075	(0.4566, 2.1075)
	Expected	3.0000	3.0000	
left_hand (49 features)	Uni-scale LK	3.0178	2.7264	(0.0178, 0.2736)
	Expected	3.0000	3.0000	
right_hand (31 features)	Uni-scale LK	2.9614	2.9868	(0.0386, 0.0132)
	Expected	3.0000	3.0000	

Πίνακας 5. Αποτελέσματα sanity check: Uni-scale LK με αναμενόμενη μετατόπιση (3,3) για $\rho=5$ και $\epsilon=0.001$


Παρατηρούμε ότι για μεγαλύτερη μετατόπιση ο Lucas-Kanade δίνει χειρότερα αποτελέσματα, ειδικά για το πρόσωπο όπου το σφάλμα είναι αρκετά μεγάλο. Αυτό συμβαίνει επειδή η μέθοδος βασίζεται στην γραμμικοποίηση της εικόνας γύρω από την τρέχουσα εκτίμηση της ροής, η οποία παύει να είναι ακριβής όταν οι μετατοπίσεις είναι μεγάλες. Για αυτόν τον λόγο, στο επόμενο βήμα θα υλοποιήσουμε την πολυ-κλιμακωτή εκδοχή του Lucas-Kanade, η οποία ξεκινά από αδρές αναπαραστάσεις των εικόνων και βελτιώνει προοδευτικά την εκτίμηση σε λεπτομερέστερες κλίμακες. Επίσης, γενικά παρατηρήσαμε ότι και για μεγαλύτερες τιμές του ρ λαμβάναμε ελαφρώς καλύτερα αποτελέσματα αλλά για χάριν

της υπολογιστικότητας κρατήσαμε το $\rho=5$ και το $\epsilon=0.0001$ αφού μας έδιναν ήδη πολύ καλά αποτελέσματα όπως φάνηκε.


Έχοντας αποδείξει ότι η υλοποίηση μας είναι σωστή προχωράμε τώρα στην εφαρμογή της στις δοσμένες διαδοχικές εικόνες της ομιλήτριας ειδικότερα παρακάτω φαίνονται ορισμένα καρέ τα οποία επιλέξαμε για να δείξουμε την ερμηνευσιμότητα της οπτικής ροής στις πραγματικές κινήσεις μεταξύ των διαδοχικών εικόνων και στη σύγκριση της μονοκλιμακωτής εκδοχής του Lucas-Kanade με την TV-L1. Ειδικότερα, στα παρακάτω πλέγματα για το ίδιο καρέ φαίνονται οι απεικονίσεις και για τα 3 κουτιά της εικόνας I_{n-1} , της εικόνας I_n , με τα χαρακτηριστικά σημεία που ανιχνεύθηκαν στο I_n , και των διανυσμάτων οπτικής ροής που υπολογίστηκαν πρώτα με τον Lucas-Kanade και μετά με τη μέθοδο TV-L1. Για την απεικόνιση των διανυσμάτων οπτικής ροής χρησιμοποιήσαμε quiver plots με $\text{scale}=1$ για να φαίνονται καλύτερα τα βελάκια, όπου τα διανύσματα σχεδιάζονται ως βέλη που ξεκινούν από τις θέσεις των χαρακτηριστικών σημείων και δείχνουν την κατεύθυνση και το μέγεθος της εκτιμώμενης ροής. Τα αποτελέσματα φαίνονται στα παρακάτω σχήματα:



Σχήμα 1. Επιλεγμένα πλέγματα σύγκρισης οπτικής ροής για διαδοχικά καρέ. Σε κάθε πλέγμα φαίνονται τα crops των τριών περιοχών, τα ανιχνευμένα features, καθώς και τα quiver plots των Lucas-Kanade($\rho=5$, $\epsilon=0.001$) και TV-L1.



Σχήμα 2. Πρόσθετα παραδείγματα από ενδιάμεσες χρονικές στιγμές, όπου φαίνονται οι διαφορές στη δομή και στο μέγεθος των διανυσμάτων μεταξύ των δύο μεθόδων.




Σχήμα 3. Παράδειγμα από τα τελευταία καρέ της ακολουθίας, όπου η σύγκριση Lucas-Kanade και TV-L1 παραμένει άμεσα ορατή μέσα από τα αντίστοιχα quiver plots.


Παρατηρώντας τις παραπάνω εικόνες πρώτον έχουμε να παρατηρήσουμε ότι η μέθοδος Lucas-Kanade δίνει γενικά καλά αποτελέσματα ακολουθώντας τις κινήσεις και των τριών περιοχών. Επίσης, μπορούμε να παρατηρήσουμε ότι γενικά η υλοποίησή μας παρακολουθεί και πολύ λεπτομερείς κινήσεις, για παράδειγμα στο καρέ 7 στο 8 παρατηρούμε ότι στο αριστερό χέρι ο αντίχειρας μόνος του κάνει μια σχετικά μεγάλη μετατόπιση για αυτό και

στο αντίστοιχο σχήμα του LK σε εκείνο το σημείο παρατηρούμε ένα μεγάλο βελάκι, κάτι το οποίο δεν φαίνεται να υπάρχει στο TV-L1. Συγκριτικά, με τις δύο μεθόδους παρατηρούμε από το πρώτο καρέ ότι σε διαδοχικά καρέ όπου δεν υπάρχουν έντονες κινήσεις οι δύο αλγόριθμοι δίνουν παρόμοια αποτελέσματα. Από τη άλλη σε διαδοχικά καρέ με πιο μεγάλη κίνηση όπως είναι τα τελευταία καρέ όπου η ομιλήτρια κάνει μια έντονη κίνηση με το δεξί της χέρι, παρατηρούμε ότι ο Lucas-Kanade δίνει πιο μεγάλα διανύσματα ροής, ενώ ο TV-L1 δίνει μικρότερα διανύσματα, πιθανώς λόγω της διαφορετικής προσέγγισης που χρησιμοποιεί για την εκτίμηση της ροής και της μεγαλύτερης ευαισθησίας του σε θόρυβο και παραμορφώσεις. Αυτό δείχνει ότι ο Lucas-Kanade μπορεί να είναι πιο ευαίσθητος σε μεγάλες κινήσεις, ενώ ο TV-L1 μπορεί να είναι πιο ομαλός, ειδικά σε περιοχές με χαμηλή υφή ή θόρυβο. Γενικά, από τα καρέ 32 και 37 φαίνεται ότι ο Lucas-Kanade φαίνεται ότι δημιουργεί έντονα διανύσματα οπτικής ροής σαν outliers ενώ ο TV-L1 δίνει πιο ομαλά αποτελέσματα.

Στη συνέχεια για να δείξουμε και στις πραγματικές εικόνες το αποτέλεσμα για διαφορετικές τιμές των παραμέτρων ρ και ϵ δοκιμάσαμε να μειώσουμε το ρ σε 1 και το ϵ σε 0.1 και τα αποτελέσματα φαίνονται στα παρακάτω σχήματα για ίδια καρέ που είχαμε επιλέξει παραπάνω:




Σχήμα 4. Παράδειγμα για $\rho=1$, $\epsilon=0.1$.



Σχήμα 5. Παράδειγμα για $\rho=1$, $\epsilon=0.1$.


Όπως είχαμε ήδη δει στο απλό πείραμα από πάνω με την απλή μετατόπιση (1,1) της εικόνας γις αυτές τις τιμές των παραμέτρων ο Lucas-Kanade δίνει πολύ χειρότερα αποτελέσματα, καθώς όπως φαίνεται τα βελάκια έχουν σχεδόν τελείως διαφορετική κατεύθυνση από εκείνη που έχουν με τη μέθοδο TV-L1, άρα δεν παρακολουθούν σωστά τη κίνηση της ομιλήτριας όπως πριν ενώ χάνει και σημαντικά σε λεπτομέρεια.

Τέλος, δοκιμάσαμε και να αυξήσουμε το ρ σε 10 και να μειώσουμε το ϵ σε 0.001 και τα αποτελέσματα φαίνονται στα παρακάτω σχήματα για ίδια καρέ που είχαμε επιλέξει παραπάνω:



(α') Καρέ 7 → 8

Σχήμα 6. Παράδειγμα για $\rho=10$, $\epsilon=0.001$.



(α') Καρέ 37 → 38

Σχήμα 7. Παράδειγμα για $\rho=10$, $\epsilon=0.001$.

Παρατηρούμε ότι με αυτές τις παραμέτρους ο Lucas-Kanade δίνει ελαφρώς καλύτερα αποτελέσματα, καθώς τα βελάκια έχουν πιο σωστή κατεύθυνση και μέγεθος σε σχέση με τη μέθοδο TV-L1, ενώ επίσης και αν χάσαμε σε πιο έντονη λεπτομέρεια σε σχέση με $\rho=5$ τα αποτελέσματά μας είναι πιο ομαδα χωρίς τα spikes που είχαμε πριν.

1.2 Υπολογισμός της Μετατόπισης των Παραθύρων από τα Διανύσματα Οπτικής Ροής

Αφού υπολογιστούν τα διανύσματα οπτικής ροής στα χαρακτηριστικά σημεία ενός bounding box, πρέπει να εξαχθεί ένα και μοναδικό διάνυσμα μετατόπισης για όλο το παράθυρο. Αφού άλλωστε όλα τα σημεία είναι σημεία ενδιαφέροντος με υψηλή υφή μια απλή επιλογή είναι ο μέσος όρος των επιμέρους διανυσμάτων. Αλλά μπορούμε να κάνουμε και πιο εύρωστες στρατηγικές ώστε να απορρίπτονται outliers ή σημεία που ανήκουν σε φτωχές περιοχές υφής. Η βασική ιδέα είναι ότι τα πιο αξιόπιστα διανύσματα συνήθως προέρχονται από σημεία με υψηλότερη ενέργεια κίνησης,

$$\|d\|^2 = d_x^2 + d_y^2. \quad (8)$$

Για τον λόγο αυτό υλοποιήσαμε τη συνάρτηση `displ(d_x, d_y)`, η οποία δεν χρησιμοποιεί όλα τα features ισότιμα. Να σημειωθεί ότι για την υλοποίηση του Lucas Kanade και του TV-L1 έπρεπε μετά να πάρουμε τα αρνητικά αυτών που επέστρεφαν, όπως αναφέραμε και παραπάνω. Αρχικά υπολογίζει την ενέργεια κάθε διανύσματος και επιβάλλεται μία μάσκα στα επιμέρους διανύσματα η οποία κρατά μόνο όσα ξεπερνούν κάποιο κατώφλι ενέργειας με το οποίο πειραματιστήκαμε σημαντικά για να πάρουμε τα καλύτερα αποτελέσματα. Με τον τρόπο αυτό απορρίπτονται πολύ μικρές ή ασταθείς μετατοπίσεις, που συνήθως αντιστοιχούν είτε σε επίπεδες περιοχές είτε σε θορυβώδεις εκτιμήσεις - outliers. Στη συνέχεια, αντί για μέσο όρο, λαμβάνουμε τη **διάμεσο** των επιζώντων τιμών ξεχωριστά στους άξονες x και y :

$$(\Delta x, \Delta y) = (\text{median}\{d_x^{(k)}\}, \text{median}\{d_y^{(k)}\}), \quad (9)$$

καθώς η διάμεσος είναι πιο ανθεκτική σε ακραίες τιμές.

Αν κανένα feature δεν περάσει το κατώφλι ενέργειας, η συνάρτηση επιστρέφει πάλι τη διάμεσο όλων των διανυσμάτων, ώστε ο αλγόριθμος να μην αποτυγχάνει λόγω έλλειψης ισχυρών σημείων.

Στο συνολικό σύστημα παρακολούθησης, για κάθε νέο καρέ εφαρμόζουμε την παραπάνω διαδικασία ξεχωριστά στο πρόσωπο, στο αριστερό χέρι και στο δεξί χέρι. Το διάνυσμα $(\Delta x, \Delta y)$ που προκύπτει προστίθεται στις συντεταγμένες του αντίστοιχου bounding box, ενώ το πλάτος και το ύψος του παραμένουν σταθερά. Με αυτόν τον τρόπο το παράθυρο μεταφέρεται από καρέ σε καρέ ακολουθώντας την κίνηση του αντικειμένου.

Αρχικά για να επιβεβαιώσουμε τη λειτουργικότητα της παραπάνω μεθόδου υπολογισμού της μετατόπισης των παραθύρων εφαρμόσαμε τη συνάρτηση `displ()` στο απλό πείραμα με την μετατόπιση (1,1) της εικόνας και τα διανύσματα οπτικής ροής που υπολογίστηκαν από τον Lucas-Kanade για τις παραμέτρους $\rho=5$ και $\epsilon=0.001$ και του TV-L1. Τα αποτελέσματα φαίνονται στον παρακάτω πίνακα 6:

Περιοχή	Μέθοδος	disp. d_x	disp. d_y	Error
face (115 features)	Uni-scale LK	1.0004	0.9999	(0.0004, 0.0001)
	TV-L1	0.9997	0.9983	(0.0003, 0.0017)
	Expected	1.0000	1.0000	
left_hand (50 features)	Uni-scale LK	1.0202	2.4967	(0.0202, 1.4967)
	TV-L1	0.9992	1.0010	(0.0008, 0.0010)
	Expected	1.0000	1.0000	
right_hand (35 features)	Uni-scale LK	0.9988	1.0011	(0.0012, 0.0011)
	TV-L1	1.0001	1.0021	(0.0001, 0.0021)
	Expected	1.0000	1.0000	

Πίνακας 6. Αποτελέσματα sanity check για τη συνάρτηση `displ()`: σύγκριση Uni-scale LK και TV-L1 με αναμενόμενη μετατόπιση (1,1) με $\rho=5$ και $\epsilon=0.001$ και threshold ενέργειας 5

Παρατηρούμε ότι αυτή η μέθοδος μας δίνει πολύ ακριβή αποτελέσματα σε σχέση με τον προηγούμενο απλό μέσο όρο όλων των σημείων που δοκιμάσαμε προηγουμένως, με εξαίρεση τη κατακόρυφη μετατόπιση του αριστερού χεριού όπου παρατηρούμε ένα μεγάλο σφάλμα, για να το λύσουμε δοκιμάσαμε να αυξήσουμε το ρ σε 10 και τα αποτελέσματα φαίνονται στον παρακάτω πίνακα 7:

Περιοχή	Μέθοδος	disp. d_x	disp. d_y	Error
face (115 features)	Uni-scale LK	0.9974	0.9998	(0.0026, 0.0002)
	Expected	1.0000	1.0000	
left_hand (50 features)	Uni-scale LK	0.9952	0.9991	(0.0048, 0.0009)
	Expected	1.0000	1.0000	
right_hand (35 features)	Uni-scale LK	0.9991	1.0011	(0.0009, 0.0011)
	Expected	1.0000	1.0000	

Πίνακας 7. Επιπλέον αποτελέσματα sanity check για τη συνάρτηση `displ()`: Uni-scale LK με αναμενόμενη μετατόπιση (1,1) με $\rho=10$ και $\epsilon=0.001$ και threshold ενέργειας 5

Όντως λύσαμε αυτό το μικρό σφάλμα και τώρα έχουμε πολύ ακριβή αποτελέσματα και για το αριστερό χέρι και αυτές είναι οι τιμές που χρησιμοποιήσαμε για την τελική υλοποίηση μας.

Οπότε τώρα περνάμε στη διαδικασία παρακολούθησης, όπου για κάθε νέο καρέ υπολογίζουμε την οπτική ροή στα χαρακτηριστικά σημεία του bounding box, εφαρμόζουμε τη συνάρτηση `displ()` για να εξάγουμε ένα διάνυσμα μετατόπισης και ενημερώνουμε τις συντεταγμένες του bounding box προσθέτοντας το διάνυσμα αυτό. Με αυτόν τον τρόπο το παράθυρο παρακολουθεί την κίνηση του αντικειμένου από καρέ σε καρέ. Να σημειωθεί για τα παραδοτέα ότι για τις τελικές εικόνες της παρακολούθησης του προσώπου και των χεριών με το


ορθογώνιο παρακολούθησης σχεδιασμένο σε καθεμιά, προκειμένου να φαίνεται καλύτερα η ροή της κίνησης τις κολλήσαμε σε ένα ενιαίο μεγάλο πλέγμα ώστε να διατηρείται και να φαίνεται η σειρά της κίνησης των καρτέ και να φαίνεται καλύτερα η ροή της κίνησης, οπότε αν ζουμάρετε λίγο θα μπορείτε να τις δείτε όλες τις εικόνες κανονικά. Επίσης, με τη βοήθεια της βιβλιοθήκης cv2.VideoWriter μετατρέψαμε την ακολουθία εικόνων με τα κουτιά σε βίντεο με 5 fps για να φαίνεται καλύτερα η κίνηση. Τα παραπάνω αρχεία αντιστοιχούν στα αρχεία tracking...jpg tracking...mp4 που θα βρείτε στα παραδοτέα ανάλογα και με τις αντίστοιχες παραμέτρους που χρησιμοποιήθηκαν για κάθε πείραμα.

Παρακάτω φαίνονται ορισμένα καρτέ από την τελική κίνηση της παρακολούθησης για το πρόσωπο, το αριστερό χέρι και το δεξί χέρι με παραμέτρους $\rho=1$ και $\epsilon=0.1$ και κατώφλι ενέργειας 0.1, όπου φαίνεται ότι η παρακολούθηση δεν λειτουργεί σωστά λόγω των κακών εκτιμήσεων της οπτικής ροής που είχαμε δει και πριν με αυτές τις παραμέτρους (οι παρακάτω εικόνες είναι κομμένα screenshots από τα αρχεία tracking...jpg, που έχουν όλες τις εικόνες ενωμένες, που θα βρείτε στα παραδοτέα):



(α') Καρέ 23 → 27

Σχήμα 8. Παράδειγμα Lucas-Kanade για $\rho=1$, $\epsilon=0.1$ κατώφλι 0.1 .




(α') Καρέ 66 → 70

Σχήμα 9. Παράδειγμα Lucas-Kanade για $\rho=1$, $\epsilon=0.1$ κατώφλι 0.1 .

Παρατηρούμε ότι όντως με αυτές τις τιμές των παραμέτρων η παρακολούθηση δεν λειτουργεί σωστά, καθώς τα κουτιά χάνουν το αντικείμενο που παρακολουθούν και μετατοπίζονται σε λάθος σημεία, ειδικά στο αριστερό χέρι όπου η κίνηση είναι πιο έντονη.


Οπότε πρέπει αν αυξήσουμε το ρ και το κατώφλι και να μειώσουμε το ϵ για να έχουμε καλύτερες εκτιμήσεις της οπτικής ροής και συνεπώς καλύτερη παρακολούθηση. Παρακάτω φαίνονται ορισμένα καρτέ από την τελική κίνηση της παρακολούθησης για το

πρόσωπο, το αριστερό χέρι και το δεξί χέρι με παραμέτρους $\rho=5$ και $\epsilon=0.001$ και κατώφλι ενέργειας 1, όπου φαίνεται ότι η παρακολούθηση λειτουργεί πολύ καλύτερα λόγω των πολύ καλύτερων εκτιμήσεων της οπτικής ροής που είχαμε με αυτές τις παραμέτρους:



(α') Καρέ 23 $\rightarrow$ 27


Σχήμα 10. Παράδειγμα Lucas-Kanade για $\rho=5$, $\epsilon=0.001$ κατώφλι 1 .



(α') Καρέ 66 $\rightarrow$ 70


Σχήμα 11. Παράδειγμα Lucas-Kanade για $\rho=5$, $\epsilon=0.001$ κατώφλι 1 .

Παρατηρούμε ότι με τις νέες παραμέτρους έχουμε πολύ καλύτερη παρακολούθηση στα ίδια ακριβώς καρέ όπως φαίνεται και μόνο στα τελευταία καρέ όπου η ομιλήτρια κάνει μία πολύ απότομη κίνηση με το αριστερό χέρι δεν έχουμε τέλεια παρακολούθηση, κάτι το οποίο θα βελτιώσουμε με τη πολυκλιμακωτή εκδοχή του αλγορίθμου. Παρολαυτά, δοκιμάσαμε και με τις παραμέτρους $\rho=10$ και $\epsilon=0.001$ και κατώφλι ενέργειας 10 και τα αποτελέσματα φαίνονται στα παρακάτω σχήματα για ίδια καρέ που είχαμε επιλέξει παραπάνω:



(α') Καρέ 23 $\rightarrow$ 27


Σχήμα 12. Παράδειγμα Lucas-Kanade για $\rho=10$, $\epsilon=0.001$ κατώφλι 10 .



(α') Καρέ 66 $\rightarrow$ 70

Σχήμα 13. Παράδειγμα Lucas-Kanade για $\rho=10$, $\epsilon=0.001$ κατώφλι 10 .

Παρατηρούμε ότι με αυτές τις παραμέτρους έχουμε χειρότερα αποτελέσματα καθώς τόσο στα καρέ 23 με 27 έχε χαλάσει η παρακολούθηση του δεξιού χεριού ενώ και στα καρέ 66 με 70 η παρακολούθηση χειροτέρευσε, ενδεχομένως επειδή με τόσο υψηλό κατώφλι ενέργειας αποκλείουμε σημαντικά διανύσματα που συνεισφέρουν στη παρακολούθηση. Οπότε, για την τελική υλοποίηση κρατήσαμε τα αποτελέσματα με $\rho=10$, $\epsilon=0.001$ και κατώφλι ενέργειας 5, ώστε να διατηρήσουμε το trade-off μεταξύ των παραμέτρων. Τα αποτελέσματα της παρακολούθησης με αυτές τις παραμέτρους φαίνονται στις παρακάτω εικόνες:



(α') Καρέ 23 $\rightarrow$ 27

Σχήμα 14. Παράδειγμα Lucas-Kanade για $\rho=10$, $\epsilon=0.001$ κατώφλι 5 .



(α') Καρέ 66 $\rightarrow$ 70

Σχήμα 15. Παράδειγμα Lucas-Kanade για $\rho=10$, $\epsilon=0.001$ κατώφλι 5 .

Παρατηρούμε ότι βελτιώθηκε η παρακολούθηση για την έντονη κίνηση του αριστερού χεριού

στα τελευταία καρέ λόγω της διατήρησης των πιο έντονων κινήσεων λόγω του υψηλού κατωφλίου αλλά το δεξί χέρι ακόμα δεν παρακολουθείται τελείως σωστά, οπότε ως τελική βέλτιστη μας λύση για τον Lucas Kanade θα επιλέξουμε το ζευγάρι παραμέτρων $\rho=5$, $\epsilon=0.001$ και κατώφλι ενέργειας 1, καθώς μας δίνει τα καλύτερα αποτελέσματα για όλη την εικόνα συνολικά ενώ τα σφάλματα το αριστερού χεριού στα τελευταία καρέ τα οποία οφείλονται στην μεγάλη κίνηση την οποία κάνει η ομιλήτρια σε εκείνα τα καρέ οπότε είναι αδύνατο να τα μειώσουμε με τον απλο Lucas Kanade θα τα επιλύσουμε με τον πολυκλιμακωτό στην επόμενη ενότητα.

Στη συνέχεια πειραματιστήκαμε με τον έτοιμο αλγόριθμο TV-L1 της OpenCV, ο οποίος είναι πιο ανθεκτικός σε μεγάλες κινήσεις και θόρυβο. Διατηρήσαμε το κατώφλι ενέργειας 1 και τα αποτελέσματα της παρακολούθησης με τον TV-L1 φαίνονται στις παρακάτω εικόνες:



(α') Καρέ 44 → 48

Σχήμα 16. Παράδειγμα TV-L1 με κατώφλι 1 .




(α') Καρέ 66 → 70

Σχήμα 17. Παράδειγμα TV-L1 με κατώφλι 1 .

Γενικά, παρατηρήσαμε ότι το αποτέλεσμα με τη μέθοδο TV-L1 έγινε χειρότερο σε σχέση με τον απλό Lucas-Kanade. Ειδικότερα, στο διάστημα όπου η ομιλήτρια εκτελεί αργές κινήσεις λάβαμε περίπου τα ίδια αποτελέσματα με πριν σε όλες τις περιοχές, ωστόσο στο δεύτερο μισό του βίντεο όπως φαίνεται στα παραπάνω καρέ όπου κάνει πιο γρήγορες κινήσεις ο αλγόριθμος TV-L1 έχει σημαντικό σφάλμα παρακολούθησης στο αριστερό χέρι. Αυτό μπορεί να οφείλεται στο γεγονός ότι είναι μέθοδος πυκνής οπτικής ροής με ισχυρή χωρική εξομάλυνση, άρα τείνει να δίνει πιο ομαλά και συχνά μικρότερα διανύσματα, ιδιαίτερα σε μικρά crops, σε περιοχές χαμηλής υψής ή σε παραμορφώσιμες περιοχές όπως τα

χέρια. Οπότε σε διαστήματα όπου οι κινήσεις είναι μεγάλες τα διανύσματα όπου παραγει δεν είναι αρκετά για να ακολουθήσουν τη πραγματική κίνηση. Επίσης, ο τρόπος με τον οποίο χρησιμοποιούμε τον αλγόριθμο και τον συγκρίνουμε με τον απλό LK δίνει σαφές πλεονέκτημα στον δεύτερο καθώς τους αξιολογούμε τοπικά σε σημεία ενδιαφέροντος κάτι το οποίο ενισχύει τον τοπικό χαρακτήρα του LK ενώ μειώνει τη global λογική του πρώτου. Βέβαια να σημειωθεί, ότι δοκιμάσαμε να χρησιμοποιήσουμε τον TV-L1 και με περισσότερα scales (3) αλλά και διατηρώντας όλα τα διανύσματα της οπτικής ροής και όχι μόνο στα σημεία ενδιαφέροντος, αλλά και πάλι το αποτέλεσμα ήταν χειρότερο από τον LK.

Τέλος, πειραματιστήκαμε και με τον εναλλακτικό τρόπο που προτείνεται για την εξαγωγή της μετατόπισης των παραθύρων, όπου αντί να χρησιμοποιούμε τη διάμεσο των διανυσμάτων οπτικής ροής που περνάνε ένα κατώφλι ενέργειας, χρησιμοποιούμε τον μέσο όρο όλων των energy masked διανυσμάτων οπτικής ροής που υπολογίζονται στα σημεία ενδιαφέροντος. Τα αποτελέσματα φαίνονται στις παρακάτω εικόνες έχοντας επιλέξει για τιμές παραμέτρων $\rho=5$ και $\epsilon=0.001$ και κατώφλι ενέργειας 1:



(α') Καρέ 44 → 48

Σχήμα 18. Παράδειγμα Lucas-Kanade mean criterion και $\rho=5$ $\epsilon=0.001$ με κατώφλι 1 .



(α') Καρέ 66 → 70

Σχήμα 19. Παράδειγμα Lucas-Kanade mean criterion και $\rho=5$ $\epsilon=0.001$ με κατώφλι 1 .

Παρατηρούμε ότι με αυτή τη μέθοδο έχουμε χειρότερα αποτελέσματα σε σχέση με τη μέθοδο της διαμέσου, καθώς τα κουτιά χάνουν πιο εύκολα το αντικείμενο που παρακολουθούν και μετατοπίζονται σε λάθος σημεία, ειδικά στο αριστερό χέρι όπου η κίνηση είναι πιο έντονη.

Αυτό μπορεί να οφείλεται στο γεγονός ότι ο μέσος όρος είναι πιο ευαίσθητος σε outliers και θόρυβο στα διανύσματα οπτικής ροής, ενώ η διάμεσος είναι πιο ανθεκτική και δίνει μια πιο σταθερή εκτίμηση της γενικής κατεύθυνσης της κίνησης. Ωστόσο, στο τελευταίο καρέ όπου η ομιλήτρια κάνει την πιο έντονη κίνηση με το αριστερό χέρι, η μέθοδος του μέσου όρου δίνει ελαφρώς καλύτερη παρακολούθηση από τη μέθοδο της διαμέσου, πιθανώς επειδή σε αυτές τις περιπτώσεις ο διάμεσος δεν ανταποκρίνεται καλά στη μεγάλη μεταβολή επειδή δεν λαμβάνει υπόψη τις μεγάλες τιμές ενώ ο μέσος όρος που τις συμπεριλαμβάνει αποδίδει καλύτερα. Οπότε για την τελική υλοποίηση μας κρατήσαμε τη μέθοδο της διαμέσου για την εξαγωγή της μετατόπισης των παραθύρων.

1.3 Πολυ-Κλιμακωτός Υπολογισμός Οπτικής Ροής


Η μονής κλίμακας εκδοχή του Lucas-Kanade λειτουργεί καλά όταν οι μετατοπίσεις μεταξύ δύο διαδοχικών καρέ είναι σχετικά μικρές για 1-2 pixels όπως είδαμε. Όταν όμως η κίνηση είναι μεγαλύτερη όπως για 3 pixels όπως είδαμε ή για περισσότερο όπως για παράδειγμα στα τελευταία καρέ του βίντεο, ο αλγόριθμος αποτυγχάνει επειδή η γραμμικοποίηση που χρησιμοποιεί γύρω από την τρέχουσα εκτίμηση παύει να είναι ακριβής και η επαναληπτική λύση μπορεί να συγκλίνει αργά ή σε λανθασμένη ροή. Για αυτόν τον λόγο υλοποιήσαμε την πολυ-κλιμακωτή εκδοχή, όπου δεν αλλάζει η βασική λογική του του Lucas-Kanade, αλλά αντί να λύνουμε εξαρχής το πρόβλημα στην πλήρη ανάλυση, ξεκινάμε από πολύ μικρότερες και πιο λείες εικόνες όπου η ίδια πραγματική κίνηση αντιστοιχεί σε μικρότερη φαινομενική μετατόπιση σε pixels. Πιο συγκεκριμένα, οι εικόνες αναλύονται σε γκαουσιανές πυραμίδες, μετά υπολογίζουμε την οπτική ροή από τις πιο μικρές (τραχείες) στις πιο μεγάλες (λεπτομερείς) κλίμακες, χρησιμοποιώντας τη λύση της μικρής κλίμακας ως αρχική συνθήκη για τη μεγάλη κλίμακα. Τα αναλυτικά βήματα του πως υλοποιήσαμε εμείς την πολυ-κλιμακωτή εκδοχή του Lucas-Kanade περιγράφονται παρακάτω.

Πιο συγκεκριμένα, η συνάρτηση `lk_multiscale(I1, I2, features, rho, epsilon, d_x0, d_y0, num_scales)` μας επιστρέφει τις τελικές εκτιμήσεις των μετατοπίσεων χρησιμοποιώντας ως υπορουτίνα τη μονοκλιμακωτή `lk()` που αναλύσαμε προηγουμένως για να υπολογίζει την εκτίμηση της μετατόπισης από το υψηλότερο στο χαμηλότερο επίπεδο. Αρχικά κατασκευάζει δύο γκαουσιανές πυραμίδες για τις εικόνες `I1`, `I2`, εφαρμόζοντας κάθε φορά Gaussian blur με $\sigma = 3$ και έπειτα υποδειγματοληψία ανά 2, ώστε να μετριάζεται το aliasing. Έτσι δημιουργούνται εικόνες από την πλήρη ανάλυση μέχρι την πιο αδρή κλίμακα. Στη συνέχεια αρχικοποιούνται πυκνοί χάρτες μετατόπισης `d_x_map`, `d_y_map` στην πιο αδρή εικόνα, όπου συνήθως τη μετατόπιση για όλα τα σημεία τη θεωρούμε μηδενική. Όπως αναφέραμε και στην υλοποίηση του απλού η `lk()` επιστρέφει όχι μόνο τις μετατοπίσεις στα feature points, αλλά και τους πλήρεις πυκνούς χάρτες μετατόπισης του τρέχοντος crop σε όλα τα σημεία. Με αυτόν τον τρόπο, το αποτέλεσμα του simple LK σε μια αδρή κλίμακα δεν χάνεται, αλλά χρησιμοποιείται μετά ως αρχική συνθήκη για την αμέσως λεπτομερέστερη.

Για κάθε επίπεδο της πυραμίδας ακολουθούμε τα επόμενα βήματα. Πρώτα κλιμακώνουμε τα feature points της αρχικής εικόνας με τον κατάλληλο παράγοντα, ώστε να αναφέρονται


στις σωστές συντεταγμένες του τρέχοντος επιπέδου. Έπειτα καλούμε την `lk()` περνώντας ως αρχική συνθήκη τους πυκνούς χάρτες `d_x_map`, `d_y_map` που είχαμε υπολογίσει για το προηγούμενο επίπεδο ωστόσο αυτός ο χάρτης έχει τις διαστάσεις της προηγούμενης εικόνας, το οποίο θα εξηγήσουμε σύντομα πως το λύνουμε για να μπορούμε να τους χρησιμοποιήσουμε σωστά ως αρικοποιήσεις. Οπότε η μόνη διαφορά με τον απλό είναι ότι δεν ξεκινά από μηδενική ροή αλλά από την ήδη υπολογισμένη εκτίμηση της αδρότερης κλίμακας. Αφού ολοκληρωθεί η λύση σε ένα επίπεδο, οι πυκνοί χάρτες παρεμβάλλονται γραμμικά στην επόμενη μεγαλύτερη ανάλυση μέσω της `map_coordinates` ή για καλύτερη ανάλυση με την `cv2.resize` και στη συνέχεια πολλαπλασιάζονται επί 2, επειδή μία μετατόπιση ενός pixel στην αδρή εικόνα αντιστοιχεί σε περίπου δύο pixels στην επόμενη λεπτομερέστερη.

Συνεπώς, η πολυ-κλιμακωτή μέθοδος της υλοποίησής μας πρέπει να αντιμετωπιστεί ως διαδοχική επαναχρησιμοποίηση του simple LK σε διαφορετικές κλίμακες χτίζοντας μια πυραμίδα που μεταφέρει και επανακλιμακώνει τους πυκνούς χάρτες μετατόπισης από επίπεδο σε επίπεδο, ενώ η πραγματική τοπική εκτίμηση της ροής γίνεται κάθε φορά από την ήδη υλοποιημένη `lk()`, η τελική εκτίμηση γίνεται στο τελικό επίπεδο και η ολική μετατόπιση με τελευταίο αποτέλεσμα περασμένο από τη συνάρτηση `displ()` όπως πριν. Χρησιμοποιήσαμε πολλούς συνδυασμούς παραμέτρων καθώς αποδείχτηκε ότι ακριβώς οι παράμετροι ου είχαμε βρει στον απλό δεν ανταποκρίνονταν πλήρως για τον πολυ κλιμακωτό ώστε να παρακολουθεί με ακρίβεια και στο τέλος τις απότομες κινήσεις του αριστερού χεριού, τελικά επιλέξαμε παραμέτρους $\rho=5$, $\epsilon=0.01$ και $\text{num_scales}=3$, κατώφλι 1. Τα αποτελέσματα της παρακολούθησης με τον πολυ-κλιμακωτό Lucas-Kanade φαίνονται στις παρακάτω εικόνες:



(α') Καρέ 44 → 48

Σχήμα 20. Παράδειγμα Multi-scale και $\rho=5$ $\epsilon=0.01$, 3 scales με κατώφλι 1 .



(α') Καρέ 66 → 70

Σχήμα 21. Παράδειγμα Multi-scale και $\rho=5$ $\epsilon=0.01$, 3 scales με κατώφλι 1 .

Όπως παρατηρούμε ο πολυκλιμακωτός μας έδωσε πολύ καλύτερη παρακολούθηση σε σχέση με τον απλό. Αυτό γίνεται ιδιαίτερα εμφανές στα τελευταία καρέ καθώς ενώ πριν ο απλός αλγόριθμος αποτύγχανε πλήρως να παρακολουθήσει το αριστερό χέρι στις τελικές απότομες κινήσεις του επειδή ήταν πολλά πίκσελ, ο πολυκλιμακωτός λόγω της ανάλυσης του σε διαδοχικές κλίμακες μπορεί να σπάσει αυτή τη μεγάλη κίνηση σε μικρότερη στις πιο αδρές κλίμακες, δίνοντας καλύτερες αρχικοποιήσεις στις επόμενες κλίμακες βοηθώντας τον αλγόριθμο να ακολουθήσει επιτυχώς και τις πιο μεγάλες κινήσεις. Συμπερασματικά , ο πολυκλιμακωτός αποδείχτηκε καλύτερος για μεγάλες κινήσεις ωστόσο θα συνεχίσουμε με μια ανάλυση της ταχύτητας σύγκλισης των 2 αλγορίθμων. Ειδικότερα, παρακάτω φαίνεται ένας πίνακας με τις συνολικές επαναλήψεις , τον συνολικό χρόνο , τον μέσο αριθμό επαναλήψεων ανά καρέ και τον μέσο χρόνο ανά καρέ για τον απλό και τον πολυ-κλιμακωτό Lucas-Kanade με τις βέλτιστες παραμέτρους που επιλέξαμε για την εκάστοτε τελική υλοποίηση μας:

Μέθοδος	Συνολικές επαν.	Συνολικός χρόνος (s)	Μέσες επαν./καρέ	Μέσος χρόνος/καρέ (s)
Uni-scale LK	31050	92.576	443.57	1.323
Multi-scale LK	93150	155.848	1330.71	2.226

Πίνακας 8. Σύγκριση του συνολικού υπολογιστικού κόστους και της ταχύτητας σύγκλισης μεταξύ Uni-scale και Multi-scale Lucas-Kanade στο συνολικό πείραμα παρακολούθησης.

Όπως μπορούμε να παρατηρήσουμε , όπως ήταν αναμενόμενο , ο πολυκλιμακωτός αλγόριθμος απαιτούσε σημαντικά περισσότερο χρόνο καθώς ο απλός τρέχει για κάθε καρέ για μία κλίμακα ενώ ο πολυκλιμακωτός για 3 κλίμακες, για αυτό μάλιστα παρατηρούμε ότι ο συνολικός αριθμός επαναλήψεων είναι τριπλάσιος από τον απλό αλγόριθμο, ενώ και στις δύο περιπτώσεις σε κάθε καρέ χρησιμοποιούνται το μέγιστο των 150 επαναλήψεων , ενδεχομένως επειδή είχαμε βάλει πάρα πολύ μικρό το κατώφλι σύγκλισης. Ωστόσο, αυτός ο τριπλασιασμός δεν ισχύει στο χρόνο όπου θα μας ενδιέφερε για πραγματικές εφαρμογές , ειδικότερα ενώ κάνει τριπλάσιες επαναλήψεις ο χρόνος δεν είναι ούτε διπλάσιος συνολικά ούτε ανά καρέ. Οπότε , γενικά ο πολυκλιμακωτός αλγόριθμος είναι πιο αργός από τον απλό, ωστόσο η διαφορά δεν είναι τόσο μεγάλη όσο θα περιμέναμε με βάση τον αριθμό των επαναλήψεων, πιθανώς επειδή στις πιο αδρές κλίμακες οι επαναλήψεις είναι πιο γρήγορες λόγω της μικρότερης ανάλυσης και του ότι οι εκτιμήσεις της ροής είναι πιο ομαλές και συνεπώς συγκλίνουν πιο γρήγορα.

2. Εντοπισμός Χωρο-χρονικών Σημείων Ενδιαφέροντος και Εξαγωγή Χαρακτηριστικών σε Βίντεο Ανθρωπίνων Δράσεων

Στο δεύτερο μέρος της άσκησης ασχολούμαστε με την εξαγωγή χωρο-χρονικών χαρακτηριστικών από βίντεο ανθρωπίνων δράσεων σε grayscale, με στόχο την κατηγοριοποίησή τους σε μία εκ των τριών κλάσεων της βάσης KTH: (*walking, running, handclapping*) της βάσης KTH. Η προσέγγιση βασίζεται στη μεθοδολογία των Laptev et al. [1], που εισάγει χωρο-χρονικά σημεία ενδιαφέροντος και περιγραφητές HOG/HOF σε συνδυασμό με Bag-of-Words και SVM.

2.1 Χωρο-χρονικά Σημεία Ενδιαφέροντος

Ένα **χωρο-χρονικό σημείο ενδιαφέροντος** είναι ένα voxel (x, y, t) του βίντεο που χαρακτηρίζεται από σημαντική τοπική μεταβολή τόσο στον χωρικό όσο και στον χρονικό άξονα. Διαισθητικά, μια ομαλή επιφάνεια του βίντεο δεν αποτελεί σημείο ενδιαφέροντος ούτε στον χώρο ούτε στον χρόνο, ενώ μια ακμή που παραμένει στάσιμη είναι ενδιαφέρουσα χωρικά αλλά όχι χρονικά. Μόνο οι περιοχές που εμφανίζουν *συνγχρόνως* χωρική μεταβολή (γωνίες, αλλαγές κατεύθυνσης) και χρονική μεταβολή (κίνηση, εμφάνιση και εξαφάνιση αντικειμένων) ικανοποιούν το κριτήριο και επιλέγονται. Τα σημεία αυτά είναι πληροφοριακά πλούσια και ιδανικά ως βάση για την εξαγωγή συμπαγών τοπικών περιγραφητών.

Υλοποιήθηκαν δύο ανιχνευτές: ο **Harris3D** και ο **Gabor**.

2.1.1 Ανιχνευτής Harris3D

Ο ανιχνευτής Harris3D [2] αποτελεί χωρο-χρονική επέκταση του κλασικού ανιχνευτή γωνιών Harris-Stephens. Ο 2D Harris-Laplacian εντοπίζει χωρικές γωνίες σε πολλαπλές κλίμακες ανεξαρτήτως κίνησης, ενώ ο Harris3D εντοπίζει σημεία που πληρούν το κριτήριο γωνιότητας και στις τρεις διαστάσεις και συνεπώς είναι πιο εστιασμένος στις δράσεις, λαμβάνοντας υπόψη και τη διάσταση του χρόνου. Η διαφορά τους φαίνεται εποπτικά στο Σχήμα 22:



(α') Multiscale 2D Harris-Laplacian



(β') Multiscale Harris3D

Σχήμα 22. Σύγκριση πολυκλιμακωτών 2D Harris-Laplacian και Harris3D σε καρέ από βίντεο "walking". Ο 2D ανιχνευτής εντοπίζει αφθονία γωνιών σε όλο το πλαίσιο: περιγράμματα, υφές και γωνίες φόντου, σε διαφορετικές χωρικές κλίμακες. Από την άλλη ο Harris3D επιλέγει πιο εστιασμένα σημεία, κυρίως στις περιοχές των άκρων που αφορά τον βηματισμό, φιλτράροντας ανενεργές περιοχές του φόντου.

Όσον αφορά τον ανιχνευτή 3D Harris, η βασική ιδέα είναι: αν μετακινήσουμε ένα μικρό χωρο-χρονικό παράθυρο γύρω από ένα voxel προς οποιαδήποτε κατεύθυνση (x, y, t) , ένα σημείο ενδιαφέροντος είναι εκεί όπου η μεταβολή της έντασης είναι μεγάλη για όλες τις κατευθύνσεις. Αυτό κωδικοποιείται μέσω του 3×3 δομικού τανυστή (second-moment matrix):

$$\mathbf{M}(x, y, t; \sigma, \tau) = g(s\sigma, s\tau) * \begin{pmatrix} L_x^2 & L_x L_y & L_x L_t \\ L_x L_y & L_y^2 & L_y L_t \\ L_x L_t & L_y L_t & L_t^2 \end{pmatrix} \quad (10)$$

όπου $L = g(\sigma, \tau) * I$ είναι το βίντεο εξομαλυσμένο στην κλίμακα διαφόρισης (σ, τ) , οι παράγωγοι L_x, L_y, L_t υπολογίζονται με τον πυρήνα κεντρικών διαφορών $[-1, 0, 1]$ κατά τον αντίστοιχο άξονα, και $g(s\sigma, s\tau)$ είναι ο γκαουσιανός πυρήνας ολοκλήρωσης που εξομαλύνει τα γινόμενα παραγώγων. Η διάκριση των δύο κλιμάκων είναι ουσιώδης: η κλίμακα διαφόρισης καθορίζει την ανάλυση στην οποία ανιχνεύονται οι τοπικές μεταβολές, ενώ η κλίμακα ολοκλήρωσης ορίζει το χωρο-χρονικό γειτονικό πλαίσιο μέσα στο οποίο αθροίζονται. Ο πυρήνας $[-1, 0, 1]$ που χρησιμοποιούμε είναι ο απλούστερος πυρήνας κεντρικής διαφοράς πρώτης τάξης: εκτιμά την παράγωγο στο κεντρικό σημείο χρησιμοποιώντας τους δύο γείτονές του, χωρίς να εισάγει μετατόπιση φάσης.

Όταν και οι τρεις ιδιοτιμές του $\mathbf{M}$ είναι μεγάλες, το voxel αναγνωρίζεται ως «γωνία» στον χωρο-χρόνο. Ως 3D κριτήριο γωνιότητας χρησιμοποιείται το εξής:

$$H(x, y, t) = \det(\mathbf{M}) - k \cdot \text{trace}^3(\mathbf{M}) \quad (11)$$

Για την τελική επιλογή των σημείων, τα δεδομένα καταφλιολοποιούνται με βάση το μέγιστο της συνολικής απόκρισης του βίντεο $H > \theta \cdot H_{\max}$. Έπειτα, τα voxels που ικανοποιούν το

κριτήριο μετατρέπονται σε μονοδιάστατο διάνυσμα (flattening), ταξινομούνται ως προς την έντασή τους και διατηρούνται τα N σημεία με τη μέγιστη τιμή.

Ως προς την υλοποίηση, η 3D Gaussian εξομάλυνση εκτελείται ως τρεις διαδοχικές 1D συνελίξεις κατά τους άξονες x, y, t χωριστά, εκμεταλλευόμενη τη διαχωρισιμότητα (separability) του γκαουσιανού πυρήνα. Επίσης, ο υπολογισμός του $\det(\mathbf{M})$ γίνεται αναλυτικά μέσω της εκτεταμένης μορφής της 3×3 ορίζουσας, αποφεύγοντας αριθμητική αποσύνθεση σε ιδιοτιμές.

Αν και στη βιβλιογραφία [1] προτείνεται πολυκλιμακική ανίχνευση (εξαγωγή σημείων σε πολλαπλές κλίμακες (σ_i, τ_j)), στην παρούσα εργασία χρησιμοποιήθηκε ενιαία κλίμακα για μείωση υπολογιστικού κόστους.

2.1.2 Ανιχνευτής Gabor

Ο ανιχνευτής Gabor αποτελεί χωρο-χρονική μέθοδο ανίχνευσης σημείων ενδιαφέροντος βασισμένη σε φιλτράρισμα με τράπεζα φίλτρων Gabor. Σε αντίθεση με τον Harris3D, που ανιχνεύει voxels με μεγάλη γεωμετρική μεταβολή σε όλες τις κατευθύνσεις, ο Gabor εστιάζει στην *ενέργεια* τοπικής κίνησης: ανιχνεύει περιοχές που παρουσιάζουν έντονη χρονική μεταβολή συγκεκριμένης χωροχρονικής συχνότητας. Αυτό τον κάνει πιο «επιεική» ως προς τη χωρική γεωμετρία αλλά πιο εκλεκτικό ως προς τον *ρυθμό* της κίνησης, ιδιότητα ιδιαίτερα χρήσιμη για περιοδικές δράσεις όπως βάδισμα και χειροκρότημα.

Η βασική ιδέα: ένα φίλτρο Gabor είναι επιλεκτικό τόσο ως προς τη χωρική / χρονική κλίμακα όσο και ως προς τη *συχνότητα* κίνησης. Ορίζεται ως γκαουσιανή περιβάλλουσα διαμορφωμένη από ημιτονοειδή φέρουσα:

$$g_c(x, y, t; \sigma_x, \sigma_y, \sigma_t) = \frac{1}{(2\pi)^{3/2} \sigma_x \sigma_y \sigma_t} \exp \left[- \left(\frac{x^2}{2\sigma_x^2} + \frac{y^2}{2\sigma_y^2} + \frac{t^2}{2\sigma_t^2} \right) \right] \cos(\omega_{x_0}x + \omega_{y_0}y + \omega_{t_0}t) \quad (12)$$

όπου $(\sigma_x, \sigma_y, \sigma_t)$ ορίζουν τη χωρο-χρονική κλίμακα (εύρος ζώνης) του φίλτρου, και $(\omega_{x_0}, \omega_{y_0}, \omega_{t_0})$ είναι οι κεντρικές γωνιακές συχνότητες στις οποίες αποκρίνεται. Στο πεδίο συχνοτήτων το φίλτρο έχει απόκριση ζωνοπερατού φίλτρου: δύο Γκαουσιανοί όγκοι συγκεντρωμένοι γύρω από $\pm(\omega_{x_0}, \omega_{y_0}, \omega_{t_0})$.

Για κάθε κλίμακα (σ, τ) ορίζεται ένα **ζεύγος τετραγωνισμού** (quadrature pair), δηλαδή ένα άρτιο φίλτρο (συνημίτονο) και ένα περιττό (ημίτονο):

$$h_{\text{ev}}(t; \tau) = \cos(2\pi\omega t) \cdot g(t; \tau), \quad h_{\text{od}}(t; \tau) = \sin(2\pi\omega t) \cdot g(t; \tau) \quad (13)$$

όπου $g(t; \tau) = \exp(-t^2/(2\tau^2))$ και $\omega = 4/\tau$. Τα φίλτρα κανονικοποιούνται ως προς τη L_1 νόρμα και εκτείνονται σε $t \in [-2\tau, 2\tau]$. Το ζεύγος αξιοποιεί την ιδιότητα ότι $\cos^2 + \sin^2 = 1$: η συνδυασμένη ενέργεια εξόδου δεν εξαρτάται από τη χρονική φάση της κίνησης, άρα ανιχνεύει ρυθμικά κινούμενες δομές ανεξαρτήτως της στιγμής μέτρησης.

Η σχέση $\omega = 4/\tau$ δεν είναι τυχαία: εξασφαλίζει ότι στο χρονικό παράθυρο $[-2\tau, 2\tau]$ χωράνε ακριβώς δύο πλήρεις ταλαντώσεις της ημιτονοειδούς φέρουσας. Αυτό διατηρεί το φίλτρο

ανταποκρινόμενο σε ένα σαφώς ορισμένο εύρος χρονικών συχνοτήτων: αρκετά στενό ώστε να είναι εκλεκτικό, αρκετά πλατύ ώστε να μην απαιτεί ακριβή συγχρονισμό με τον ρυθμό κίνησης.

Το κριτήριο ανίχνευσης είναι το άθροισμα τετραγώνων των δύο αποκρίσεων:

$$H(x, y, t) = (I * h_{ev})^2(x, y, t) + (I * h_{od})^2(x, y, t) \quad (14)$$

Όσον αφορά την υλοποίηση του, εκμεταλλευόμαστε τη *διαχωριστικότητα* του 3D φίλτρου Gabor: χωρική εξομάλυνση (2D Gaussian, κλίμακα σ) και χρονική συνέλιξη (1D Gabor, κλίμακα τ) εκτελούνται ανεξάρτητα κατά τους αντίστοιχους άξονες, μειώνοντας σημαντικά το υπολογιστικό κόστος. Σημειώνεται ότι στο πλήρες 3D μοντέλο το χωρικό τμήμα του φίλτρου έχει και χωρικές συχνότητες ($\omega_{x_0}, \omega_{y_0}$) $\neq 0$, δηλαδή είναι *προσανατολισμένο* στον χώρο. Στην υλοποίησή μας ο χωρικός προσανατολισμός αφαιρείται θέτοντας $\omega_{x_0} = \omega_{y_0} = 0$, οπότε η χωρική συνιστώσα εκφυλίζεται σε ισότροπη Γκαουσιανή εξομάλυνση, απλοποίηση που μειώνει το μέγεθος του filterbank αλλά χάνει την ευαισθησία σε χωρική κατεύθυνση κίνησης.

2.1.3 Απόρριψη Ομαλών Περιοχών και Επιλογή Σημείων

Και οι δύο ανιχνευτές ακολουθούν κοινή στρατηγική επιλογής σημείων:


1. **Κατωφλιοποίηση:** διατηρούνται μόνο voxels με $H(x, y, t) > \theta \cdot H_{\max}$ (όπου $H_{\max}$ το global maximum μεταξύ όλων των frames), ώστε να απορριφθούν ομαλές ή χαμηλής ενέργειας περιοχές. Η παράμετρος θ ελέγχει πόσο αυστηρή είναι αυτή η απόρριψη υποψηφίων.
2. **Επιλογή top-N:** Από τα υποψήφια σημεία επιλέγονται τα N με τη μεγαλύτερη τιμή απόκρισης H .

2.1.4 Απεικόνιση Σημείων Ενδιαφέροντος και Σχολιασμός

Για κάθε ανιχνευτή (Harris3D, Gabor) οπτικοποιήθηκαν η απόκριση H και τα εντοπισμένα σημεία για ένα αντιπροσωπευτικό βίντεο ανά κλάση δράσης (*walking, running, handclapping*), με παραμέτρους $\sigma=2$, $\tau=1.5$, $\theta=0.05$, $N=500$, και έπειτα με τις δοσμένες από την εκφώνηση παραμέτρους (οι οποίες παρατίθενται στο φάκελο με τα αρχεία αποτελεσμάτων).

Εξάγονται GIFs που περιλαμβάνουν ολόκληρη τη χρονική ακολουθία με σημειωμένα τα σημεία ενδιαφέροντος. Αυτό επιτρέπει την καλύτερη ποιοτική αξιολόγηση της σταθερότητας των ανιχνεύσεων. Για πιο αναλυτική αξιολόγηση των σημείων ενδιαφέροντος που εξάγει ο κάθε ανιχνευτής, για κάθε κλάση παρουσιάζονται διαδοχικά ο Harris3D εντοπισμός, το Harris3D heatmap, ο Gabor εντοπισμός και το Gabor heatmap, στα τρία frames με τη μεγαλύτερη συγκέντρωση ανιχνευμένων σημείων. Η επιλογή αυτή, διασφαλίζει ότι απεικονίζονται οι φάσεις της εκάστοτε δράσης με την πιο έντονη κινητική πληροφορία.

Παρακάτω παρουσιάζονται τα αποτελέσματα για τις τρεις κλάσεις δράσης με τις custom παραμέτρους, ξεκινώντας με την κλάση *walking*.



(α') frame 21

(β') frame 33

(γ') frame 34

Σχήμα 23. Harris3D - walking: εντοπισμένα σημεία ενδιαφέροντος.




(α') frame 21

(β') frame 33

(γ') frame 34

Σχήμα 24. Harris3D - walking: χάρτης απόκρισης H .




(α') frame 15

(β') frame 44

(γ') frame 45

Σχήμα 25. Gabor - walking: εντοπισμένα σημεία ενδιαφέροντος.




(α') frame 15

(β') frame 44

(γ') frame 45

Σχήμα 26. Gabor - walking: χάρτης ενέργειας H .




(α') frame 26

(β') frame 27

(γ') frame 28

Σχήμα 27. Harris3D - running: εντοπισμένα σημεία ενδιαφέροντος.




(α') frame 26

(β') frame 27

(γ') frame 28

Σχήμα 28. Harris3D - running: χάρτης απόκρισης H .




(α') frame 26


(β') frame 27

(γ') frame 28


Σχήμα 29. Gabor - running: εντοπισμένα σημεία ενδιαφέροντος.




Σχήμα 30. Gabor - running: χάρτης ενέργειας H .




Σχήμα 31. Harris3D - handclapping: εντοπισμένα σημεία ενδιαφέροντος.



Σχήμα 32. Harris3D - handclapping: χάρτης απόκρισης H .



Σχήμα 33. Gabor - handclapping: εντοπισμένα σημεία ενδιαφέροντος.



Σχήμα 34. Gabor - handclapping: χάρτης ενέργειας H .

Παρατηρούμε ότι και οι δύο ανιχνευτές εντοπίζουν σημεία ενδιαφέροντος στις περιοχές κίνησης (χέρια, πόδια), με σημαντικές ωστόσο διαφορές στη χωροχρονική κατανομή τους:

Ο ανιχνευτής **Gabor** παράγει μια ομαλή και πιο διάχυτη χρονική απόκριση. Επειδή χρησιμοποιεί το ζεύγος τετραγωνικής φάσης που αναλύθηκε νωρίτερα, το άθροισμα των τετραγώνων τους ($h_{ev}^2 + h_{od}^2$) παραμένει σχεδόν σταθερό κατά τη διάρκεια μιας περιοδικής κίνησης (π.χ. χειροκρότημα), με την Gaussian περιβάλλουσα να διαχέει την ενέργεια σε γειτονικά frames. Έτσι, τα σημεία κατανέμονται φυσιολογικά στον χώρο και τον χρόνο.

Αντίθετα, ο **Harris3D** απαιτεί την *ταυτόχρονη* κορύφωση ισχυρής χωρικής δομής (γωνίες, άκρα) και χρονικής μεταβολής. Η συνθήκη αυτή ικανοποιείται μόνο σε πολύ συγκεκριμένες στιγμές απότομης μεταβολής (όπως η ακριβής στιγμή της κρούσης στο *handclapping*), προκαλώντας απότομες αιχμές στην απόκριση H . Ως αποτέλεσμα, τα top- N σημεία συσσωρεύονται σε πολύ περιορισμένα, εστιασμένα χρονικά «ξεσπάσματα» (temporal bursts).

2.2 Χωρο-χρονικοί Ιστογραφικοί Περιγραφητές

Έχοντας εντοπίσει τα χωρο-χρονικά σημεία ενδιαφέροντος (x_0, y_0, t_0, σ) στην προηγούμενη ενότητα, το επόμενο βήμα είναι η *εξαγωγή χαρακτηριστικών*, δηλαδή η μετατροπή της τοπικής γειτονιάς κάθε σημείου σε ένα διάνυσμα σταθερής διάστασης που περιγράφει τι συμβαίνει γύρω από το σημείο. Για τον σκοπό αυτό χρησιμοποιούνται δύο τοπικοί περιγραφητές που συμπληρώνουν ο ένας τη λειτουργία του άλλου, οι **HOG** (Histogram of Oriented Gradients) και **HOF** (Histogram of Optical Flow), ακολουθώντας τους Laptev et al. [1] που τους εισήγαγαν ως επέκταση του κλασικού SIFT. Η δύναμη της σύζευξης βρίσκεται στο γεγονός ότι ο HOG αποτυπώνει τη στιγμιαία *εμφάνιση* (στάση σώματος, περίγραμμα μελών), ενώ ο HOF την *κίνηση* (κατεύθυνση και ένταση μετατοπίσεων).

Ο **HOG** (Histogram of Oriented Gradients), όπως είδαμε και στο προηγούμενο εργαστήριο, κωδικοποιεί τη χωρική δομή (αιχμές, περιγράμματα, υφές) μέσω του gradient της έντασης: για κάθε pixel υπολογίζει τις μερικές παραγώγους G_x, G_y , εξάγει γωνία και μέτρο, και φτιάχνει ιστόγραμμα των γωνιών σταθμισμένο με το μέτρο. Αποτυπώνει έτσι τη *στιγμαία γεωμετρία* του σώματος (στάση κορμού, θέση χεριών και ποδιών, σιλουέτα), που συχνά αρκεί από μόνη της για να ξεχωρίσει δράσεις όπως *handclapping* με ανυψωμένα χέρια έναντι *walking* με χέρια στα πλάγια.

Ο **HOF** (Histogram of Optical Flow) κωδικοποιεί αντί για γεωμετρία την *κίνηση* γύρω από το σημείο. Για κάθε ζεύγος διαδοχικών frames υπολογίζεται πεδίο οπτικής ροής (f_x, f_y) που εκτιμά πόσο και προς ποια κατεύθυνση μετακινήθηκε κάθε pixel, και στη συνέχεια κατασκευάζεται ιστόγραμμα των κατευθύνσεων σταθμισμένο με το μέτρο της ροής (ώστε ασθενείς, θορυβώδεις μετατοπίσεις να μη κυριαρχούν). Το ιστόγραμμα αυτό απομονώνει την κίνηση από την εμφάνιση και είναι ιδιαίτερα διακριτικό για περιοδικές δράσεις όπως *walking* ή *running*, όπου διαφορετικές φάσεις του κύκλου παράγουν χαρακτηριστικές κατανομές ροής.

Σε αντίθεση με την αρχική μέθοδο των Laptev et al., η οποία αναλύει έναν μεγάλο τρισδιάστατο χωροχρονικό όγκο γύρω από κάθε σημείο ενδιαφέροντος, στη δική μας υλοποίηση ακολουθήσαμε μια πιο ελαφριά προσέγγιση. Συγκεκριμένα, καταργήσαμε τη χρονική υποδιαίρεση του όγκου ($n_t = 1$) και εξετάζουμε αποκλειστικά ένα δισδιάστατο (χωρικό) παράθυρο μεγέθους $4\sigma \times 4\sigma$ στο frame όπου εντοπίστηκε το σημείο. Αυτή η απλοποίηση σε ένα χωρικό πλέγμα 3×3 διατηρεί τον τελικό περιγραφητή HOG+HOF εξαιρετικά συμπαγή (στις 144 διαστάσεις), αποτρέποντας την εκθετική αύξηση του μεγέθους του.

2.2.1 Υπολογισμός Gradient και Οπτικής Ροής

Όσον αφορά τον υπολογισμό των περιγραφητών **HOG** για κάθε frame t υπολογίζονται οι οριζόντιες και κατακόρυφες συνιστώσες της βαθμίδας έντασης μέσω κεντρικών διαφορών:

$$G_x = I * [-1, 0, 1], \quad G_y = I * [-1, 0, 1]^T \quad (15)$$

Η χρήση κεντρικών διαφορών (αντί Sobel) είναι συμβατή με τον τρόπο που υπολογίστηκαν οι παράγωγοι στους ανιχνευτές, εξασφαλίζοντας συνέπεια κλίμακας.

Από την άλλη όσον αφορά τον υπολογισμό των περιγραφητών **HOF**, για κάθε ζεύγος διαδοχικών frames ($t, t+1$) υπολογίζεται πεδίο οπτικής ροής (f_x, f_y) μέσω του αλγορίθμου **TV-L1**. Το TV-L1 παράγει πυκνή ροή με ισχυρή αντοχή σε θόρυβο και στα άλματα έντασης χάρη στον όρο ολικής μεταβολής. Χρησιμοποιήθηκε η υλοποίηση του OpenCV μέσω της `cv2.optflow.DualTVL1OpticalFlow_create(nscale=1)` που υπολογίζει τη ροή σε μία μόνο κλίμακα, αποφεύγοντας την πυραμίδα που θα αύξανε σημαντικά τον υπολογιστικό φόρτο.

2.2.2 Εξαγωγή HOG/HOF Περιγραφητών

Αφού έχουν προϋπολογιστεί τα πεδία G_x, G_y και η οπτική ροή (f_x, f_y) για όλα τα frames του βίντεο, η εξαγωγή των περιγραφητών γίνεται *ανά σημείο ενδιαφέροντος*. Για κάθε σημείο (x_0, y_0, t_0, σ) που επιστράφηκε από τον ανιχνευτή, ορίζεται ένα τετράγωνο χωρικό παράθυρο (*patch*) πλευράς 4σ pixels γύρω από τη θέση του, δηλαδή $[y_0 - 2\sigma, y_0 + 2\sigma] \times [x_0 - 2\sigma, x_0 + 2\sigma]$, πάνω στο frame t_0 . Η σύνδεση του μεγέθους του patch με την κλίμακα σ του ανιχνευτή εξασφαλίζει ότι ο περιγραφητής αποτυπώνει την τοπική δομή στην *ίδια κλίμακα* στην οποία εντοπίστηκε το σημείο. Το patch αποκόπτεται στα όρια της εικόνας για να αποφευχθεί

έξοδος εκτός ορίων, και εκφυλισμένα patches (διαστάσεων μικρότερων των 2 pixels) που μπορεί να προκύψουν για σημεία πολύ κοντά στο περιθώριο παραλείπονται από την υλοποίηση μας.

Πάνω σε κάθε τέτοιο patch εφαρμόζεται η έτοιμη συνάρτηση `orientation_histogram` των `utils`, η οποία είναι γενική και δέχεται οποιοδήποτε διανυσματικό πεδίο (u, v) πάνω στο patch και ανάλογα με το όρισμα που της τροφοδοτούμε, παράγεται είτε HOG είτε HOF. Εσωτερικά, η συνάρτηση υποδιαιρεί το patch σε πλέγμα 3×3 κελιών και σε κάθε κελί φτιάχνει ιστόγραμμα των 8 bins με βάση τη γωνία του (u, v) κάθε pixel, σταθμισμένο με το μέτρο του $\sqrt{u^2 + v^2}$, έτσι ώστε ισχυρά διανύσματα (έντονες ακμές ή γρήγορη κίνηση) να μετρούν περισσότερο από θορυβώδη. Τα εννέα 8-d ιστογράμματα συνενώνονται σε ένα $3 \times 3 \times 8 = 72$ -διάστατο υπο-διάνυσμα.

Η υλοποίηση μας καλεί τη συνάρτηση δύο φορές ανά σημείο, πάνω στο ίδιο patch. Για τον **HOG** τροφοδοτούνται οι χωρικές βαθμίδες (G_x, G_y) του frame t_0 , οπότε το ιστόγραμμα αποτυπώνει τις κατευθύνσεις των τοπικών ακμών, δηλαδή τη γεωμετρική δομή (περιγράμματα μελών, στάση σώματος). Για τον **HOF** τροφοδοτούνται οι συνιστώσες της οπτικής ροής (f_x, f_y) μεταξύ των frames t_0 και t_0+1 , οπότε τώρα το ιστόγραμμα αποτυπώνει τις κατευθύνσεις και τις εντάσεις της τοπικής κίνησης. Αν το σημείο ενδιαφέροντος εντοπιστεί στο τελευταίο frame όπου δεν υπάρχει επόμενο διαδοχικό frame, κάνουμε νοητό zero-padding με μηδενικό πεδίο.

Τα δύο 72-d υπο-διανύσματα συνενώνονται σε έναν ενιαίο περιγραφητή 144 διαστάσεων [HOG || HOF], με τις πρώτες 72 θέσεις να αντιστοιχούν στην εμφάνιση και τις υπόλοιπες 72 στην κίνηση. Η διάταξη αυτή επιλέχθηκε συνειδητά ώστε στην Εν. 2.3 να μπορούμε να αξιολογήσουμε ξεχωριστά κάθε υπο-περιγραφητή κρατώντας απλώς τις πρώτες ή τις τελευταίες 72 στήλες του πίνακα περιγραφητών.

2.3 Κατασκευή Bag of Visual Words και Ταξινόμηση με SVM

Έχοντας πλέον για κάθε βίντεο ένα σύνολο 144-διάστατων περιγραφητών, το επόμενο βήμα είναι η ταξινόμησή του σε μία από τις τρεις δράσεις. Το πλήθος των περιγραφητών διαφέρει από βίντεο σε βίντεο, οπότε πρέπει πρώτα να μετατραπούν σε αναπαράσταση σταθερής διάστασης.

Για τον σκοπό αυτό χρησιμοποιούμε την προσέγγιση **Bag of Visual Words (BoVW)**. Με K-means πάνω στους περιγραφητές εκπαίδευσης χτίζουμε ένα λεξιλόγιο K *visual words* (κεντροειδών), και στη συνέχεια κάθε βίντεο κωδικοποιείται σε ένα κανονικοποιημένο ιστόγραμμα που μετράει πόσες φορές εμφανίζεται η κάθε οπτική λέξη στους περιγραφητές του.

Με αυτό το ιστόγραμμα ως είσοδο, εκπαιδεύουμε έναν χ^2 -SVM ταξινομητή μέσω της έτοιμης συνάρτησης `svm_train_test` του `cv26_lab2_utils.py`.

2.3.1 Διαχωρισμός Συνόλου Δεδομένων

Ο διαχωρισμός των βίντεο σε σύνολα εκπαίδευσης και ελέγχου ορίζεται από το αρχείο `traininnng_videos.txt`. Διαβάζουμε τα ονόματα που περιέχει, συλλέγουμε όλα τα αρχεία με κατάληξη `.avi` από τους φακέλους των τριών δράσεων (*walking, running, handclapping*), και χωρίζουμε σε 36 βίντεο εκπαίδευσης και 12 βίντεο ελέγχου ανάλογα με το αν το όνομα κάθε αρχείου περιλαμβάνεται ή όχι στη λίστα. Από κάθε βίντεο φορτώνουμε τα πρώτα 100 καρέ σε grayscale, μέσω της συνάρτησης `read_video`.

2.3.2 Κατασκευή Λεξιλογίου *visual words*

Για τη μετατροπή κάθε βίντεο σε Bag of Visual Words, χρησιμοποιούμε τη συνάρτηση `bag_of_words` του `cv26_lab2_utils.py`. Η κλήση έχει τη μορφή `bow_tr, bow_ts = bag_of_words(tr, ts, num_centers=K)`, όπου τα `tr` και `ts` περιέχουν τους περιγραφητές των βίντεο εκπαίδευσης και ελέγχου αντίστοιχα, ενώ το K ορίζει το μέγεθος του λεξιλογίου. Για λόγους ταχύτητας, η δοσμένη συνάρτηση εκτελεί τον αλγόριθμο K-means σε ένα τυχαίο slice (50%) των δεδομένων εκπαίδευσης. Στη συνέχεια, αντιστοιχίζει κάθε περιγραφητή στο κοντινότερο centroid (δηλαδή τη λέξη) και επιστρέφει ℓ_2 -κανονικοποιημένα ιστογράμματα συχνοτήτων.

Στην υλοποίησή μας, τρέχουμε την `bag_of_words` μέσα σε έναν loop για να δοκιμάσουμε συστηματικά διάφορους συνδυασμούς ανιχνευτών, περιγραφητών και μεγεθών K . Χάρη στη διάταξη [HOG || HOF] που ορίσαμε στην προηγούμενη ενότητα, ο διαχωρισμός των περιγραφητών είναι άμεσος: αν θέλουμε μόνο HOG κρατάμε τις πρώτες 72 στήλες (`d[:, :72]`), ενώ για HOF τις τελευταίες 72 (`d[:, 72:]`). Τέλος, πειραματιζόμαστε με μεγέθη λεξιλογίου $K \in \{50, 100, 200\}$ για να εξετάσουμε πώς η χωρητικότητά του επηρεάζει την τελική ακρίβεια ταξινόμησης.

2.3.3 Ταξινόμηση με SVM

Αφού έχουμε για κάθε βίντεο ένα K -διάστατο ιστόγραμμα BoVW, το ταξινομούμε σε μία από τις τρεις δράσεις μέσω της έτοιμης συνάρτησης `svm_train_test(bow_tr, train_labels, bow_ts, test_labels)` του `cv26_lab2_utils.py`. Η συνάρτηση επιστρέφει την ακρίβεια στο test set και τις προβλέψεις ανά βίντεο.

Εσωτερικά η `svm_train_test` χρησιμοποιεί έναν SVM με default πυρήνα χ^2 , ο οποίος είναι καταλληλότερος για ιστογράμματα από τον απλό γραμμικό ή τον RBF. Ο πυρήνας έχει τη μορφή

$$K_{\chi^2}(\mathbf{x}, \mathbf{y}) = \exp\left(-\gamma \sum_i \frac{(x_i - y_i)^2}{x_i + y_i}\right), \quad (16)$$

όπου ο παρονομαστής $x_i + y_i$ δίνει μεγαλύτερη βαρύτητα σε angle bins με μικρές τιμές (δηλαδή σε ένα σπάνιο χαρακτηριστικό), αποτρέποντας τις λίγες κυρίαρχες οπτικές λέξεις να επιβληθούν στη μέτρηση ομοιότητας, κάτι που θα συνέβαινε με την απλή ευκλείδεια απόσταση. Πρακτικά ο πίνακας του πυρήνα υπολογίζεται εκ των προτέρων (*precomputed*)

και κανονικοποιείται διαιρούμενος με τη μέση τιμή του, ώστε η κλίμακα των αποστάσεων να μην εξαρτάται από το μέγεθος του λεξιλογίου.

Επειδή οι δράσεις είναι τρεις και το SVM είναι εκ φύσεως δυαδικός ταξινομητής, η `svm_train_test` εκπαιδεύει εσωτερικά τρία ανεξάρτητα SVMs με στρατηγική *One-vs-Rest*: το καθένα μαθαίνει να διακρίνει μία κλάση από τις υπόλοιπες δύο. Για κάθε test βίντεο επιλέγεται η κλάση με τη μεγαλύτερη πιθανότητα (μέσω Platt scaling), και η τελική ακρίβεια υπολογίζεται ως το ποσοστό σωστών προβλέψεων στα 12 test βίντεο.

2.3.4 Πειραματισμοί και Σχολιασμός

Τρέξαμε συνολικά 39 πειράματα ώστε να δούμε πώς επηρεάζουν την τελική ακρίβεια οι επιλογές ανιχνευτή (Harris3D έναντι Gabor), τύπου περιγραφητή (HOG, HOF ή HOG+HOF) και οι υπερπαράμετροι σ , τ , θ , N , K , καθώς και η ειδική παράμετρος k του Harris.

Για τις παραλλαγές HOG / HOF αξιοποιούμε τη διάταξη [HOG||HOF] του 144-d διανύσματος και κρατάμε τις πρώτες ή τις τελευταίες 72 στήλες αντίστοιχα, χωρίς να ξαναυπολογίζουμε περιγραφητές. Τα αποτελέσματα όλων των πειραμάτων συνοψίζονται στον Πίνακα 9.

Πίνακας 9. Αποτελέσματα πειραμάτων

Ανιχνευτής	Περιγρ.	σ	τ	θ	N	K	k	Ακρίβεια
<i>A. Βασικά πειράματα (detector & descriptor type)</i>								
harris	HOG+HOF	2	1.5	0.02	500	50	0.005	58.33%
gabor	HOG+HOF	2	1.5	0.08	500	50	-	83.33%
harris	HOG	2	1.5	0.02	500	50	0.005	58.33%
gabor	HOG	2	1.5	0.08	500	50	-	75.00%
harris	HOF	2	1.5	0.02	500	50	0.005	66.67%
gabor	HOF	2	1.5	0.08	500	50	-	75.00%
<i>B. Μέγεθος λεξιλογίου K</i>								
gabor	HOG+HOF	2	1.5	0.08	500	20	-	75.00%
gabor	HOG+HOF	2	1.5	0.08	500	100	-	83.33%
gabor	HOG+HOF	2	1.5	0.08	500	200	-	58.33%
gabor	HOG+HOF	2	1.5	0.08	500	500	-	75.00%
harris	HOG+HOF	2	1.5	0.02	500	100	0.005	75.00%
harris	HOG+HOF	2	1.5	0.02	500	200	0.005	75.00%
<i>C. Χωρική κλίμακα σ</i>								
gabor	HOG+HOF	1	1.5	0.08	500	50	-	91.67%
gabor	HOG+HOF	3	1.5	0.08	500	50	-	66.67%
gabor	HOG+HOF	4	1.5	0.08	500	50	-	66.67%
harris	HOG+HOF	1	1.5	0.02	500	50	0.005	58.33%
harris	HOG+HOF	3	1.5	0.02	500	50	0.005	83.33%

συνέχεια στην επόμενη σελίδα

Ανιχνευτής	Περιγρ.	σ	τ	θ	N	K	k	Ακρίβεια
harris	HOG+HOF	4	1.5	0.02	500	50	0.005	75.00%
<i>D. Χρονική κλίμακα τ</i>								
gabor	HOG+HOF	2	0.5	0.08	500	50	-	41.67%
gabor	HOG+HOF	2	1.0	0.08	500	50	-	50.00%
gabor	HOG+HOF	2	2.0	0.08	500	50	-	58.33%
harris	HOG+HOF	2	1.0	0.02	500	50	0.005	50.00%
harris	HOG+HOF	2	2.0	0.02	500	50	0.005	50.00%
<i>E. Κατώφλι θ</i>								
gabor	HOG+HOF	2	1.5	0.02	500	50	-	75.00%
gabor	HOG+HOF	2	1.5	0.05	500	50	-	75.00%
gabor	HOG+HOF	2	1.5	0.15	500	50	-	66.67%
gabor	HOG+HOF	2	1.5	0.30	500	50	-	83.33%
harris	HOG+HOF	2	1.5	0.005	500	50	0.005	66.67%
harris	HOG+HOF	2	1.5	0.01	500	50	0.005	66.67%
harris	HOG+HOF	2	1.5	0.05	500	50	0.005	66.67%
harris	HOG+HOF	2	1.5	0.10	500	50	0.005	66.67%
<i>F. Πλήθος σημείων N</i>								
gabor	HOG+HOF	2	1.5	0.08	100	50	-	66.67%
gabor	HOG+HOF	2	1.5	0.08	200	50	-	91.67%
gabor	HOG+HOF	2	1.5	0.08	1000	50	-	83.33%
gabor	HOG+HOF	2	1.5	0.08	2000	50	-	75.00%
<i>G. Παράμετρος k (μόνο Harris, $N=200$)</i>								
harris	HOG+HOF	2	1.5	0.02	200	50	0.001	83.33%
harris	HOG+HOF	2	1.5	0.02	200	50	0.005	66.67%
harris	HOG+HOF	2	1.5	0.02	200	50	0.01	75.00%
harris	HOG+HOF	2	1.5	0.02	200	50	0.02	83.33%

Στο **baseline πείραμα**, ο ανιχνευτής Gabor υπερτερεί ξεκάθαρα του Harris, πετυχαίνοντας 83.33% έναντι 58.33%. Για τον Gabor, ο συνδυασμένος περιγραφητής HOG+HOF (83.33%) αποδίδει καλύτερα από τα επιμέρους HOG ή HOF (75%). Ενδιαφέρον εύρημα αποτελεί η συμπεριφορά του Harris: ο περιγραφητής HOF μόνος του (66.67%) υπερτερεί του συνδυασμένου HOG+HOF (58.33%), πιθανώς επειδή η καθαρή χρονική πληροφορία της οπτικής ροής βοηθάει τον Harris να αντισταθμίσει την υπερβολική χωρική του ευαισθησία.

Όσον αφορά το **μέγεθος του λεξιλογίου K** : ο Gabor μεγιστοποιεί την απόδοσή του στα $K=50$ και $K=100$ (φτάνοντας 83.33%). Το πολύ μικρό λεξιλόγιο ($K=20$) συγχωνεύει διαφορετικά κινητικά μοτίβα ρίχνοντας την ακρίβεια, ενώ το υπερβολικά μεγάλο ($K=200$) υπερ-εξειδικεύεται, προκαλώντας πτώση στο 58.33%.

Η **χωρική κλίμακα σ** αποδείχθηκε καθοριστική. Μειώνοντας την κλίμακα του Gabor στο $\sigma=1$, η ακρίβεια εκτοξεύεται στο 91.67%, που αποτελεί και το global maximum των πειραμάτων μας. Αντίθετα, η αύξηση της κλίμακας στα $\sigma=3, 4$ «θολώνει» την πληροφορία

ρίχνοντας την ακρίβεια στο 66.67%. Ο Harris δείχνει την καλύτερή του συμπεριφορά στο $\sigma=3$ (83.33%).

Η **χρονική κλίμακα** τ επιβεβαιώνεται πειραματικά ως η πιο ευαίσθητη παράμετρος. Η τιμή $\tau=1.5$ είναι η βέλτιστη, καθώς οποιαδήποτε απόκλιση (είτε στενότερο παράθυρο 0.5, 1.0 είτε ευρύτερο 2.0) κατακρημνίζει την απόδοση και των δύο ανιχνευτών στα επίπεδα του 33% – 58%. Το στενό παράθυρο δεν προλαβαίνει να «δει» την περιοδικότητα της δράσης, ενώ το πολύ ευρύ αναμειγνύει πολλές φάσεις του κύκλου κίνησης καταστρέφοντας τη χρονική δομή.

Το **κατώφλι** θ παρουσιάζει σταθερότητα στον Gabor (με τις τιμές 0.08 και 0.30 να ξεχωρίζουν). Για τον Harris, μια μικρή αλλαγή από το baseline 0.02 προς οποιαδήποτε κατεύθυνση ανεβάζει ελαφρώς την ακρίβεια στο 66.67%.

Όσον αφορά το **πλήθος σημείων** N , ο Gabor δείχνει να προτιμά εστιασμένη πληροφορία. Μειώνοντας τα σημεία στα $N=200$, η ακρίβεια φτάνει ξανά στο 91.67%. Η αύξηση στα 2000 σημεία εισάγει υπερβολικό θόρυβο από το φόντο, ρίχνοντας την απόδοση στο 75%.

Τέλος, διερευνήθηκε η επιρροή της **παραμέτρου** k του Harris, η οποία ελέγχει πόσο αυστηρά απορρίπτονται οι ακμές έναντι των γωνιών. Τα αποτελέσματα δείχνουν ότι οι τιμές $k=0.001$ και $k=0.02$ δίνουν την υψηλότερη ακρίβεια (83.33%), ενώ η lab-recommended τιμή $k=0.005$ αποδίδει χειρότερα (66.67%). Η παράμετρος δεν παρουσιάζει μονότονη επίδραση, υποδηλώνοντας ότι η βέλτιστη επιλεκτικότητα μεταξύ ακμών και γωνιών εξαρτάται από τη συγκεκριμένη δομή του dataset.

Συμπερασματικά, ο καλύτερος συνδυασμός του πειράματός μας είναι ο Gabor ανιχνευτής με HOG+HOF περιγραφητές ($\tau=1.5$, $K=50$), είτε με μικρή χωρική κλίμακα ($\sigma=1$, $N=500$) είτε με πιο αυστηρή επιλογή σημείων ($\sigma=2$, $N=200$).

3. Ταξινόμηση Βίντεο με Χρήση Προεκπαιδευμένων Βαθιών Νευρωνικών Δικτύων

3.1 2D Χαρακτηριστικά με MobileNet

3.1.1 Φόρτωση Βίντεο UCF11

Στο τρίτο μέρος της εργασίας, θα ασχοληθούμε με το πρόβλημα της ταξινόμησης βίντεο ανθρώπων δράσεων χρησιμοποιώντας προεκπαιδευμένα βαθιά νευρωνικά δίκτυα ως εξαγωγείς χαρακτηριστικών. Το σύνολο δεδομένων που χρησιμοποιούμε είναι το *UCF11* το οποίο περιέχει βίντεο χωρισμένα σε 6 κατηγορίες δράσεων:

- Basketball
- Biking
- Diving

- **Swing**
- **VolleyballSpiking**
- **Walking**

Η διαίρεση του συνόλου σε εκπαίδευση και τεστ γίνεται με βάση το αρχείο `training_videos.txt`, το οποίο καθορίζει ποια βίντεο θα χρησιμοποιηθούν για εκπαίδευση και ποια για δοκιμή. Έτσι, υλοποιήσαμε τη συνάρτηση `create_train_test_ucf11()` η οποία διαβάζει αυτό το αρχείο και δημιουργεί τις αντίστοιχες λίστες διαδρομών και ετικετών.

3.1.2 Εξαγωγή Χαρακτηριστικών με *MobileNet_v3_small*

Το *MobileNet_v3_small* είναι ένα ελαφρύ αλλά ικανό δίκτυο που σχεδιάστηκε για εξαγωγή χαρακτηριστικών σε 2D εικόνες. Χρησιμοποιούμε το προεκπαιδευμένο μοντέλο από το ImageNet. Η διαδικασία εξαγωγής χαρακτηριστικών αποτελείται από τα εξής βήματα:

1. **Ανάγνωση βίντεο:** Διαβάζουμε το βίντεο με τη βοηθητική συνάρτηση `read_video` από το συμπληρωματικό υλικό
2. **Μετατροπή σε RGB:** Κάθε γκριζα εικόνα μετατρέπεται σε RGB με αναπαραγωγή του καναλιού τρεις φορές
3. **Κανονικοποίηση:** Εφαρμόζουμε την προεπεξεργασία ImageNet (μέσος όρος και κανονική απόκλιση)
4. **Εξαγωγή χαρακτηριστικών:** Περνάμε το κάθε καρέ από το προεκπαιδευμένο *MobileNet_v3_small* και εξάγουμε τα χαρακτηριστικά από το τελευταίο στρώμα χωρίς τη ταξινόμηση
5. **Χρονική συγκέντρωση:** Υπολογίζουμε το μέσο όρο των χαρακτηριστικών όλων των καρέ για να λάβουμε ένα μόνο διάνυσμα χαρακτηριστικών ανά βίντεο- (**average pooling**)

Αυτή η προσέγγιση χρησιμοποιεί κάθε καρέ ανεξάρτητα και δεν λαμβάνει άμεσα υπόψη τη χρονική συσχέτιση διαδοχικών καρέ παρά μόνο στο τέλος όπου λαμβάνει το μέσο όρο όλων των χαρακτηριστικών, αλλά τα 2D χαρακτηριστικά παρέχουν ισχυρή βάση για την ταξινόμηση.

3.1.3 Ταξινόμηση με SVM

Μετά την εξαγωγή των χαρακτηριστικών, χρησιμοποιούμε έναν Γραμμικό SVM για την ταξινόμηση των βίντεο. Το SVM είναι ιδιαίτερα κατάλληλο για υψηλού μήκους χαρακτηριστικά διανύσματα που προέρχονται από προεκπαιδευμένα δίκτυα. Εκπαιδεύουμε το SVM στο σύνολο εκπαίδευσης και αξιολογούμε την απόδοσή του στο σύνολο δοκιμής.

Στο επόμενο στάδιο θα χρησιμοποιήσουμε ένα 3D CNN για να εξάγουμε χωροχρονικά χαρακτηριστικά του βίντεο και μετά θα συγκρίνουμε τα αποτελέσματα του MobileNet με εκείνα του x3d_xs για να κατανοήσουμε τη σημασία της χρονικής εξάρτησης στην ταξινόμηση ενεργειών βίντεο.

3.2 3D Χαρακτηριστικά με x3d_xs

Οπότε για να αξιολογήσουμε και τη χρονική εξάρτηση στην ταξινόμηση, χρησιμοποιούμε ένα τρισδιάστατο CNN(3D Convolutional Neural Network). Το x3d_xs είναι ένα ελαφρύ αλλά αποτελεσματικό μοντέλο 3D CNN που προεκπαιδεύτηκε στο σύνολο δεδομένων Kinetics, το οποίο περιέχει εκατομμύρια βίντεα ανθρώπινων δράσεων.

3.2.1 Φόρτωση Μοντέλου x3d_xs

Φορτώνουμε το προεκπαιδευμένο μοντέλο x3d_xs από το PyTorchVideo χρησιμοποιώντας το `torch.hub.load()`. Το μοντέλο αυτό απαιτεί ειδικότερη προεπεξεργασία εισόδου:

- **Διαστάσεις εισόδου:** $(1, C, T, H, W) = (1, 3, 4, 182, 182)$ όπου $C = 3$ για RGB, $T = 4$ για χρονικό πλάτος(4 καρέ), $H = W = 182$ για χωρικό πλάτος
- **Κανονικοποίηση:** Κάνουμε Z-score normalization με στατιστικά του ImageNet-video: μέσος όρος $[0.45, 0.45, 0.45]$ και κανονική απόκλιση $[0.225, 0.225, 0.225]$
- **Εύρος τιμών:** Οι τιμές των pixel κανονικοποιούνται από $[0, 255]$ σε $[0, 1]$ πριν την εφαρμογή της κανονικοποίησης ImageNet

3.2.2 Εξαγωγή Χαρακτηριστικών και Προετοιμασία Δεδομένων

Γενικά, προτείνεται να χρησιμοποιήσουμε τη συνάρτηση `torch.nn.functional.interpolate` ώστε να δειγματοληψήσουμε τυχαία τα 4 καρέ τα οποία περιμένει στην χρονική είσοδο ο εξαγωγέας. Ωστόσο εμείς αποφασίσαμε να πάρουμε διαδοχικές τετράδες από καρέ του βίντεο χωρίς επικάλυψη, να τις περάσουμε όλες από το δίκτυο και να πάρουμε τον μέσο όρο των χαρακτηριστικών τους στο τέλος. Αυτό προφανώς είναι προτιμότερο καθώς χρησιμοποιούμε όλη τη χρονική πληροφορία που μας δίνεται και δεν δειγματοληπτούμε τυχαία από όλα τα καρέ, ωστόσο έχει μεγάλο υπολογιστικό κόστος. Παρόλαυτα, επιλέξαμε αυτή τη προσέγγιση ώστε να δούμε αν θα βγάλουμε καλύτερα αποτελέσματα όπως θα αναφερθεί και στη συνέχεια στον σχολιασμό των αποτελεσμάτων. Οπότε για να χτίσουμε τους χωροχρονικούς όγκους που απαιτούσε το μοντέλο και να εξάγουμε τα τελικά χαρακτηριστικά και τη τελική ταξινόμηση, εφαρμόσαμε τα εξής βήματα:

1. **Ανάγνωση βίντεο:** Φορτώνουμε όλα τα καρέ του βίντεο
2. **Αλλαγή μεγέθους:** Αλλάζουμε το μέγεθος κάθε καρέ σε 182×182 χρησιμοποιώντας double linear interpolation όπως περιμένει το δίκτυο

3. **Δημιουργία clips:** Διαιρούμε το βίντεο σε μη-επικαλυπτόμενα clips των 4 καρέ με βήμα(stride) 4
4. **Padding:** Το τελευταίο clip που περιέχει λιγότερα από 4 καρέ συμπληρώνεται με επανάληψη του τελευταίου καρέ
5. **Κανονικοποίηση:** Κανονικοποιούμε τις τιμές pixel από $[0, 255]$ σε $[0, 1]$ και στη συνέχεια εφαρμόζουμε την κανονικοποίηση ImageNet-video
6. **Hook για εξαγωγή χαρακτηριστικών:** Καταχωρούμε ένα hook στο `blocks[5].output_pool` του μοντέλου για να εξάγουμε τα χαρακτηριστικά πριν τα στάδια ταξινόμησης
7. **Χρονική συγκέντρωση:** Υπολογίζουμε το μέσο όρο των χαρακτηριστικών όλων των clips για να λάβουμε ένα μόνο διάνυσμα χαρακτηριστικών ανά βίντεο
8. **Ταξινόμηση:** Εκπαιδεύουμε έναν Γραμμικό SVM με τα εξαγόμενα χαρακτηριστικά για την ταξινόμηση των βίντεο

Αυτή η προσέγγιση ενσωματώνει τη χρονική πληροφορία κατά τη διάρκεια της εξαγωγής χαρακτηριστικών, επιτρέποντας στο δίκτυο να μάθει χρονικά μοτίβα του βίντεο. Μάλιστα, η χρήση όλων των clips αντί για τυχαία δειγματοληψία πιθανώς εξηγεί την καλύτερη απόδοση του `x3d_xs` σε σχέση με το MobileNet, καθώς εκμεταλλεύεται πλήρως τη χρονική δυναμική των βίντεο.


3.2.3 Ταξινόμηση και Confusion Matrix

Στο πλαίσιο των πειραματισμών μας και της εύρεσης βελτιστοποιήσεων του πειράματος εφαρμόσαμε την τεχνική LoRA (Low-Rank Adaptation) για να προσαρμόσουμε τα βάρη του προεκπαιδευμένου δικτύου στις συγκεκριμένες κατηγορίες του UCF11, χωρίς αν χρειαστεί να εκπαιδευτούν όλα τα βάρη. Ειδικότερα, Το LoRA είναι μια μέθοδος που επιτρέπει την προσαρμογή μεγάλων μοντέλων με πολύ λίγα παραμετρικά βάρη, διατηρώντας την αρχική γνώση του μοντέλου ενώ μαθαίνει τις ιδιαιτερότητες του νέου dataset. Επίσης, δοκιμάσαμε και έναν MLP(Multi-Layer Perceptron) ως μη-γραμμικό ταξινομητή για να δούμε αν μπορούμε να εκμεταλλευτούμε καλύτερα τα χαρακτηριστικά που εξάγονται από τα δίκτυα με έναν μη γραμμικό ταξινομητή έναντι του γραμμικού SVM. Τα συγκεντρωτικά αποτελέσματα των πειραμάτων μας παρουσιάζονται στον Πίνακα 10, όπου συγκρίνουμε την ακρίβεια ταξινόμησης για τις 2D (MobileNet) και 3D (`x3d_xs`) προσεγγίσεις, τόσο με τον SVM όσο και με τον MLP, και με ή χωρίς την εφαρμογή της τεχνικής LoRA.

Πίνακας 10. Σύγκριση ακρίβειας ταξινόμησης για 2D (MobileNet) και 3D (x3d_xs) χαρακτηριστικά


Μέθοδος	SVM Ακρίβεια	MLP Ακρίβεια
Frozen MobileNet	98.80%	97.60%
LoRA MobileNet	98.80%	97.60%
Frozen x3d_xs	99.40%	98.80%
LoRA x3d_xs	99.40%	99.40%

Γενικά , παρατηρούμε ότι και οι δύο προσεγγίσεις προσαρμόζονται πάραπολύ καλά στα δεδομένα μας και πετυχαίνουν πολύ υψηλή ακρίβεια ταξινόμησης, με το x3d_xs να υπερέχει ελαφρώς του MobileNet. Τα αποτελέσματα δείχνουν ότι το x3d_xs υπερέχει του MobileNet κατά περίπου 0.6% λόγω της ικανότητας του να μοντελοποιεί ρητά τη χρονική δυναμική. Η προσαρμογή LoRA βελτιώνει την απόδοση κατά ένα μικρό ποσοστό, ιδιαίτερα για μη γραμμικές ταξινομήσεις με MLP. Βέβαια να σημειωθεί ότι αν δεν εφαρμόζαμε για το x3d_xs την προσέγγιση με τα clips και την χρονική συγκέντρωση, είδαμε ότι θα είχαμε χειρότερα αποτελέσματα. Μάλιστα για το *Frozenx3d_xs* με την απλή τεχνική υποδειγματοληψίας των 4 καρέ που απαιτεί το μοντέλο, είχαμε ακρίβεια 97% αντί για 99.4% που πετύχαμε με την προσέγγιση με τα clips και την χρονική συγκέντρωση. Αυτό ήταν αναμενόμενο καθώς η τυχαία υποδειγματοληψία πιθανώς δεν έπιανε τα κρίσιμα χρονικά μοτίβα που απαιτούνται για την σωστή ταξινόμηση των ενεργειών, ενώ η προσέγγιση με τα clips και την συγκέντρωση εκμεταλλεύτηκε πλήρως τη χρονική πληροφορία που παρέχει το x3d_xs. Ακολουθούν οι πίνακες σύγκρισης των μεθόδων , όπως έτσι και αλλιώς φάνηκε από την ακρίβεια ταξινόμησης και οι δύο προσεγγίσεις είανισχεδόν τέλειες.




Σχήμα 35. Πίνακας σύγχυσης: Frozen MobileNet + SVM (98.8%)

Frozen MobileNet + SVM (98.8% Ακρίβεια)




Σχήμα 36. Πίνακας σύγχυσης: Frozen x3d_xs + SVM (99.4%)

Frozen x3d_xs + SVM (99.4% Ακρίβεια)




Σχήμα 37. Πίνακας σύγχυσης: LoRA MobileNet + SVM (98.8%)

LoRA MobileNet + SVM (98.8% Ακρίβεια)




Σχήμα 38. Πίνακας σύγχυσης: LoRA x3d_xs + SVM (99.4%)

LoRA x3d_xs + SVM (99.4% Ακρίβεια)




Σχήμα 39. Πίνακας σύγχυσης: Frozen MobileNet + MLP (97.6%)

MLP Ταξινόμηση




Σχήμα 40. Πίνακας σύγχυσης: Frozen x3d_xs + MLP (98.8%)

Frozen x3d_xs + MLP (98.8% Ακρίβεια)



Σχήμα 41. Πίνακας σύγχυσης: LoRA MobileNet + MLP (97.6%)

LoRA MobileNet + MLP (97.6% Ακρίβεια)



Σχήμα 42. Πίνακας σύγχυσης: LoRA x3d_xs + MLP (99.4%)

LoRA x3d_xs + MLP (99.4% Ακρίβεια)*3.2.4 Σύγκριση 2D και 3D Προσεγγίσεων*

Η σύγκριση μεταξύ των 2D (MobileNet) και 3D (x3d_xs) προσεγγίσεων είναι γενικά ένα μεγάλο ζήτημα ώστε να αποφανθούμε πιο μοντέλο αντιλαμβάνεται καλύτερα τις χρονικές δυναμικές και επιτυγχάνει υψηλή ακρίβεια ταξινόμησης. Στο πείραμα μας το x3d_xs υπερέρχει του MobileNet κατά περίπου 0.6% (99.4% vs 98.8%) στην απόδοση SVM, με αυτή την βελτίωση να προέρχεται από τη μεγαλύτερη ικανότητα του να μοντελοποιεί ρητά τη χρονική δυναμική μέσω συνελίξεων κατά μήκος του χρονικού άξονα, σε αντίθεση με το MobileNet που βασίζεται στη συγκέντρωση μετά την εξαγωγή χαρακτηριστικών. Επιπλέον, το x3d_xs προεκπαιδεύτηκε στο σύνολο δεδομένων Kinetics, το οποίο επικεντρώνεται ειδικά στις ανθρώπινες ενέργειες και τις χρονικές δυναμικές, ενώ το MobileNet προεκπαιδεύτηκε στο ImageNet που περιέχει κυρίως στατικές εικόνες, οπότε λογικό να είναι πιο αποτελεσματικό. Τέλος, υπάρχει προφανώς το trade-off μεταξύ του υπολογιστικού κόστους και της αποτελεσματικότητας, ειδικά ενώ το MobileNet είναι ελαφρύτερο και ταχύτερο για εξαγωγή χαρακτηριστικών, το x3d_xs απαιτεί περισσότερο χρόνο υπολογισμού και παρέχει αμυδρά καλύτερα αποτελέσματα, οπότε είναι λογικό να προτιμήσουμε το MobileNet σε πραγματικές εφαρμογές. Ωστόσο, γενικά σε πιο δύσκολα σύνολα δεδομένων αναμένουμε ότι οι διαφορές μεταξύ 2D και 3D προσεγγίσεων θα είναι πιο έντονες, καθώς η χρονική δυναμική θα παίζει μεγαλύτερο ρόλο στην ταξινόμηση των ενεργειών, με αποτέλεσμα γενικά για ταξινόμηση βίντεο να προτιμήσουμε τη τρισδιάστατη οπτική.

Από την άλλη πλευρά, αυτό το μέρος της εργασίας επιδεικνύει ότι τα προεκπαιδευμένα δίκτυα είναι εξαιρετικοί εξαγωγείς χαρακτηριστικών για τα προβλήματα ταξινόμησης βίντεο. Ακόμη και χωρίς καν το LORA δηλαδή κάποια εξειδικευμένη εκπαίδευση στο UCF11, τα μοντέλα αυτά επιτυγχάνουν σχεδόν τέλεια ακρίβεια (>98%), γεγονός που υποδεικνύει ότι τα χαρακτηριστικά που μαθαίνονται κατά τη διάρκεια της προεκπαίδευσης σε μεγάλα σύνολα δεδομένων μεταφέρονται εξαιρετικά καλά σε νέες εργασίες.

Αναφορές

- [1] I. Laptev, M. Marszalek, C. Schmid, and B. Rozenfeld, "Learning realistic human actions from movies", in *Proc. IEEE CVPR*, pp. 1-8, 2008.
- [2] I. Laptev and T. Lindeberg, "Space-time interest points", in *Proc. IEEE ICCV*, vol. 1, pp. 432-439, 2003.