



Εθνικό Μετσόβιο Πολυτεχνείο

Σχολή Ηλεκτρολόγων Μηχανικών &
Μηχανικών Υπολογιστών

Εξάμηνο 8^ο
Όραση Υπολογιστών

1η Εργαστηριακή Άσκηση

Εντοπισμός Σημείων Ενδιαφέροντος
και Εξαγωγή Χαρακτηριστικών σε
Εικόνες

Μέλη Ομάδας

Καβαδάκης Σωτήρης 03122035

Δαλαμπέκης Ιγνάτιος 03122017

Αθήνα, Μάρτιος 2026

Περιεχόμενα

1	Ανίχνευση Ακμών σε Γκρίζες Εικόνες	3
1.1	Δημιουργία Εικόνων Εισόδου	3
1.1.1	Φόρτωση Αρχικής Εικόνας	3
1.1.2	Προσθήκη Θορύβου	3
1.2	Υλοποίηση Αλγορίθμων Ανίχνευσης Ακμών	4
1.2.1	Πυρήνες Gaussian και LoG	4
1.2.2	Προσέγγιση Laplacian	5
1.2.3	Εύρεση Zero-crossings	8
1.2.4	Απόρριψη σε Ομαλές Περιοχές	10
1.3	Αξιολόγηση Αποτελεσμάτων	11
1.3.1	Υπολογισμός Αληθινών Ακμών	11
1.3.2	Ποσοτική Αξιολόγηση	11
1.3.3	Πειραματισμός Παραμέτρων	11
1.4	Εφαρμογή σε Πραγματικές Εικόνες	14
1.4.1	Εφαρμογή στην ermpoupoli.jpg	14
1.4.2	Αξιολόγηση Αποτελεσμάτων	14
2	Εντοπισμός Σημείων Ενδιαφέροντος	17
2.1	Ανίχνευση Γωνιών σε Μία Κλίμακα	17
2.1.1	Υπολογισμός του Δομικού Τανυστή	17
2.1.2	Ιδιοτιμές του Τανυστή	19
2.1.3	Κριτήριο Harris και Επιλογή Σημείων	20
2.2	Πολυκλιμακωτή Ανίχνευση Γωνιών	22
2.2.1	Κατασκευή της Αναπαράστασης Πολλαπλών Κλιμάκων	22
2.2.2	Harris-Laplacian Επιλογή Χαρακτηριστικής Κλίμακας	24
2.3	Ανίχνευση Blobs σε Μία Κλίμακα	29
2.3.1	Ορίζουσα του Hessian	29
2.3.2	Επιλογή Σημείων Blob	30
2.4	Πολυκλιμακωτή Ανίχνευση Blobs	31
2.4.1	Hessian-Laplace	31

2.5	Έλεγχος Repeatability υπό Γεωμετρικούς Μετασχηματισμούς	36
2.5.1	Μεθοδολογία Πειράματος	37
2.5.2	Αποτελέσματα και Ερμηνεία	37
3	Κατηγοριοποίηση Εικόνων με Χρήση Τοπικών Περιγραφητών και Χαρακτηριστικών από Βαθύ Νευρωνικό Δίκτυο	40
3.1	Κατηγοριοποίηση με τοπικούς περιγραφητές SURF και HOG	40
3.1.1	Ανιχνευτές Σημείων και Τοπικοί Περιγραφητές	41
3.1.2	Δημιουργία Train/Test sets - Bag-of-Words και Εκπαίδευση Ταξι- νομητή	41
3.1.3	Μεθοδολογία Πειράματος	42
3.1.4	Αποτελέσματα Πειράματος	43
3.1.5	Σύνοψη και Ερμηνεία Αποτελεσμάτων	46
3.2	Κατηγοριοποίηση με Χαρακτηριστικά από Συνελικτικό Νευρωνικό Δίκτυο	47
3.2.1	Φόρτωση Μοντέλου και Προεπεξεργασία Εικόνων	47
3.2.2	Εξαγωγή Χαρακτηριστικών	48
3.2.3	Δημιουργία Συνόλων Δεδομένων, Εκπαίδευση Ταξινομητή και Αξιο- λόγηση	48
3.2.4	Οπτικοποίηση Ενεργοποιήσεων Ενδιάμεσων Επιπέδων (Feature Maps)	49
3.2.5	Πειράματα Ανθεκτικότητας	53
3.2.6	Bonus: Σύγκριση Μεθόδων (LoRA & MLP)	53
3.2.7	Οπτικοποίηση Χώρου Χαρακτηριστικών (PCA)	54
3.2.8	Grad-CAM: Σύγκριση Παγωμένου και LoRA Backbone	55

1. Ανίχνευση Ακμών σε Γκρίζες Εικόνες

1.1 Δημιουργία Εικόνων Εισόδου

1.1.1 Φόρτωση Αρχικής Εικόνας

Φορτώθηκε η αρχική γκρίζα εικόνα $I_0 = \text{edgetest_26.png}$ με χρήση της συνάρτησης `cv2.imread` με τη σημαία `IMREAD_GRAYSCALE`, ώστε να διαβαστεί απευθείας ως εικόνα grayscale. Στη συνέχεια μετατράπηκε σε τύπο `float64` για ακρίβεια στους υπολογισμούς που ακολουθούν και αποφυγή overflow.

1.1.2 Προσθήκη Θορύβου

Για την αξιολόγηση της ανθεκτικότητας των αλγορίθμων ανίχνευσης ακμών, δημιουργήθηκαν δύο θορυβώδεις εκδόσεις της I_0 με την πρόσθεση λευκού Gaussian θορύβου:

$$I(x, y) = I_0(x, y) + n(x, y), \quad n(x, y) \sim \mathcal{N}(0, \sigma_n^2) \quad (1)$$

Το PSNR (Peak Signal-to-Noise Ratio) ορίζεται ως:


$$\text{PSNR} = 20 \log_{10} \left(\frac{I_{\max} - I_{\min}}{\sigma_n} \right) \quad [\text{dB}] \quad (2)$$

όπου $I_{\max}$ και $I_{\min}$ είναι η μέγιστη και ελάχιστη τιμή της I_0 . Αντιστρέφοντας τη σχέση αυτή προκύπτει:

$$\sigma_n = \frac{I_{\max} - I_{\min}}{10^{\text{PSNR}/20}} \quad (3)$$

Χρησιμοποιήθηκαν δύο τιμές: $\text{PSNR} = 20 \text{ dB}$ και $\text{PSNR} = 10 \text{ dB}$, παράγοντας τις εικόνες I_{20} και I_{10} αντίστοιχα.

Καθώς το PSNR μετρά λογαριθμικά τον λόγο σήματος-προς-θόρυβο, μείωση κατά 10 dB αντιστοιχεί σε τριπλασιασμό ($\times 10^{10/20} \approx 3.16$) της τυπικής απόκλισης σ_n . Έτσι η I_{10} έχει σημαντικά πιο έντονο θόρυβο από την I_{20} , κάτι που είναι εμφανές στο Σχήμα 1: στην I_{10} τα ομοιόμορφα τμήματα της εικόνας εμφανίζουν έντονη κοκκώδη υφή, ενώ στην I_{20} ο θόρυβος είναι ήπιος. Ο λευκός Gaussian θόρυβος, λόγω της μέγιστης εντροπίας και της ομοιόμορφης κατανομής ενέργειας σε όλο το φάσμα, θεωρείται το “χειρότερο” σενάριο για αλγορίθμους ανίχνευσης ακμών, προσφέροντας το πιο αυστηρό κριτήριο αξιολόγησης της ανθεκτικότητάς τους.



Σχήμα 1. Αρχική εικόνα I_0 (αριστερά), θορυβώδης εικόνα I_{20} με PSNR = 20 dB (κέντρο) και I_{10} με PSNR = 10 dB (δεξιά).

1.2 Υλοποίηση Αλγορίθμων Ανίχνευσης Ακμών

Μαθηματικά, μια ακμή αντιστοιχεί σε απότομη μεταβολή έντασης, δηλαδή σε υψηλή τιμή κλίσης $\|\nabla I\|$. Η άμεση παραγωγή όμως ενισχύει τον θόρυβο, αφού ο θόρυβος περιέχει κυρίως υψηλές συχνότητες τις οποίες η παράγωγος τονίζει. Απαιτείται λοιπόν πρώτα εξομάλυνση με low-pass φίλτρο. Το φίλτρο Gaussian G_σ είναι η βέλτιστη επιλογή: είναι το μόνο φίλτρο που επιτυγχάνει ισότητα στην αρχή αβεβαιότητας ($\Delta t \cdot \Delta \omega \geq \frac{1}{2}$), δηλαδή τη βέλτιστη ισορροπία μεταξύ χωρικής και φασματικής ανάλυσης, ενώ παράλληλα παρουσιάζει κυκλική συμμετρία, μη ευνοώντας καμία κατεύθυνση ακμής.

Η μέθοδος που υλοποιείται βασίζεται στον αλγόριθμο Marr-Hildreth [1], ο οποίος προτάθηκε το 1980 ως βιολογικά εμπνευσμένο μοντέλο ανίχνευσης ακμών. Η κεντρική ιδέα είναι ότι η ανθρώπινη όραση επεξεργάζεται εικόνες σε πολλαπλές χωρικές κλίμακες μέσω κυψελιδωτών πεδίων που προσεγγίζονται από το LoG, και εντοπίζει ακμές στα zero-crossings της εξόδου. Ο αλγόριθμος αποτελείται από τα βήματα που περιγράφονται στις ακόλουθες υποενότητες.

1.2.1 Πυρήνες Gaussian και LoG

Η ανίχνευση ακμών μέσω zero-crossings της Laplacian απαιτεί δύο φίλτρα: έναν πυρήνα Gaussian G_σ για εξομάλυνση της εικόνας, και έναν πυρήνα Laplacian-of-Gaussian (LoG) $h = \nabla^2 G_\sigma$ για την εκτίμηση της δεύτερης παραγώγου.


Ο πυρήνας G_σ κατασκευάστηκε εκμεταλλευόμενος την ιδιότητα διαχωρισιμότητας της 2D Gaussian: επειδή $G_\sigma(x, y) = G_\sigma(x) \cdot G_\sigma(y)$, ο 2D πυρήνας προκύπτει ως εξωτερικό γινόμενο δύο 1D πυρήνων που επιστρέφει η `cv2.getGaussianKernel`. Αυτό είναι υπολογιστικά αποδοτικότερο από την άμεση κατασκευή του 2D πυρήνα.

Ο πυρήνας LoG υπολογίστηκε απευθείας από τον αναλυτικό τύπο που προκύπτει εφαρμόζοντας τον τελεστή Laplace στη 2D Gaussian:


$$h(x, y) = \nabla^2 G_\sigma(x, y) = \frac{r^2 - 2\sigma^2}{2\pi\sigma^6} \exp\left(-\frac{r^2}{2\sigma^2}\right), \quad r^2 = x^2 + y^2 \quad (4)$$

Και στις δύο περιπτώσεις, το μέγεθος του πυρήνα ορίστηκε ως $n = 2\lceil 3\sigma \rceil + 1$, ώστε να καλύπτεται εύρος $\pm 3\sigma$ γύρω από το κέντρο — περιοχή που εμπεριέχει 99.7% της ενέργειας της Gaussian. Χρήση μικρότερου πυρήνα θα έχανε πολύτιμη πληροφορία, ενώ μεγαλύτερος πυρήνας θα αύξανε αχρείαστα τον υπολογιστικό κόστος.

Επιπλέον, ο πυρήνας LoG κεντράρεται ως προς το μηδέν με την αφαίρεση της μέσης τιμής του (`kernel -= kernel.mean()`). Αυτό είναι θεωρητικά αναγκαίο: ο ιδανικός πυρήνας LoG ικανοποιεί $\iint h(x,y) dx dy = 0$, οπότε η απόκρισή του σε σταθερές περιοχές είναι μηδέν. Στη διακριτή προσέγγιση με περικυκλωμένο πυρήνα αυτή η ιδιότητα δεν ικανοποιείται ακριβώς, και η διόρθωση αποτρέπει την εισαγωγή DC offset στην εκτίμηση της Laplacian.



Σχήμα 2. Έξοδος LoG (L_1) για PSNR= 20 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Θετικές τιμές φωτεινότερες, αρνητικές σκουρότερες από το γκρι (128).



Σχήμα 3. Έξοδος LoG (L_1) για PSNR= 10 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Με περισσότερο θόρυβο η απόκριση είναι πιο θορυβώδης για μικρό σ .

1.2.2 Προσέγγιση Laplacian


Για την εκτίμηση της Laplacian της εξομαλυμένης εικόνας υλοποιήθηκαν δύο εναλλακτικές προσεγγίσεις: μία γραμμική βασισμένη στη συνέλιξη με τον πυρήνα LoG, και μία

μη-γραμμική βασισμένη σε μορφολογικούς τελεστές.

Γραμμική (L_1 - LoG). Η μέθοδος εκμεταλλεύεται την ιδιότητα ότι ο τελεστής Laplace επιτρέπει εναλλαγή με τη συνέλιξη, επιτρέποντας την ενοποίηση της εξομάλυνσης και της παραγωγής σε ένα βήμα:

$$L_1 = \nabla^2(G_\sigma * I) = (\nabla^2 G_\sigma) * I = h * I \quad (5)$$

Αρκεί δηλαδή μία μόνο συνέλιξη της εικόνας I με τον πυρήνα LoG h , αντί για ξεχωριστή εξομάλυνση και εφαρμογή Laplacian. Η γεωμετρία του πυρήνα είναι *ισοτροπική* αφού εξαρτάται μόνο από $r^2 = x^2 + y^2$.



Σχήμα 4. Ροή υπολογισμού της γραμμικής Laplacian L_1 .

Ο L_1 είναι *γραμμικός, μετατοπιστικά αναλλοίωτος* (LSI) τελεστής: η απόκριση σε κάθε pixel είναι σταθμισμένος μέσος όρος της γειτονιάς, με βάρη που ορίζει ο πυρήνας h . Η ισοτροπία του τον καθιστά ιδανικό για φυσικές εικόνες όπου οι ακμές εμφανίζονται σε αυθαίρετες κατευθύνσεις. Επιπλέον, η Gaussian εξομάλυνση ελαχιστοποιεί το Mean Squared Error υπό Gaussian θόρυβο — ακριβώς τον τύπο θορύβου που χρησιμοποιούμε στα πειράματα — γεγονός που καθιστά την L_1 θεωρητικά βέλτιστη για αυτές τις συνθήκες. Το κύριο μειονέκτημά της είναι η *διάχυση σφάλματος*: ο θόρυβος δεν εξαλείφεται αλλά απλώνεται χωρικά μέσω της συνέλιξης, οπότε σε υψηλό θόρυβο (PSNR = 10 dB) μπορεί να εμφανιστούν ψευδείς ακμές ακόμη και μετά την εξομάλυνση.

Μη-γραμμική (L_2 - Μορφολογική). Η μέθοδος βασίζεται σε τελεστές Min-Max που εφαρμόζονται στην εξομαλυσμένη εικόνα $I_\sigma = G_\sigma * I$ [2]. Χρησιμοποιείται το σταυροειδές στοιχείο δόμησης B (5-γειτονιά):


$$B = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Η Laplacian εκτιμάται ως:

$$L_2 = (I_\sigma \oplus B) + (I_\sigma \ominus B) - 2I_\sigma \quad (6)$$


όπου η dilation ($\oplus$) επιλέγει το τοπικό *μέγιστο* και η erosion ($\ominus$) το τοπικό *ελάχιστο* στη γειτονιά κάθε pixel. Η έκφραση αυτή είναι ανάλογη του κλασικού τύπου διακριτής δεύτερης παραγώγου $f(x+h) + f(x-h) - 2f(x)$, με τα ακρότατα να παίζουν τον ρόλο των γειτονικών

τιμών. Η εξομάλυνση πρέπει να εφαρμοστεί ρητά πριν τους μορφολογικούς τελεστές, αφού η μη-γραμμικότητα των $\max/\min$ δεν επιτρέπει ενοποίησή τους σε ενιαίο πυρήνα [2].




Σχήμα 5. Ροή υπολογισμού της μη-γραμμικής Laplacian L_2 : η εξομαλυνμένη εικόνα I_σ τροφοδοτεί παράλληλα τη dilation και την erosion, των οποίων τα αποτελέσματα συνδυάζονται ως $(\oplus) + (\ominus) - 2I_\sigma$.

Το κύριο *πλεονέκτημα* των μορφολογικών τελεστών είναι η ανθεκτικότητα σε ακραίες τιμές: τα $\min/\max$ λειτουργούν ως rank filters που καταστέλλουν αποτελεσματικά θόρυβο τύπου salt-and-pepper, σε αντίθεση με τη γραμμική συνέλιξη που τέτοιο θόρυβο τον απλώνει χωρικά. Ωστόσο, με Gaussian θόρυβο οι τελεστές $\max/\min$ λαμβάνουν υπόψη μόνο τις ακραίες τιμές της γειτονιάς αντί για σταθμισμένο μέσο όρο, παράγοντας παχύτερες και πιο αποσπασματικές ακμές σε σχέση με την L_1 . Επιπλέον, λόγω του σταυροειδούς B , η απόκριση δεν είναι ισοτροπική: ευνοεί τις αξονικές (οριζόντιες/κάθετες) ακμές, ενώ οι διαγώνιες ανιχνεύονται λιγότερο αξιόπιστα. Παρά ταύτα, οι δύο μέθοδοι επιτυγχάνουν συγκρίσιμο C στα πειράματα, με μικρές αποκλίσεις που εξαρτώνται από την επιλογή παραμέτρων (βλ. §14).



Σχήμα 6. Έξοδος μη-γραμμικής Laplacian (L_2) για PSNR= 20 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Ίδια κωδικοποίηση με τα Σχ. 2--3.




Σχήμα 7. Έξοδος μη-γραμμικής Laplacian (L_2) για PSNR= 10 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Οι ακμές είναι παχύτερες λόγω του σταυροειδούς B .

1.2.3 Εύρεση Zero-crossings


Τα zero-crossings της Laplacian L , τα σημεία δηλαδή όπου η δεύτερη παράγωγος αλλάζει πρόσημο, αντιστοιχούν στις ακμές της εξομαλυμένης εικόνας. Ο εντοπισμός υλοποιείται σε δύο βήματα. Πρώτα κατασκευάζεται η δυαδική εικόνα προσήμου $X = (L \geq 0)$, όπου τα pixels με $L \geq 0$ παίρνουν τιμή 1 και τα υπόλοιπα τιμή 0. Τα zero-crossings βρίσκονται ακριβώς στα όρια μεταξύ περιοχών τιμής 0 και 1 στην X , δηλαδή στο μορφολογικό όριο ∂X του συνόλου X . Σύμφωνα με τη θεωρία μαθηματικής μορφολογίας [2], το όριο ενός δυαδικού συνόλου προσεγγίζεται ως:

$$Y = (X \oplus B) - (X \ominus B) \approx \partial X \quad (7)$$


Τα pixels όπου $Y = 1$ αποτελούν τα zero-crossings της L . Η συμμετρία της έκφρασης — dilation που διαστέλλει το σύνολο X και erosion που το συρρικνώνει — εξασφαλίζει ότι το εξαγόμενο όριο είναι συμμετρικό ως προς το X και το συμπλήρωμά του X^c [2], αποφεύγοντας συστηματική μετατόπιση των ακμών προς τη μία ή την άλλη πλευρά.




Σχήμα 8. Zero-crossings γραμμικής L_1 για PSNR= 20 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Λευκά pixels: $Y = 1$, αλλαγή προσήμου της L .



Σχήμα 9. Zero-crossings γραμμικής L_1 για PSNR= 10 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Με μικρό σ τα ψευδή zero-crossings λόγω θορύβου είναι εμφανώς περισσότερα.



Σχήμα 10. Zero-crossings μη-γραμμικής L_2 για PSNR= 20 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά).



Σχήμα 11. Zero-crossings μη-γραμμικής L_2 για PSNR= 10 dB: $\sigma = 1.5$ (αριστερά) και $\sigma = 3.0$ (δεξιά). Παχύτερες γραμμές λόγω του σταυροειδούς B .

1.2.4 Απόρριψη σε Ομαλές Περιοχές

Τα zero-crossings της Laplacian εμφανίζονται σε κάθε σημείο αλλαγής προσήμου, ακόμη και σε ομαλές περιοχές όπου η Laplacian ταλαντώνεται γύρω από το μηδέν λόγω θορύβου. Αυτά τα ψευδή zero-crossings δεν αντιστοιχούν σε πραγματικές ακμές και πρέπει να απορριφθούν. Ο μηχανισμός που χρησιμοποιείται βασίζεται στην κλίση (gradient magnitude) της εξομαλυμένης εικόνας I_σ : μια πραγματική ακμή συνοδεύεται αναγκαστικά από μεγάλη κλίση, ενώ σε ομαλές περιοχές η κλίση είναι μικρή. Συγκεκριμένα, η τελική δυαδική εικόνα ακμών D προκύπτει ως:

$$D[i, j] = 1 \iff Y[i, j] = 1 \text{ και } \|\nabla I_\sigma[i, j]\| > \theta_{\text{edge}} \cdot \max_{x, y} \|\nabla I_\sigma\| \quad (8)$$

Η κλίση $\|\nabla I_\sigma\| = \sqrt{(\partial I_\sigma / \partial x)^2 + (\partial I_\sigma / \partial y)^2}$ υπολογίζεται στην εξομαλυμένη (και όχι στην αρχική) εικόνα, γιατί η εξομάλυνση έχει ήδη καταστείλει τον θόρυβο, οπότε η κλίση αντικατοπτρίζει πραγματικές μεταβάσεις έντασης.

Η επιλογή του $\|\nabla I_\sigma\|$ ως κριτηρίου απόρριψης — αντί της απόλυτης τιμής της Laplacian $|L|$ — είναι σκόπιμη: το $|L|$ είναι μηδέν ακριβώς στα zero-crossings (εξ ορισμού), οπότε δεν παρέχει κανένα διαχωριστικό κριτήριο εκεί. Αντίθετα, η κλίση $\|\nabla I_\sigma\|$ είναι τοπικά μέγιστη στα σημεία που αντιστοιχούν σε πραγματικές ακμές και μικρή στα ψευδή zero-crossings που οφείλονται σε θόρυβο, επιτρέποντας τη διάκρισή τους.

Η παράμετρος $\theta_{\text{edge}} \in [0, 1]$ ελέγχει την αυστηρότητα: υψηλότερη τιμή κρατά μόνο τις ισχυρότερες ακμές μειώνοντας τον θόρυβο αλλά χάνοντας ασθενείς ακμές, ενώ χαμηλή τιμή ανιχνεύει περισσότερες ακμές αλλά εισάγει ψευδοανιχνεύσεις. Η βέλτιστη τιμή εξαρτάται από το επίπεδο θορύβου της εικόνας εισόδου.

1.3 Αξιολόγηση Αποτελεσμάτων

1.3.1 Υπολογισμός Αληθινών Ακμών

Για να αξιολογηθεί ποσοτικά ο αλγόριθμος ανίχνευσης ακμών, χρειάζεται μια δυαδική εικόνα αληθινών ακμών T (ground truth). Αφού διαθέτουμε την αρχική καθαρή εικόνα I_0 χωρίς θόρυβο, οι αληθινές ακμές μπορούν να εκτιμηθούν μέσω της μορφολογικής κλίσης (morphological gradient) [2]:

$$M = (I_0 \oplus B) - (I_0 \ominus B) \quad (9)$$

Η ποσότητα M μετρά σε κάθε pixel τη μέγιστη μεταβολή έντασης εντός γειτονιάς 3×3 : σε ομαλές περιοχές η dilation και η erosion δίνουν παρόμοιες τιμές ($M \approx 0$), ενώ στις ακμές η διαφορά τους είναι μεγάλη. Η τελική δυαδική εικόνα αληθινών ακμών προκύπτει με κατωφλιοποίηση: $T = (M > \theta_{\text{real}})$, όπου επιλέχθηκε $\theta_{\text{real}} = 0.2 \cdot M.\text{max}() = 51$.

1.3.2 Ποσοτική Αξιολόγηση


Η σύγκριση μεταξύ των ανιχνευθεισών ακμών D και των αληθινών T γίνεται μέσω του κριτηρίου:

$$C = \frac{Pr(D|T) + Pr(T|D)}{2} = \frac{\text{Precision} + \text{Recall}}{2} \quad (10)$$


όπου $\text{Precision} = |D \cap T|/|D|$ είναι το ποσοστό ανιχνευθεισών ακμών που είναι πραγματικά ακμές, και $\text{Recall} = |D \cap T|/|T|$ το ποσοστό αληθινών ακμών που εντοπίστηκαν. Το κριτήριο C ισορροπεί μεταξύ αυτών των δύο ποσοτήτων: ένας αλγόριθμος που ανιχνεύει πάρα πολλές ακμές μπορεί να πετύχει υψηλό Recall αλλά θα έχει χαμηλό Precision (πολλές ψευδοανιχνεύσεις), ενώ ένας υπερβολικά συντηρητικός αλγόριθμος θα έχει υψηλό Precision αλλά χαμηλό Recall (χάνει ακμές). Η μέγιστη τιμή $C = 1$ αντιστοιχεί σε τέλεια ανίχνευση.

1.3.3 Πειραματισμός Παραμέτρων

Ως αφετηρία χρησιμοποιήθηκαν οι προτεινόμενες τιμές της εκφώνησης: $\sigma = 1.5$, $\theta_{\text{edge}} = 0.2$ για $\text{PSNR} = 20 \text{ dB}$ και $\sigma = 3.0$, $\theta_{\text{edge}} = 0.2$ για $\text{PSNR} = 10 \text{ dB}$. Σημειώνεται ότι η συστηματική σάρωση που ακολουθεί (§15) αναδεικνύει βέλτιστη ζώνη κοντά στο $\sigma \approx 2$ για $\text{PSNR} = 10 \text{ dB}$, επιβεβαιώνοντας ότι η προτεινόμενη τιμή $\sigma = 3.0$ είναι συντηρητική. Τα αποτελέσματα με τις τιμές εκκίνησης φαίνονται στα Σχήματα 12 και 13.




Σχήμα 12. Αποτελέσματα ανίχνευσης ακμών για $\text{PSNR} = 20 \text{ dB}$, $\sigma = 1.5$, $\theta_{\text{edge}} = 0.2$. Αριστερά: αληθινές ακμές T , κέντρο: γραμμική μέθοδος (L_1), δεξιά: μη-γραμμική μέθοδος (L_2).




Σχήμα 13. Αποτελέσματα ανίχνευσης ακμών για $\text{PSNR} = 10 \text{ dB}$, $\sigma = 3.0$, $\theta_{\text{edge}} = 0.2$. Η αύξηση του σ αντισταθμίζει τον ισχυρότερο θόρυβο, αλλά εισάγει μεγαλύτερη χωρική αβεβαιότητα στον εντοπισμό.

Η αύξηση του σ για $\text{PSNR} = 10 \text{ dB}$ είναι αναμενόμενη: ο ισχυρότερος θόρυβος απαιτεί πιο επιθετική εξομάλυνση, η οποία όμως αμβλύνει τις ακμές και εισάγει μεγαλύτερη χωρική αβεβαιότητα.

Με σκοπό να αναλυθεί συστηματικά η επίδραση των παραμέτρων σ και θ_{edge} , πραγματοποιήθηκε εξαντλητική σάρωση και των δύο ταυτόχρονα μέσω 2D heatmaps (Σχήματα 14-15).



Σχήμα 14. 2D heatmap της μετρικής C σε πλέγμα $(\sigma, \theta_{\text{edge}})$ για PSNR= 20 dB.



Σχήμα 15. 2D heatmap της μετρικής C σε πλέγμα $(\sigma, \theta_{\text{edge}})$ για PSNR= 10 dB.

Στην κατηγορία του χαμηλότερου θορύβου (PSNR= 20 dB), και οι δύο μέθοδοι φέρνουν τα καλύτερα αποτελέσματα για $\sigma \approx 1.5$ και θ_{edge} ανάμεσα στο 0.17 και 0.20. Άρα, οι βέλτιστες τιμές των παραμέτρων εξαρτώνται πρωτίστως από το επίπεδο θορύβου και όχι από τον τύπο της Laplacian. Παρόλα αυτά, οι δύο προσεγγίσεις δεν συμπεριφέρονται πάντα ισοδύναμα εκτός της βέλτιστης ζώνης: η γραμμική (L_1), για εύρος $\sigma \in [1, 3]$ και $\theta_{\text{edge}} \in [0.10, 0.35]$, παρουσιάζει μικρές αποκλίσεις του C από τη βέλτιστη τιμή, δηλαδή είναι ανθεκτική σε εσφαλμένη επιλογή παραμέτρων. Αντίθετα, η μη-γραμμική (L_2) εμφανίζει μεγαλύτερη απόκλιση C στις ίδιες τιμές: αν απομακρυνθούμε από τις βέλτιστες παραμέτρους, η ποιότητα του αποτελέσματος μειώνεται ταχύτερα.

Για το υψηλότερο θόρυβο (PSNR= 10 dB), η βέλτιστη ζώνη μετατοπίζεται σε $\sigma \approx 2$ και $\theta_{\text{edge}} \approx 0.25$. Άρα, όσο πιο θορυβώδης η εικόνα, τόσο μεγαλύτερο σ (ισχυρότερη εξομάλυνση) και μεγαλύτερο θ_{edge} (αυστηρότερο φιλτράρισμα ψευδών zero-crossings) απαιτούνται. Το γραμμικό φίλτρο συνεχίζει να αποδίδει καλύτερα για ευρύτερο εύρος τιμών σε σχέση με το μη-γραμμικό.


1.4 Εφαρμογή σε Πραγματικές Εικόνες

1.4.1 Εφαρμογή στην *ermoupoli.jpg*


Οι αλγόριθμοι ανίχνευσης ακμών εφαρμόστηκαν στην πραγματική εικόνα *ermoupoli.jpg* χωρίς πρόσθεση τεχνητού θορύβου. Σε αντίθεση με τη συνθετική εικόνα που περιέχει καθαρά γεωμετρικά σχήματα με ευδιάκριτες μεταβάσεις, η πραγματική εικόνα παρουσιάζει ομαλές μεταβολές φωτεινότητας, πολύπλοκες υφές και φυσικό θόρυβο, καθιστώντας την ανίχνευση ακμών σημαντικά πιο απαιτητική. Η αξιολόγηση εδώ είναι αποκλειστικά ποιοτική (οπτική), αφού δεν υπάρχει ground truth.

1.4.2 Αξιολόγηση Αποτελεσμάτων


Δοκιμάστηκαν τέσσερις συνδυασμοί παραμέτρων που καλύπτουν συστηματικά τον χώρο παραμέτρων, ώστε να αναδειχθεί η επίδραση κάθε παραμέτρου ξεχωριστά. Η εικόνα *ermoupoli.jpg* παρουσιάζει αρχιτεκτονική δομή (κτίριο, παράθυρα, κολώνες) αλλά και δύσκολες περιοχές όπως βλάστηση και ουρανός, προσφέροντας ένα αντιπροσωπευτικό πεδίο δοκιμής.




Σχήμα 16. $\sigma = 1.5$, $\theta_{\text{edge}} = 0.1$. Το χαμηλό σ διατηρεί λεπτομέρεια και χωρική ακρίβεια, αλλά το χαμηλό κατώφλι αφήνει να περάσουν πολλές ψευδοανιχνεύσεις: η βλάστηση και η υφή της πρόσοψης δημιουργούν πυκνό θορυβώδη χάρτη zero-crossings που δυσχεραίνει την ανάγνωση των δομικών ακμών.




Σχήμα 17. $\sigma = 1$, $\theta_{\text{edge}} = 0.2$ - βέλτιστος συνδυασμός. Το πολύ μικρό σ διατηρεί τη μέγιστη χωρική ακρίβεια, ενώ το μεσαίο κατώφλι ισορροπεί μεταξύ απόρριψης ψευδοανιχνεύσεων και διατήρησης ασθενών αλλά πραγματικών ακμών: τα περιγράμματα του κτιρίου, τα παράθυρα και οι κολώνες αποδίδονται με λεπτές, συνεχείς ακμές χωρίς υπερβολικό θόρυβο.



Σχήμα 18. $\sigma = 1.5$, $\theta_{\text{edge}} = 0.3$. Η αύξηση του κατωφλίου εξαλείφει τις ψευδοανιχνεύσεις από υφές και θόρυβο (χάνοντας όμως μερικές πραγματικές ακμές), ενώ ο μικρός σ διατηρεί την ακρίβεια εντοπισμού.



Σχήμα 19. $\sigma = 3.0$, $\theta_{\text{edge}} = 0.1$. Η αυξημένη εξομάλυνση καταστέλλει αποτελεσματικά τον θόρυβο στη βλάστηση, αλλά πλαταίνει τις ακμές και συγχωνεύει γειτονικές δομές: τα μικρά παράθυρα χάνουν την ατομική τους ταυτότητα και τα λεπτά αρχιτεκτονικά στοιχεία γίνονται δυσδιάκριτα.



Σχήμα 20. $\sigma = 3.0$, $\theta_{\text{edge}} = 0.3$. Ο πιο συντηρητικός συνδυασμός: απομένουν μόνο οι κυρίαρχες ακμές υψηλής κλίσης (κύριο περίγραμμα κτιρίου, ορίζοντας). Ο χάρτης είναι εξαιρετικά καθαρός αλλά αδυνατεί να αποδώσει οποιαδήποτε δομική λεπτομέρεια της εικόνας.

Ο βέλτιστος συνδυασμός είναι $\sigma = 1$, $\theta_{\text{edge}} = 0.2$ (Σχήμα 17). Ο πολύ μικρός σ μεγιστοποιεί τη χωρική ακρίβεια — κρίσιμη για αρχιτεκτονικές δομές με λεπτές λεπτομέρειες — ενώ το μεσαίο κατώφλι δρα ως εκλεκτικό φίλτρο: κρατά τα zero-crossings με επαρκώς μεγάλη κλίση χωρίς να χάνει τις ασθενέστερες αλλά πραγματικές ακμές που χάνονται με $\theta_{\text{edge}} = 0.3$. Αυτή η λογική είναι σύμφωνη με την πρόβλεψη του Marr-Hildreth [1]: σε φυσικές εικόνες, τα όρια αντικειμένων συνοδεύονται από σημαντικά μεγαλύτερη κλίση από ό,τι οι υφές ή ο θόρυβος.

Η σύγκριση L_1 και L_2 στην πραγματική εικόνα επιβεβαιώνει τα ευρήματα της συνθετικής:

η L_1 παράγει λεπτότερες, πιο συνεχείς ακμές, ενώ η L_2 δίνει παχύτερες και πιο αποσπασματικές. Για αρχιτεκτονικές εικόνες, όπου οι ακμές είναι κυρίως μακριές και συνεχείς, η L_1 φαίνεται ποιοτικά ανώτερη. Η L_2 μπορεί να προτιμηθεί όταν η ακρίβεια εντοπισμού σε επίπεδο pixel είναι σημαντικότερη από τη συνέχεια.

2. Εντοπισμός Σημείων Ενδιαφέροντος

Στο δεύτερο μέρος της άσκησης υλοποιήθηκαν οι βασικοί ανιχνευτές σημείων ενδιαφέροντος της εκφώνησης: Harris για γωνίες και Hessian για blobs, τόσο σε μία κλίμακα όσο και σε πολυκλιμακωτή μορφή. Όλες οι υλοποιήσεις έγιναν στο αρχείο `part2.py` και εφαρμόστηκαν στις εικόνες `solar.jpg` και `blood_cells.jpg`. Όπως και στο Μέρος 1, οι εικόνες μετατρέπονται σε grayscale float64, ενώ οι συνελίξεις εκτελούνται με `cv2.filter2D` και ανακλαστικά σύνορα (`BORDER_REFLECT`), ώστε να αποφεύγονται τεχνητές αποκρίσεις στα όρια.

Η γενική λογική είναι η ίδια και στις τέσσερις υποενότητες: πρώτα κατασκευάζεται ένας χάρτης απόκρισης που είναι θεωρητικά κατάλληλος για τον τύπο δομής που αναζητούμε, στη συνέχεια εφαρμόζεται non-maximum suppression και σχετική κατωφλίωση, και τέλος, όπου απαιτείται, προστίθεται στάδιο επιλογής χαρακτηριστικής κλίμακας με κανονικοποιημένη LoG απόκριση [3].

2.1 Ανίχνευση Γωνιών σε Μία Κλίμακα

2.1.1 Υπολογισμός του Δομικού Τανυστή

Για δεδομένη κλίμακα διαφορίσεως $\sigma = 2.0$ και κλίμακα ολοκλήρωσης $\rho = 2.5$, υπολογίστηκαν τα στοιχεία του δομικού τανυστή J σε κάθε pixel (x,y) της εικόνας, σύμφωνα με τις σχέσεις:

$$J_1(x,y) = G_\rho * \left(\frac{\partial I_\sigma}{\partial x} \right)^2, \quad J_2(x,y) = G_\rho * \left(\frac{\partial I_\sigma}{\partial x} \frac{\partial I_\sigma}{\partial y} \right), \quad J_3(x,y) = G_\rho * \left(\frac{\partial I_\sigma}{\partial y} \right)^2 \quad (11)$$


όπου $I_\sigma = G_\sigma * I$ είναι η εξομαλυμένη εικόνα. Η Gaussian κατασκευάζεται, όπως και στο Μέρος 1, ως εξωτερικό γινόμενο δύο 1D πυρήνων που επιστρέφει η `cv2.getGaussianKernel`, με μέγεθος $n = 2\lceil 3\sigma \rceil + 1$. Οι πρώτες παράγωγοι υπολογίζονται αριθμητικά με τη `numpy.gradient`. Τέλος, οι συνελίξεις με τον γκαουσιανό πυρήνα G_ρ , γνωστή ως κλίμακα ολοκλήρωσης (integration scale), εκτελούνται πάλι με τη `cv2.filter2D` και εξασφαλίζει ότι ο πίνακας J ενσωματώνει πληροφορία από πολλαπλές κατευθύνσεις εντός μιας ευρύτερης γειτονιάς μεγέθους τάξης ρ γύρω από κάθε σημείο, επιτρέποντας την ορθή εκτίμηση της γωνιότητας του σημείου. Επίσης, η προηγούμενη συνέλιξη έχει σημαντική μαθηματική αξία καθώς χωρίς αυτό ο πίνακας J θα είχε σε κάθε σημείο βαθμό 1 και η ορίζουσά του θα μηδενιζόταν ταυτοτικά ($\det(J) = 0$), καθιστώντας αδύνατη την εύρεση γωνιών, όπως θα εξηγηθεί και στο επόμενο ερώτημα. Έτσι, ο τανυστής

$$J(x,y) = \begin{bmatrix} J_1(x,y) & J_2(x,y) \\ J_2(x,y) & J_3(x,y) \end{bmatrix} \quad (12)$$

κωδικοποιεί τη μεταβολή της έντασης σε τοπική γειτονιά του κάθε σημείου. Όπως έχει αναφερθεί στο Μέρος 1, οι ακμές εντοπίζονται στις περιοχές όπου η παράγωγος της έντασης σε κάποια κατεύθυνση είναι μεγάλη καθώς σε αυτά τα σημεία έχουμε σημαντική μεταβολή


της φωτεινότητας. Οπότε, αν σκεφτούμε ότι μια γωνία δημιουργείται από τη τομή δύο ακμών, αναμένουμε ότι θα πρέπει να έχουμε σημαντική μεταβολή της φωτεινότητας σε δύο κατευθύνσεις. Ο τανυστής J κωδικοποιεί ακριβώς αυτή την πληροφορία καθώς το στοιχείο J_1 βασίζεται στο I_x^2 και εντοπίζει την έντονη μεταβολή κατά τον οριζόντιο άξονα x δίνοντας έμφαση στις κατακόρυφες ακμές ενώ το J_3 βασίζεται στο I_y^2 και εντοπίζει την έντονη μεταβολή κατά τον κατακόρυφο άξονα y δίνοντας έμφαση στις οριζόντιες ακμές. Τέλος, ο μικτός όρος J_2 εξαρτάται από το "μικτό" γινόμενο $I_x \cdot I_y$ άρα θα λαμβάνει μεγάλες τιμές μόνο εκεί που και οι δύο παράγωγοι είναι ταυτόχρονα σημαντικές. κάτι το οποίο συμβαίνει κυρίως σε γωνίες ή σε διαγώνιες ακμές. Παρακάτω παρουσιάζονται οι χάρτες J_1 , J_2 , J_3 για τις δύο εικόνες, όπου φαίνεται καθαρά ότι τα J_1 , J_3 εμφανίζονται πιο έντονα (άσπρο) κατά μήκος των ακμών, ενώ ο μικτός όρος J_2 ενισχύει κυρίως τις γωνίες και τις διαγώνιες ακμές.

Part 2.1.1 - solar.jpg (sigma=2.0, rho=2.5)



Σχήμα 21. Οπτικοποίηση των J_1 , J_2 , J_3 για την εικόνα solar.jpg με $\sigma = 2.0$ και $\rho = 2.5$. Τα διαγώνια στοιχεία του τανυστή ενισχύουν διαφορετικούς προσανατολισμούς κλίσης, ενώ ο όρος J_2 αποτυπώνει την αλληλεπίδραση των δύο κατευθύνσεων.

Part 2.1.1 - blood_cells.jpg (sigma=2.0, rho=2.5)



Σχήμα 22. Αντίστοιχα μεγέθη J_1 , J_2 , J_3 για την εικόνα blood_cells.jpg. Οι έντονες αποκρίσεις εμφανίζονται κατά μήκος των κυτταρικών περιγραμμάτων, όπου οι παράγωγοι στις δύο διευθύνσεις είναι μεγάλες.

Ειδικότερα, στο σχήμα με τα κύτταρα μπορούμε να παρατηρήσουμε καλύτερα την αξία του κάθε στοιχείου του τανυστή. Ειδικότερα, στη πρώτη εικόνα του J_1 βλέπουμε ότι οι έντονες λευκές αποκρίσεις εμφανίζονται κατά μήκος των κατακόρυφων καμπυλών των κυττάρων όπου η οριζόντια παράγωγος είναι μεγάλη, ενώ στο J_3 οι έντονες λευκές αποκρίσεις εμφανίζονται κατά μήκος των οριζόντιων ακμών των κυττάρων όπου οι κατακόρυφες παράγωγοι

είναι μεγάλες. Τέλος, στο J_2 οι έντονες αποκρίσεις εμφανίζονται κυρίως στις γωνιακές καμπύλες των κυττάρων μεταξύ των προαναφερθέντων οριζόντιων και κατακόρυφων καμπυλών όπου και οι δύο παράγωγοι είναι ταυτόχρονα σημαντικές, σηματοδοτώντας μία πλάγια ακμή ή γωνία.

2.1.2 Ιδιοτιμές του Τανυστή

Από τον συμμετρικό πίνακα J υπολογίζονται οι δύο ιδιοτιμές λ_- και λ_+ σε κλειστή μορφή:

$$\lambda_{\pm} = \frac{1}{2} \left(J_1 + J_3 \pm \sqrt{(J_1 - J_3)^2 + 4J_2^2} \right) \quad (13)$$

Οι ιδιοτιμές του δομικού τανυστή J περιγράφουν τις κύριες διευθύνσεις μεταβολής της έντασης σε μια γειτονιά. Ειδικότερα, αν φανταστούμε την τοπική μεταβολή σαν μια έλλειψη τότε η ιδιοτιμή λ_+ (η μεγαλύτερη ιδιοτιμή) αντιστοιχεί στον μεγάλο άξονα της έλλειψης (μέγιστη μεταβολή) εν η ιδιοτιμή λ_- (η μικρότερη ιδιοτιμή) αντιστοιχεί στον μικρό άξονα της έλλειψης (ελάχιστη μεταβολή), επίσης, οι ιδιοτιμές αυτές έχουν άμεση γεωμετρική ερμηνεία. Πρώτον, σε ομαλές περιοχές, όπου τόσο I_x όσο και I_y θα είναι πολύ μικρά άρα και τα στοιχεία του τανυστή, και οι δύο ιδιοτιμές είναι μικρές σχεδόν. Από την άλλη, σε ακμές, όπου ένα από τα δύο διαγώνια στοιχεία του τανυστή θα είναι σημαντικά μεγαλύτερο από τα υπόλοιπα, η ιδιοτιμή λ_+ είναι μεγάλη και η λ_- θα είναι πολύ μικρή σχεδόν 0 όπως φαίνεται εύκολα από τη παραπάνω εξίσωση. Τέλος, σε γωνίες και οι δύο λαμβάνουν μεγάλες τιμές καθώς οι τιμές τους θα εξαρτώνται σημαντικά από τον πλέον μη αμελητέο όρο του μη-διαγώνιου στοιχείου του τανυστή και τα J_1 , J_3 είναι μεγάλα με αποτέλεσμα να μην μηδενίζεται το λ_- . Οπότε, μπορούμε να συνοψίσουμε τη γεωμετρική ερμηνεία των ιδιοτιμών ως εξής:


Πίνακας 1. Γεωμετρική Ερμηνεία των Ιδιοτιμών λ_+ και λ_- του Τανυστή J

Περιοχή Εικόνας	Τιμή λ_+	Τιμή λ_-
Επίπεδη (Flat)	Σχεδόν 0	Σχεδόν 0
Ακμή (Edge)	Μεγάλη (> 0)	Σχεδόν 0
Γωνία (Corner)	Μεγάλη (> 0)	Μεγάλη (> 0)

Από τον παραπάνω πίνακα γίνεται σαφές ότι οι ιδιοτιμές παρέχουν κρίσιμη πληροφορία για τον τύπο της τοπικής δομής: επίπεδη, ακμή ή γωνία για αυτό και είναι κατάλληλο ενδιάμεσο στάδιο για τον ορισμό ενός κριτηρίου "γωνιότητας". Στην πράξη, η λ_+ λειτουργεί ως ο κυρίαρχος άξονας μεταβολής και καλός ανιχνευτής ακμών, ενώ η λ_- αποκαλύπτει αν η μεταβολή είναι ισχυρή και στη δεύτερη διεύθυνση γεγονός όπου συμβαίνει σε γωνίες, καθιστώντας την καλό ανιχνευτή γωνιών. Η ύπαρξη και των δύο είναι αυτή που ξεχωρίζει μια πραγματική γωνία από μια απλή ακμή. Οπότε, γίνεται κατανοητό ότι η ύπαρξη και των δύο ιδιοτιμών είναι αναγκαία για την ανίχνευση γωνιών, για αυτό και η συνέλιξη με τον γκαουσιανό πυρήνα ολοκλήρωσης είναι μαθηματικά απαραίτητη για να εξασφαλίσει ότι ο


ταυσστής J έχει βαθμό 2 και οι ιδιοτιμές του είναι μη μηδενικές. Παρακάτω παρουσιάζονται οι γκρίζες εικόνες για τα $\lambda_+(x, y)$ και $\lambda_-(x, y)$ για τις δύο εικόνες, όπου φαίνεται ότι η λ_+ είναι γενικά πιο εκτεταμένη και ενισχύει τις ακμές, ενώ η λ_- παραμένει έντονη κυρίως σε δομές που έχουν μεταβολή και στις δύο διευθύνσεις, δηλαδή σε γωνίες και σημεία επαφής.

Part 2.1.2 - solar.jpg (sigma=2.0, rho=2.5)



Σχήμα 23. Ιδιοτιμές λ_- και λ_+ για την solar.jpg. Η λ_+ τονίζει τα περιγράμματα και τις ακμές των πάνελ, ενώ η λ_- παραμένει έντονη κυρίως στα γωνιακά σημεία.

Part 2.1.2 - blood_cells.jpg (sigma=2.0, rho=2.5)



Σχήμα 24. Ιδιοτιμές λ_- και λ_+ για την blood_cells.jpg. Η λ_+ τονίζει τα περιγράμματα των κυτάρων, ενώ η λ_- παραμένει έντονη κυρίως στις γωνιακές καμπύλες και στα σημεία επαφής.

2.1.3 Κριτήριο Harris και Επιλογή Σημείων

Ωστόσο, οι ιδιοτιμές από μόνες τους δεν αρκούν για να ορίσουν ένα αξιόπιστο κριτήριο γωνίας, ενώ επίσης ο υπολογισμός τους σε κάθε pixel είναι υπολογιστικά βαρύς, δημιουργώντας την ανάγκη για ένα απλούστερο κριτήριο το οποίο στη περίπτωση μας θα είναι το Harris-Stephens.

Το κριτήριο Harris-Stephens [4] ορίστηκε ως:


$$R(x, y) = \lambda_-(x, y)\lambda_+(x, y) - k(\lambda_-(x, y) + \lambda_+(x, y))^2 \quad (14)$$

με $k = 0.05$. Το κριτήριο αυτό συνδυάζει τις ιδέες που αναπτύξαμε παραπάνω για τις ιδιοτιμές στις διαφορετικές δομές καθώς στις γωνίες, το R θα παίρνει μεγάλες θετικές τιμές, στις ακμές, το R θα παίρνει αρνητικές τιμές και στις επίπεδες περιοχές, το R θα είναι σχεδόν μηδέν. Οπότε για να διαμορφώσουμε ένα κριτήριο γωνιότητας θα θέλαμε να βρούμε τα τοπικά μέγιστα του R που είναι θετικά και αρκετά μεγάλα. Τελικά, επιλέξαμε σαν γωνίες τα pixels (x,y) τα οποία ικανοποιούν τα εξής δύο κριτήρια:


1. Αποτελούν τοπικά μέγιστα της R σε δισκοειδή γειτονιά με μέγεθος που εξαρτάται από την κλίμακα ($n = 2\lceil 3\sigma \rceil + 1$). Ειδικότερα, χρησιμοποιήθηκε η συνθήκη $\text{Cond1} = (R == \text{cv2.dilate}(R, B_{sq}))$ με χρήση της cv2.dilate ως μέθοδος Non-Maximum Suppression, καθώς δημιουργεί μια μάσκα boolean που είναι True μόνο στα pixels όπου το R είναι ίσο με το μέγιστο του δισκοειδούς παραθύρου που ορίσαμε, εξασφαλίζοντας ότι διατηρούνται μόνο τα τοπικά μέγιστα. Η ιδέα πίσω από αυτή τη τεχνική είναι ότι αν κάνουμε dilation(φίλτρο κινούμενου μεγίστου) σε έναν παράθυρο τα μόνα σημεία τα οποία δεν θα αλλάξουν τιμή είναι μόνο εκείνα τα οποία έχουν ήδη τη μέγιστη τιμή σε αυτό το παράθυρο. Οπότε, σαρώνοντας όλη την εικόνα με αυτό το δισκοειδές παράθυρο, θα κρατήσουμε μόνο τα τοπικά μέγιστα του R .
2. Ικανοποιούν το κατώφλι $R(x,y) > \theta_{\text{corn}} R_{\text{max}}$ με $\theta_{\text{corn}} = 0.005$, με σκοπό να αποφύγουμε μικρές διακυμάνσεις ή θόρυβο που έτυχε να είναι τοπικά μέγιστα καθιστώντας τον ανιχνευτή πιο robust.

Τα επιλεγμένα σημεία αποθηκεύονται σε πίνακα $N \times 3$ με συντεταγμένες (x, y, σ) , καθώς αυτή τη παράμετρο δέχεται η συνάρτηση `interest_points_visualization` την οποία χρησιμοποιούμε για την οπτικοποίηση των σημείων ενδιαφέροντος στην αντίστοιχη κλίμακα που τα έχουμε εντοπίσει. Παρακάτω φαίνεται ο χάρτης απόκρισης R και τα τελικά σημεία γωνίας που προκύπτουν μετά από non-maximum suppression και κατωφλίωση για τις δύο εικόνες.

Part 2.1.3 - solar.jpg (sigma=2.0, rho=2.5, k=0.05, theta_corn=0.005)



Σχήμα 25. Αποτελέσματα της ενότητας 2.1.3 για την εικόνα `solar.jpg`. Αριστερά φαίνεται ο χάρτης απόκρισης Harris R , ενώ δεξιά τα τελικά σημεία γωνίας που προκύπτουν μετά από non-maximum suppression και κατωφλίωση.

Part 2.1.3 - blood_cells.jpg (sigma=2.0, rho=2.5, k=0.05, theta_corn=0.005)

Σχήμα 26. Αποτελέσματα της ενότητας 2.1.3 για την εικόνα `blood_cells.jpg`. Αριστερά φαίνεται ο χάρτης απόκρισης Harris R , ενώ δεξιά τα τελικά σημεία γωνίας που προκύπτουν μετά από non-maximum suppression και κατωφλίωση.

Παρατηρούμε ότι όντως και στις δύο περιπτώσεις ο χάρτης R παρουσιάζει πιο φωτεινές τις γωνιακές δομές της εικόνας, στην `solar.jpg` παρουσιάζει πιο φωτεινές τις γωνίες των πάνελ και τις διασταυρώσεις των γραμμών, ενώ στη `blood_cells.jpg` ενισχύει κυρίως τις γωνιακές καμπύλες των κυττάρων και τα σημεία επαφής μεταξύ τους. Τέλος, στις έγχρωμες εικόνες με τα σημεία γωνίας, παρατηρούμε ότι πραγματικά η μέθοδος Harris-Stephens έχει εντοπίσει τις γωνίες των πάνελ και τις διασταυρώσεις των γραμμών στην `solar.jpg` και τις γωνιακές καμπύλες των κυττάρων και τα σημεία επαφής μεταξύ τους στη `blood_cells.jpg` ή γενικά τα σημεία όπου έχουμε μεταβολή της φωτεινότητας και στις δύο διευθύνσεις όπως στη πρώτη εικόνα στις σχιές των γωνιών των πάνελ. Συμπερασματικά, επιβεβαιώνεται η αποτελεσματικότητα του κριτηρίου Harris για την ανίχνευση γωνιών σε έγχρωμες εικόνες.

Γενικά, η μέθοδος Harris-Stephens φαίνεται ότι μας δίνει καλύτερα και πιο ρεαλιστικά αποτελέσματα στην εικόνα με τα πάνελ όπου υπάρχουν καθαρές γωνίες και ευθείες γραμμές, ενώ στην εικόνα με τα κύτταρα, όπου οι δομές είναι πιο οργανικές και κυκλικές, η μέθοδος εντοπίζει κυρίως τις γωνιακές καμπύλες και τα σημεία επαφής, αλλά δεν είναι τόσο αποτελεσματική στην ανίχνευση των κυκλικών περιγραμμάτων των κυττάρων, κάτι το οποίο θα μπορούσε να βελτιωθεί με τη χρήση ενός ανιχνευτή blobs όπως ο Hessian που θα δούμε στη συνέχεια.

2.2 Πολυκλιμακωτή Ανίχνευση Γωνιών

2.2.1 Κατασκευή της Αναπαράστασης Πολλαπλών Κλίμακων


Στο προηγούμενο ερώτημα η ανίχνευση των γωνιών γινόταν σε μία μόνο κλίμακα η οποία οριζόταν από τις παραμέτρους σ και ρ . Ωστόσο, αυτή η μέθοδος δεν είναι πάντα αρκετή για να ανιχνεύσει όλες τις σημαντικές γωνίες σε μια εικόνα, καθώς διαφορετικές δομές μπορεί να είναι πιο εμφανείς σε διαφορετικές κλίμακες. Για παράδειγμα, μικρές γωνίες μπορεί να είναι πιο ευδιάκριτες σε μικρές κλίμακες (μικρό σ), ενώ μεγαλύτερες γωνίες ή πιο αδρές δομές

μπορεί να απαιτούν μεγαλύτερες κλίμακες(μεγάλο σ) για να ανιχνευθούν αποτελεσματικά, αναλογικά με το παράδειγμα τη φωτογραφικής μηχανής και την απόσταση εστίασης της από το αντικείμενο. Οπότε, η λύση σε αυτό το πρόβλημα είναι η ανάλυση στον χώρο των κλιμάκων(scale-space) όπως προτάθηκε από τον Lindeberg [5], όπου με την πολυκλιμακωτή αναπαράσταση της εικόνας μπορούμε να ανιχνεύσουμε γωνίες σε πολλαπλές κλίμακες και να επιλέξουμε τη πιο αντιπροσωπευτική για κάθε σημείο, ορίζοντας κάποια μετρική αμετάβλητη ως προς τη κλίμακα την οποία θα μεγιστοποιήσουμε σε μία γειτονία κλιμάκων. Έτσι, στις παραπάνω ιδέες βασίζεται η πολυκλιμακωτή μέθοδος Harris-Laplacian ανίχνευσης γωνιών, όπου στο πρώτο στάδιο βάσει της μεθόδου Harris που περιγράφηκε στο προηγούμενο ερώτημα, βρίσκουμε τις γωνίες της εικόνας σε πολλαπλές κλίμακες με διαφορετικές τιμές σ και ρ , και στο δεύτερο στάδιο για κάθε σημείο που ανιχνεύεται ως γωνία σε κάποια κλίμακα, ελέγχεται αν η κανονικοποιημένη απόκριση Laplacian είναι μέγιστη σε σχέση με τις γειτονικές κλίμακες, επιλέγοντας έτσι τη χαρακτηριστική κλίμακα για κάθε σημείο. Οπότε το πρώτο στάδιο αποτελείται από την εφαρμογή του αλγορίθμου εύρεσης γωνιών μόνης κλίμακας για διαφορετικές κλίμακες ολοκλήρωσης και διαφόρισης:

$$\sigma_i = s^i \sigma_0, \quad \rho_i = s^i \rho_0, \quad i = 0, \dots, N-1 \quad (15)$$


με $\sigma_0 = 2.0$, $\rho_0 = 2.5$ οι αρχικές κλίμακες διαφόρισης και ολοκλήρωσης, $s = 1.5$ ο παράγοντας κλιμάκωσης και $N = 4$ ο αριθμός των κλιμάκων.. Σε κάθε επίπεδο κλίμακας εφαρμόστηκε ανεξάρτητα ο ανιχνευτής Harris της προηγούμενης παραγράφου, παράγοντας για κάθε i τον χάρτη αποκρίσεων R_i και το αντίστοιχο σύνολο γωνιών. Παρακάτω παρουσιάζονται οι χάρτες R_i και οι εντοπισμένες γωνίες για κάθε κλίμακα.

Part 2.2.1 - solar.jpg (sigma_0=2.0, rho_0=2.5, s=1.5, N=4)



Σχήμα 27. Πολυκλιμακωτοί χάρτες Harris και αντίστοιχες γωνίες για την solar.jpg. Στην πρώτη γραμμή απεικονίζεται η απόκριση R_i ανά κλίμακα και στη δεύτερη τα σημεία που διατηρούνται μετά το non-maximum suppression.

Part 2.2.1 - blood_cells.jpg (sigma_0=2.0, rho_0=2.5, s=1.5, N=4)



Σχήμα 28. Πολυκλίμακωτή συμπεριφορά του Harris στην blood_cells.jpg. Οι λεπτές τοπικές δομές εμφανίζονται σε μικρότερες κλίμακες, ενώ σε μεγαλύτερες κλίμακες κυριαρχούν πιο ομαδοποιημένες κυτταρικές δομές.

Παρατηρούμε ότι όσο αυξάνει το i , από τον χάρτη R , η εξομάλυνση (Gaussian blur-χαμηλοπερατό φίλτρο) γίνεται ισχυρότερη με αποτέλεσμα τη σταδιακή εξάλειψη των δομών υψηλής λεπτομέρειας και συχνότητας όπως θόρυβος και μικρές λεπτομέρειες υφής με αποτέλεσμα να μετατοπίζεται το ενδιαφέρον του ανιχνευτή από λεπτομέρειες μικρής κλίμακας προς πιο μεγάλες δομές της εικόνας. Οπότε έχουμε σταδιακή μείωση των ανιχνευόμενων γωνιών και εντοπισμό πιο μεγάλων δομών καθώς αυξάνει το i . Επίσης, στις κάτω εικόνες με τα σημεία γωνίας, ο κύκλος εστίασης παύει να αποτελείται από μερικά pixels και γίνεται πιο φαρδύς λαμβάνοντας υπόψιν ολόκληρες περιοχές τους. Για παράδειγμα, στην solar.jpg στην κλίμακα $i = 0$ εντοπίζονται πολλές γωνίες κατά μήκος των πάνελ και των διασταυρώσεων των γραμμών τους, ενώ στην κλίμακα $i = 3$ οι γωνίες είναι λιγότερες και επικεντρώνονται κυρίως στις μεγάλες γωνίες των πάνελ. Αντίστοιχα, στη blood_cells.jpg στην κλίμακα $i = 0$ εντοπίζονται πολλές γωνίες κατά μήκος των λεπτών κυτταρικών περιγραμμάτων και των σημείων επαφής, ενώ στην κλίμακα $i = 3$ οι γωνίες είναι λιγότερες και επικεντρώνονται κυρίως στις πιο ομαδοποιημένες κυτταρικές δομές, ανιχνεύοντας ως γωνία ενδεχομένως ένα ολόκληρο μικρό κύτταρο.


2.2.2 Harris-Laplacian Επιλογή Χαρακτηριστικής Κλίμακας

Οπότε, μετά την ανίχνευση των γωνιών σε κάθε κλίμακα, το επόμενο βήμα είναι να επιλέξουμε τη χαρακτηριστική κλίμακα για κάθε σημείο βάσει κάποιας μετρικής που είναι αμετάβλητη ως προς τη κλίμακα. Στην περίπτωση του Harris-Laplacian, αυτή η μετρική είναι η κανονικοποιημένη απόκριση Laplacian-of-Gaussian (LoG). Οι Mikolajczyk και Schmid [6] έδειξαν πειραματικά ότι η κανονικοποιημένη LoG απόκριση παρουσιάζει τα καλύτερα αποτελέσματα σε σχέση με άλλες μετρικές για πολλαπλές κλίμακες. Αρχικά υπολογίζουμε την κανονικοποιημένη Λαπλασιανή της Γκαουσιανής (Laplacian of Gaussian LoG) για τις

διαφορετικές κλίμακες διαφύρισης του προηγούμενου βήματος:

$$|\text{LoG}(x, i)| = \sigma_i^2 |L_{xx}(x, i) + L_{yy}(x, i)| \quad (16)$$

Οπότε πρακτικά κάνουμε συνέλιξη της εικόνας με τον πυρήνα LoG της αντίστοιχης κλίμακας και στη συνέχεια πολλαπλασιασμό με σ_i^2 . Για κάθε σημείο Harris που ανιχνεύτηκε στην κλίμακα i , ελέγχεται αν η κανονικοποιημένη LoG απόκριση στο ίδιο χωρικό σημείο είναι μέγιστη ως προς τις γειτονικές κλίμακες $i-1, i, i+1$ και μόνο σε αυτήν την περίπτωση το σημείο διατηρείται. Με τον τρόπο αυτό εξασφαλίζεται ότι το τελικό σύνολο σημείων δεν είναι μόνο γωνίες, αλλά και γωνίες με τη χαρακτηριστική τους κλίμακα στο scale-space. Η ιδέα πίσω από τη χρήση της normalized log προέρχεται από το τρισδιάστατο της σχήμα (το λεγόμενο μεξικάνικο καπέλο) όπως φαίνεται παρακάτω:




Σχήμα 29. Οπτικοποίηση του πυρήνα Laplacian-of-Gaussian (LoG).

Οπότε η κανονικοποιημένη LoG απόκριση μεγιστοποιείται στη μύτη του καπέλου της οποίας το μέγεθος εξαρτάται από τη κλίμακα σ . Οπότε συνελλίσσοντας την εικόνα με τον πυρήνα LoG σε διαφορετικές κλίμακες προσπαθούμε να βρούμε την κλίμακα εκείνη, εφόσον υπάρχει για κάθε σημείο, στην οποία το μέγεθος της μύτης του καπέλου είναι ίδιο με το μέγεθος του σημείου ενδιαφέροντος, δηλαδή η κατάλληλη κλίμακα που περιγράφει ένα


σημείο ενδιαφέροντος, οπότε τότε να μεγιστοποιείται η LoG απόκριση και να ικανοποιείται το παραπάνω κριτήριο γειτονικών κλίμακων. Να σημειωθεί ότι, η κανονικοποίηση με σ_i^2 είναι απαραίτητη καθώς χωρίς αυτήν, οι αποκρίσεις σε διαφορετικές κλίμακες δεν θα ήταν συγκρίσιμες, επειδή καθώς αυξάνεται το σ η Laplacian μειώνεται. Παρακάτω παρουσιάζονται οι χάρτες κανονικοποιημένης LoG απόκρισης και τα τελικά σημεία που διατηρούνται μετά τον έλεγχο μεγίστου ως προς την κλίμακα για τις δύο εικόνες.

Part 2.2.2 - solar.jpg (sigma_0=2.0, rho_0=2.5, s=1.5, N=4)



Σχήμα 30. Αναπαράσταση Harris-Laplacian ανά κλίμακα για τη solar.jpg. Η πρώτη γραμμή δείχνει την κανονικοποιημένη απόκριση LoG και η δεύτερη τα σημεία που διατηρούνται μετά τον έλεγχο μεγίστου ως προς την κλίμακα.

Part 2.2.2 - blood_cells.jpg (sigma_0=2.0, rho_0=2.5, s=1.5, N=4)




Σχήμα 31. Αντίστοιχη πολυκλιμακωτή οπτικοποίηση Harris-Laplacian για την blood_cells.jpg.

Σε σχέση με τα σημεία κάθε κλίμακας για τις δύο φωτογραφίες που παρουσιάστηκαν στο ερώτημα 2.2.1 παρατηρούμε ότι η διαδικασία επιλογής κλίμακας απορρίπτει αρκετά σημεία

που ήταν ισχυρά χωρικά αλλά όχι σταθερά στο scale-space, διατηρώντας μόνο τα πιο σταθερά interest points. Παρακάτω φαίνονται οι τελικοί χάρτες με τα σημεία Harris-Laplacian που προκύπτουν μετά τον έλεγχο μεγίστου ως προς την κλίμακα για τις δύο εικόνες, όπου φαίνεται ότι τα σημεία που διατηρούνται είναι πιο σταθερά και αντιπροσωπευτικά των σημαντικών γωνιών της εικόνας, ενώ ταυτόχρονα η κλίμακα που συνοδεύει κάθε σημείο αποτυπώνεται μέσω της ακτίνας του κύκλου που σχεδιάζεται γύρω από αυτό.

Part 2.2.2 - Final Harris-Laplacian points on solar.jpg


Total selected points: 284



Σχήμα 32. Τελικά σημεία Harris-Laplacian για την εικόνα solar.jpg.


Part 2.2.2 - Final Harris-Laplacian points on blood_cells.jpg

Total selected points: 318



Σχήμα 33. Τελικά σημεία Harris-Laplacian για την εικόνα blood_cells.jpg.

Συνολικά, η μεθοδολογία για να εντοπίσουμε γωνίες σε πολλαπλές κλίμακες μέσω της μεθόδου Harris-Laplacian συνοψίζεται από το παρακάτω διάγραμμα ροής:



Σχήμα 34. Pipeline του αλγορίθμου Harris-Laplacian. Αρχικά εφαρμόζεται ο ανιχνευτής Harris σε πολλαπλές κλίμακες για την εύρεση υποψήφιων γωνιών και παράλληλα υπολογίζεται η κανονικοποιημένη LoG απόκριση. Τελικά διατηρούνται μόνο τα σημεία των οποίων η LoG απόκριση μεγιστοποιείται ως προς τις γειτονικές κλίμακες.

2.3 Ανίχνευση Blobs σε Μία Κλίμακα

Στο επόμενο μέρος τη εργασίας, θα ασχοληθούμε με την ανίχνευση μιας άλλης κατηγορίας σημείων ενδιαφέροντος τα blobs, η οποία είναι μια γενίκευση της ανίχνευσης γωνιών σε δομές που ορίζονται ως περιοχές με κάποια ομοιογένεια που διαφέρουν σημαντικά από την γειτονιά τους, όπως κυκλικές ή ελλειπτικές περιοχές. Αν και οι γωνίες μπορούν να θεωρηθούν ως ειδική περίπτωση blobs, η ανίχνευση blobs απαιτεί διαφορετική προσέγγιση, καθώς οι δομές που αναζητούμε δεν έχουν έντονες μεταβολές σε μία μόνο διεύθυνση, αλλά σε όλες τις διευθύνσεις.

Γενικά, η διαδικασία που θα ακολουθήσουμε για την ανίχνευση blobs σε μία κλίμακα είναι παρόμοια με αυτήν της ανίχνευσης γωνιών, με τη διαφορά ότι το κριτήριο απόκρισης θα βασίζεται στην ορίζουσα του Hessian αντί για το κριτήριο Harris. Η διαδικασία περιλαμβάνει τα εξής βήματα:

2.3.1 Ορίζουσα του Hessian

Για τον εντοπισμό blobs, αντί του δομικού τανυστή χρησιμοποιήθηκαν οι δεύτερες μερικές παράγωγοι της εξομαλυμένης εικόνας:

$$L_{xx}(x, y; \sigma), \quad L_{xy}(x, y; \sigma), \quad L_{yy}(x, y; \sigma) \quad (17)$$

όπου

$$\begin{aligned} L_{xx}(x, y, \sigma) &= \frac{\partial^2}{\partial x^2} I_\sigma(x, y), \\ L_{yy}(x, y, \sigma) &= \frac{\partial^2}{\partial y^2} I_\sigma(x, y), \\ L_{xy}(x, y, \sigma) &= \frac{\partial^2}{\partial x \partial y} I_\sigma(x, y). \end{aligned} \quad (18)$$

οι οποίες υπολογίζονται αριθμητικά με επαναληπτική εφαρμογή της `numpy.gradient` πάνω στην εικόνα $I_\sigma = G_\sigma * I$ πάλι με $\sigma = 2$. Στον κώδικα, οι μικτές παράγωγοι L_{xy} υπολογίζονται με δύο ισοδύναμους τρόπους ($\partial_y(\partial_x I_\sigma)$ και $\partial_x(\partial_y I_\sigma)$) και στη συνέχεια γίνεται μέσος όρος των δύο εκτιμήσεων. Η επιλογή των παραγώγων 2ης τάξης αντί των 1ης τάξης που χρησιμοποιήθηκαν στην ανίχνευση γωνιών οφείλεται στο γεγονός ότι μας δίνουν καλύτερη εποπτεία για τη τοπική καμπυλότητα την οποία θέλουμε να εντοπίσουμε στα blobs [3]. Από αυτές σχηματίζεται ο πίνακας Hessian:

$$H(x, y) = \begin{bmatrix} L_{xx}(x, y; \sigma) & L_{xy}(x, y; \sigma) \\ L_{xy}(x, y; \sigma) & L_{yy}(x, y; \sigma) \end{bmatrix} \quad (19)$$

και ως κριτήριο απόκρισης λαμβάνεται η ορίζουσά του:

$$R(x, y) = \det(H(x, y)) = L_{xx}(x, y; \sigma)L_{yy}(x, y; \sigma) - L_{xy}(x, y; \sigma)^2 \quad (20)$$

Η ποσότητα αυτή είναι μεγάλη σε περιοχές όπου η ένταση μεταβάλλεται έντονα και στις δύο διευθύνσεις, δηλαδή σε δομές τύπου blob. Σε αντίθεση με το κριτήριο Harris, το οποίο είναι σχεδιασμένο να ευνοεί γωνίες, η ορίζουσα του Hessian ανταποκρίνεται καλύτερα σε συμπαγείς, σχεδόν ισότροπες φωτεινές ή σκοτεινές δομές.

2.3.2 Επιλογή Σημείων Blob


Η επιλογή των τελικών σημείων blob ακολουθεί ακριβώς την ίδια λογική με την ανίχνευση Harris: κρατούνται μόνο όσα pixels είναι τοπικά μέγιστα της $\det(H)$ στην ίδια δισκοειδή γειτονιά και ταυτόχρονα υπερβαίνουν σχετικό κατώφλι της μορφής

$$R(x, y) > \theta_{\text{blob}} R_{\text{max}} \quad (21)$$

με $\theta_{\text{blob}} = 0.005$ όπως στο προηγούμενο μέρος. Έτσι προκύπτει σύνολο σημείων $N \times 3$ με μορφή (x, y, σ) , ώστε να είναι συμβατό με τη `interest_points_visualization`.


Παρακάτω παρουσιάζονται οι χάρτες απόκρισης $\det(H)$ και τα τελικά blobs που προκύπτουν μετά από non-maximum suppression και καταφυγή για τις δύο εικόνες. Παρατηρούμε ότι ο ανιχνευτής Hessian ανταποκρίνεται έντονα στις σχεδόν κυκλικές δομές των κυττάρων στη `blood_cells.jpg`, όπως αναμένεται από έναν blob detector, ενώ στην `solar.jpg` εντοπίζει κυρίως τις μικρές φωτεινές ή σκοτεινές περιοχές που διαφέρουν από το φόντο τους πέρα από τις γωνίες, όπως στις διασταυρώσεις των πάνελ και τις σκιές τους. Αυτό μας δείχνει τη συμπληρωματική λογική των δύο ανιχνευτών: ο Harris είναι καλύτερος για γωνίες και ο Hessian για blobs και τους χρησιμοποιούμε ανάλογα με τη δομή που θέλουμε να εντοπίσουμε στην εικόνα.

Part 2.3 - solar.jpg (sigma=2.0, theta_blob=0.005)



Σχήμα 35. Αποτελέσματα της ενότητας 2.3 για την εικόνα `solar.jpg`. Αριστερά φαίνεται η απόκριση $\det(H)$ και δεξιά τα blobs που εντοπίστηκαν σε μία μόνο κλίμακα.

Part 2.3 - blood_cells.jpg (sigma=2.0, theta_blob=0.005)



Σχήμα 36. Αποτελέσματα της ενότητας 2.3 για την εικόνα `blood_cells.jpg`. Ο ανιχνευτής Hessian ανταποκρίνεται έντονα στις σχεδόν κυκλικές δομές των κυττάρων, όπως αναμένεται από έναν blob detector.

2.4 Πολυκλιμακωτή Ανίχνευση Blobs

Όμοια με την ανίχνευση γωνιών, η ανίχνευση blobs σε μία μόνο κλίμακα μπορεί να μην είναι αρκετή για να εντοπίσει όλες τις σημαντικές δομές τύπου blob σε μια εικόνα, καθώς διαφορετικά blobs μπορεί να είναι πιο εμφανή σε διαφορετικές κλίμακες. Για παράδειγμα, μικρά blobs μπορεί να είναι πιο ευδιάκριτα σε μικρές κλίμακες (μικρό σ), ενώ μεγαλύτερα blobs μπορεί να απαιτούν μεγαλύτερες κλίμακες (μεγάλο σ) για να ανιχνευθούν αποτελεσματικά. Οπότε, όπως και στην περίπτωση των γωνιών, η λύση είναι η ανάλυση στον χώρο των κλιμάκων (scale-space) με την πολυκλιμακωτή αναπαράσταση της εικόνας, ώστε να ανιχνεύσουμε blobs σε πολλαπλές κλίμακες και να επιλέξουμε τη πιο αντιπροσωπευτική για κάθε σημείο.


2.4.1 Hessian-Laplace

Για τη πολυκλιμακωτή ανίχνευση blobs χρησιμοποιούμε πάλι τις κλίμακες

$$\sigma_i = s^i \sigma_0, \quad i = 0, \dots, N-1 \quad (22)$$


με $\sigma_0 = 2.0$, $s = 1.5$ και $N = 4$. Οπότε πρακτικά τα αρχικά σημεία ενδιαφέροντος για κάθε κλίμακα επιλέγονται σύμφωνα με την μέθοδο του προηγούμενου ερωτήματος. Παρακάτω παρουσιάζονται οι χάρτες απόκρισης $\det(H)$ και τα αντίστοιχα blobs για κάθε κλίμακα πριν από το στάδιο επιλογής χαρακτηριστικής κλίμακας. Παρατηρούμε ότι καθώς αυξάνει το i , η εξομάλυνση γίνεται ισχυρότερη με αποτέλεσμα τη σταδιακή εξάλειψη των δομών υψηλής λεπτομέρειας και συχνότητας, με αποτέλεσμα να μετατοπίζεται το ενδιαφέρον του ανιχνευτή από λεπτομέρειες μικρής κλίμακας προς πιο μεγάλες δομές της εικόνας, όπως συμβαίνει και στην πολυκλιμακωτή ανίχνευση γωνιών.

Part 2.4.1 - solar.jpg (sigma_0=2.0, s=1.5, N=4)



Σχήμα 37. Πολυκλιμακωτή απόκριση $\det(H)$ και τα αντίστοιχα blobs για την solar.jpg πριν από το στάδιο επιλογής χαρακτηριστικής κλίμακας.

Part 2.4.1 - blood_cells.jpg (sigma_0=2.0, s=1.5, N=4)




Σχήμα 38. Πολυκλιμακωτή απόκριση $\det(H)$ και τα αντίστοιχα blobs για την blood_cells.jpg πριν από την επιλογή της τελικής χαρακτηριστικής κλίμακας.

Στη συνέχεια εφαρμόζεται το δεύτερο στάδιο Hessian-Laplace όπου για κάθε υποψήφιο blob ελέγχεται αν η κανονικοποιημένη LoG απόκριση, για τους ίδιους λόγους που εξηγήθηκαν στο 2.2.2, $\sigma_i^2 |LoG|$ είναι μέγιστη ως προς τις γειτονικές κλίμακες. Όσα σημεία δεν μεγιστοποιούν αυτή τη μετρική απορρίπτονται.


Παρακάτω παρουσιάζονται οι χάρτες κανονικοποιημένης LoG απόκρισης και τα τελικά blobs που διατηρούνται μετά τον έλεγχο μέγιστου ως προς την κλίμακα για τις δύο εικόνες:

Part 2.4 - solar.jpg (sigma_0=2.0, s=1.5, N=4)



Σχήμα 39. Hessien-Laplace ανά κλίμακα για την solar.jpg. Η πρώτη γραμμή δείχνει την κανονικοποιημένη LoG, ενώ η δεύτερη τα blobs που παραμένουν μετά την επιλογή χαρακτηριστικής κλίμακας.

Part 2.4 - blood_cells.jpg (sigma_0=2.0, s=1.5, N=4)




Σχήμα 40. Αντίστοιχη διαδικασία για την blood_cells.jpg. Ο ανιχνευτής Hessien-Laplace επιλέγει κυρίως τις σχεδόν κυκλικές δομές των κυττάρων στις κλίμακες όπου εμφανίζονται πιο σταθερές.

Όπως και στις γωνίες, η διαδικασία επιλογής κλίμακας με τη LoG απορρίπτει πολλά blobs που είχαν εντοπιστεί αρχικά αλλά η κλίμακα τους δεν ήταν σταθερή. Παρακάτω φαίνονται τα τελικά εντοπισμένα blobs για τις 2 εικόνες στις διαφορετικές κλίμακες όπου εντοπίστηκε το καθένα:

Part 2.4 - Final Hessian-Laplace blobs on solar.jpg


Total selected blobs: 782



Σχήμα 41. Τελικά blobs Hessian-Laplace για την εικόνα solar.jpg.


Part 2.4 - Final Hessian-Laplace blobs on blood_cells.jpg

Total selected blobs: 527



Σχήμα 42. Τελικά blobs Hessian-Laplace για την εικόνα blood_cells.jpg.

Παρατηρούμε από τις εικόνες ότι όπως και στην ανίχνευση γωνιών, έτσι και στη πολυκλιμακωτή ανίχνευση blobs, τα τελικά σημεία που διατηρούνται είναι πιο σταθερά και αντιπροσωπευτικά των σημαντικών δομών τύπου blob της εικόνας και κάθε σημείο αποτυπώνεται μέσω της ακτίνας του κύκλου που σχεδιάζεται γύρω από αυτό. Τέλος, όπως είχαμε αναφέρει και παραπάνω παρατηρούμε ότι ο ανιχνευτής Hessian-Laplace μας δίνει καλύτερα και πιο ρεαλιστικά αποτελέσματα στην εικόνα με τα κύτταρα η οποία περιέχει πολλές σχεδόν κυκλικές δομές όπως κύτταρα, ενώ στην εικόνα με τα πάνελ μπερδεύει τις εναλλαγές φωτεινότητας με blobs. Για αυτό ξαναεπισημαίνουμε ότι ανάλογα με το είδος των σχημάτων και των δομών που περιέχουν οι εικόνες πρέπει να χρησιμοποιούμε τον κατάλληλο ανιχνευτή. Συνολικά, η μεθοδολογία για να εντοπίσουμε blobs σε πολλαπλές κλίμακες μέσω της μεθόδου Hessian-Laplace συνοψίζεται από το παρακάτω διάγραμμα ροής:



Σχήμα 43. Pipeline του αλγορίθμου Hessian-Laplace. Αρχικά εφαρμόζεται ο ανιχνευτής Hessian σε πολλαπλές κλίμακες για την εύρεση υποψήφιων blobs και παράλληλα υπολογίζεται η κανονικοποιημένη LoG απόκριση. Τελικά διατηρούνται μόνο τα σημεία των οποίων η LoG απόκριση μεγιστοποιείται ως προς τις γειτονικές κλίμακες.

2.5 Έλεγχος Repeatability υπό Γεωμετρικούς Μετασχηματισμούς

Στο τελευταίο τμήμα του Μέρους 2 αξιολογήσαμε τη *repeatability* των ανιχνευτών interest points, δηλαδή το κατά πόσο οι ίδιοι ανιχνευτές εξακολουθούν να εντοπίζουν αντίστοιχα σημεία όταν η εικόνα υποστεί γνωστούς γεωμετρικούς μετασχηματισμούς. Ειδικότερα, αυτή η αναγκη προέκυψε από την ιδέα εύρεσης ενός τρόπου αξιολόγησης των αποτελεσμάτων των ανιχνευτών μας όπως είχαε κάνει και στο πρώτο μέρος θεωρώντας κάποιον αλγόριθμο εύρεσης αληθινών ακμών και μετά σύγκριση του με τα δικά μας αποτελέσματα. Ωστόσο, για τις γωνίες και τα blobs δεν υπάρχει κάποια παρόμοια ground truth μέθοδος, οπότε θεωρήσαμε κρίσιμο να αξιολογήσουμε την ευρωστία-robustness των ανιχνευτών μας οι οποίοι ιδανικά θα θέλαμε να είναι ανεξάρτητοι σε περιστροφές, μικρές παραμορφώσεις (αφινικούς μετασχηματισμούς) και αλλαγές στο μέγεθος-κλίμακα της εικόνας[3]. Οπότε για να αξιολογήσουμε την ευρωστία των ανιχνευτών μας χρησιμοποιήσαμε το μέτρο της επαναληψιμότητας-repeatability. Η repeatability είναι ιδιαίτερα σημαντική, διότι ένας ανιχνευτής που δίνει πολλά σημεία σε μία εικόνα αλλά αποτυγχάνει να τα επανεντοπίσει μετά από μετατόπιση, περιστροφή ή αλλαγή κλίμακας δεν είναι πρακτικά χρήσιμος για αντιστοίχιση εικόνων ή κατηγοριοποίηση με τοπικούς περιγραφητές.

Στον κώδικα, η repeatability υπολογίζεται από τη συνάρτηση `calculate_repeatability()`. Αν $\mathcal{P}_1$ είναι το σύνολο σημείων της αρχικής εικόνας και $\mathcal{P}_2$ το σύνολο σημείων της μετασχηματισμένης εικόνας, τότε:

$$\text{Repeatability} = \frac{n_{\text{matches}}}{\min(|\mathcal{P}_1|, |\mathcal{P}_2|)} \quad (23)$$

όπου n_{matches} είναι ο αριθμός των μοναδικών αντιστοιχίσεων μεταξύ των δύο συνόλων. Για να βρεθεί μια αντιστοίχιση, κάθε σημείο της αρχικής εικόνας προβάλλεται στην μετασχηματισμένη μέσω της γνωστής ομογραφίας H και συγκρίνεται με τα σημεία που ανιχνεύθηκαν στη δεύτερη εικόνα. Ένα ζεύγος θεωρείται έγκυρο όταν η ευκλείδεια απόσταση είναι μικρό-

τερη από `dist_thresh = 3 pixels` και ένα ποσοστό ανοχής 0.5 για τη τιμή της κλίμακας. Επιπλέον, κάθε σημείο της δεύτερης εικόνας μπορεί να χρησιμοποιηθεί το πολύ μία φορά, ώστε να αποφεύγονται πολλαπλές αντιστοιχίσεις στο ίδιο interest point.

Οπότε σκοπός μας είναι να παρατηρήσουμε αν οι ανιχνευτές μας είναι αναλλοίωτοι σε τέτοιους μετασχηματισμούς και να συγκρίνουμε τις μονοκλιμακωτές με τις πολυκλιμακωτές μεθόδους.

2.5.1 Μεθοδολογία Πειράματος

Το πείραμα εκτελέστηκε και στις δύο εικόνες του Μέρους 2, `solar.jpg` και `blood_cells.jpg`. Για κάθε εικόνα ανιχνεύθηκαν σημεία ενδιαφέροντος στην αρχική της μορφή και κατόπιν η ίδια εικόνα μετασχηματίστηκε με τρεις γνωστούς γεωμετρικούς μετασχηματισμούς:

1. **Translation:** μετατόπιση κατά (20, 15) pixels,
2. **Rotation:** περιστροφή κατά 45° γύρω από το κέντρο της εικόνας,
3. **Scaling:** σμίκρυνση με συντελεστή 0.5 γύρω από το κέντρο της εικόνας.

Για κάθε μία από τις τρεις αυτές περιπτώσεις εφαρμόστηκε ξανά ο ίδιος ανιχνευτής στη μετασχηματισμένη εικόνα και συγκρίθηκαν τα δύο σύνολα σημείων. Οι τέσσερις ανιχνευτές που αξιολογήθηκαν ήταν:

1. Harris,
2. Harris-Laplacian,
3. Hessian,
4. Hessian-Laplacian.

Οι παράμετροι του πειράματος είναι ακριβώς οι ίδιες με εκείνες που χρησιμοποιούνται στα προηγούμενα υποερωτήματα του μέρους 2.

2.5.2 Αποτελέσματα και Ερμηνεία

Τα αποτελέσματα του πειράματος συνοψίζονται στον Πίνακα 2, όπου παρουσιάζεται η repeatability για κάθε συνδυασμό εικόνας, μετασχηματισμού και ανιχνευτή:

Πίνακας 2. Αποτελέσματα repeatability για τις δύο εικόνες, τους τρεις μετασχηματισμούς και τους τέσσερις ανιχνευτές.

Εικόνα	Ανιχνευτής	Translation	Rotation	Scaling
solar.jpg	Harris	0.928	0.840	0.756
solar.jpg	Harris-Laplacian	0.877	0.692	0.507
solar.jpg	Hessian	0.935	0.748	0.606
solar.jpg	Hessian-Laplacian	0.934	0.720	0.554
blood_cells.jpg	Harris	0.910	0.855	0.591
blood_cells.jpg	Harris-Laplacian	0.901	0.822	0.384
blood_cells.jpg	Hessian	0.916	0.805	0.592
blood_cells.jpg	Hessian-Laplacian	0.873	0.714	0.422

Τα αποτελέσματα του πειράματος επιβεβαιώνουν καταρχάς ότι η **translation** είναι ο ευκολότερος μετασχηματισμός καθώς όλες οι μέθοδοι παρουσιάζουν πολύ υψηλή repeatability, περίπου 0.87--0.94. Αυτό είναι αναμενόμενο, καθώς η μετατόπιση δεν αλλάζει τη δομή της εικόνας, απλώς μετακινεί τα σημεία ενδιαφέροντος σε νέα θέση. Οι ανιχνευτές μας είναι σχεδιασμένοι να εντοπίζουν τοπικές δομές, οπότε η μετατόπιση δεν επηρεάζει την ικανότητά τους να τις εντοπίσουν.

Η **rotation** αποδεικνύεται δυσκολότερη καθώς όλες οι μέθοδοι κυμαίνονται με repeatability, περίπου 0.7--0.85. Αυτό οφείλεται στο γεγονός ότι η περιστροφή αλλάζει την προσανατολισμένη δομή των γωνιών και των blobs, με αποτέλεσμα αυτοί οι τοπικοί περιγραφητές να μην είναι τόσο αποτελεσματικοί. Παρ' όλα αυτά, οι ανιχνευτές μας δείχνουν ακόμα αρκετά καλή απόδοση, πάνω από 0.7 γεγονός που τους καθιστά αρκετά αξιόπιστους.

Η **scaling** είναι η πιο δύσκολη περίπτωση. Εδώ εμφανίζεται μικρότερη repeatability για όλους τους ανιχνευτές, η οποία κυμαίνεται περίπου από 0.4 έως 0.76. Αυτό οφείλεται στο γεγονός ότι η αλλαγή κλίμακας επηρεάζει σημαντικά τη δομή της εικόνας, καθώς τα blobs και οι γωνίες μπορεί να γίνουν πολύ μικρότερα ή μεγαλύτερα, με αποτέλεσμα να μην ανιχνεύονται εύκολα από τους ανιχνευτές που δεν είναι σχεδιασμένοι για να είναι scale-invariant.

Γενικά παρατηρούμε ότι οι μονοκλιμακωτοί ανιχνευτές υπερτερούν των πολυκλιμακωτών, γεγονός που υποδηλώνει ότι η διαδικασία επιλογής κλίμακας με τη LoG δεν είναι αρκετά αποτελεσματική για να διατηρήσει τα πιο σταθερά σημεία υπό αλλαγή κλίμακας. Αυτό μπορεί να οφείλεται στο γεγονός ότι η επιλογή της χαρακτηριστικής κλίμακας με βάση τη LoG μπορεί να απορρίπτει σημεία που είχαν εντοπιστεί αρχικά αλλά η κλίμακα τους δεν ήταν σταθερή, με αποτέλεσμα να μειώνεται η repeatability.

Συγκεντρωτικά, οι ανιχνευτές μας παρουσιάζουν αρκετά καλή απόδοση στο translation και στο rotation, αλλά στο scaling είναι προβληματικό. Αυτό υπογραμμίζει τη σημασία της επιλογής του κατάλληλου ανιχνευτή ανάλογα με τις απαιτήσεις της εφαρμογής μας και

τη φύση των εικόνων που επεξεργαζόμαστε.

3. Κατηγοριοποίηση Εικόνων με Χρήση Τοπικών Περιγραφητών και Χαρακτηριστικών από Βαθύ Νευρωνικό Δίκτυο

Στο τρίτο μέρος αξιολογείται η επίδοση διαφόρων μεθόδων εξαγωγής χαρακτηριστικών σε πρόβλημα κατηγοριοποίησης εικόνων από τη βάση Pascal VOC2005, με τρεις κλάσεις: αυτοκίνητο, άνθρωπος και ποδήλατο.

3.1 Κατηγοριοποίηση με τοπικούς περιγραφητές SURF και HOG

Το πείραμα αφορά τη κατηγοριοποίηση εικόνων των τριών κλάσεων cars, person και bike με χρήση των τοπικών περιγραφητών SURF (Speed Up Robust Features) και HOG (Histogram of Oriented Gradients). Στη συνέχεια, έγινε αναπαράσταση των περιγραφητών με τη τεχνική Bag-of-Words και ταξινόμηση με SVM, με χρήση της τεχνικής k-fold cross-validation με 5 folds. Ακολουθεί μια σύντομη περιγραφή των δύο μεθόδων εξαγωγής τοπικών χαρακτηριστικών που χρησιμοποιήθηκαν στο πείραμα:

Ο αλγόριθμος **HOG (Histogram of Oriented Gradients)** αποτυπώνει την τοπική γεωμετρία της εικόνας αναλύοντας την κατανομή των κλίσεων της έντασης. Ειδικότερα, η μέθοδος χωρίζει τη γειτονιά γύρω από το εκάστοτε σημείο ενδιαφέροντος σε ένα πλέγμα ομοιόμορφα κατανεμημένων κελιών. Στη συνέχεια, για κάθε pixel εντός του κάθε κελιού, υπολογίζει το μέτρο και τη γωνία του κατευθυνόμενου gradient της φωτεινότητας με χρήση των παρακάτω σχέσεων:

- Μέτρο: $Magnitude(x, y) = \sqrt{I_x^2 + I_y^2}$

- Γωνία: $Angle(x, y) = \arctan\left(\frac{I_y}{I_x}\right)$

Έπειτα, για κάθε κελί σχηματίζεται ένα τοπικό ιστόγραμμα, όπου το κάθε pixel ψηφίζει στο bin που αντιστοιχεί η γωνία του gradient και με τιμή το μέτρο του gradient, σε αυτό το pixel. Αφού έχει σχηματιστεί το ιστόγραμμα για κάθε κελί, εφαρμόζεται κανονικοποίηση για να γίνει ο περιγραφητής ανθεκτικός σε αλλαγές φωτεινότητας και αντίθεσης. Τέλος, τα ιστόγραμματα όλων των κελιών συνενώνονται σε ένα ενιαίο διάνυσμα που αποτελεί τον HOG περιγραφητή για το συγκεκριμένο σημείο ενδιαφέροντος. Συμπερασματικά, Ο HOG είναι ιδιαίτερα αποτελεσματικός στην αναγνώριση αντικειμένων με ιδιαίτερα γεωμετρικά χαρακτηριστικά και σχήμα όπως έντονες ακμές και γωνίες καθώς καταγράφει το σχήμα (shape) και τις εξωτερικές ακμές ενός αντικειμένου ενώ είναι ανθεκτικός σε μικρές παραμορφώσεις και αλλαγές φωτεινότητας.

Ένα από τα βασικά χαρακτηριστικά του **SURF (Speeded Up Robust Features)** είναι ότι περιστροφικά ανεξάρτητος (rotation invariance). Ειδικότερα, το επιτυγχάνει αυτό αποδίδοντας έναν κύριο προσανατολισμό σε κάθε σημείο ενδιαφέροντος, βάσει των τοπικών

αποκρίσεων της γειτονιάς του, με αποτέλεσμα να μην εξαρτάται από περιστροφές. Στη συνέχεια, χωρίζει τη γειτονιά γύρω από το σημείο ενδιαφέροντος σε ένα πλέγμα και σε κάθε υπομήμημα του πλέγματος υπολογίζει το άθροισμα των αποκρίσεων των παραγώγων: $\sum d_x$, $\sum d_y$, $\sum |d_x|$ και $\sum |d_y|$, συμπυκνώνοντας τη πληροφορία της τοπικής περιγραφής σε ένα πολύ μικρότερο διάνυσμα, 4 διαστάσεων για κάθε υπομήμημα του πλέγματος, σε σχέση με τα ιστογράμματα υψηλότερης διάστασης του HOG. Συμπερασματικά, ο SURF είναι πιο αποδοτικός υπολογιστικά και περιγράφει ιδανικά τις τοπικές μεταβολές φωτεινότητας και την υφή της εικόνας, παραμένοντας ανθεκτικός σε περιστροφές.

3.1.1 Ανιχνευτές Σημείων και Τοπικοί Περιγραφητές

Καταρχάς, για κάθε εικόνα και από κάθε κλάση εξάγουμε τα χαρακτηριστικά με βάση τα οποία θα γίνει η κατηγοριοποίηση. Για να το κάνουμε αυτό, χρησιμοποιούμε τη συνάρτηση `FeatureExtraction(...)` η οποία δέχεται σαν ορίσματα μια συνάρτηση του ανιχνευτή και μία συνάρτηση τοπικού περιγραφιτή. Ειδικότερα, οι συναρτήσεις ανιχνευτών που δοκιμάσαμε είναι οι πολυκλιμακωτές εκδοχές Harris-Laplacian και Hessian-Laplacian όπως εκείνες έχουν υλοποιηθεί στο δεύτερο μέρος και δέχονται σαν ορίσματα την εικόνα και τις παραμέτρους και επιστρέφουν έναν πίνακα $N \times 3$ με τα σημεία ενδιαφέροντος και τη χαρακτηριστική κλίμακα. Ως συναρτήσεις τοπικών περιγραφητών χρησιμοποιήθηκαν οι δοθείσες `featuresSURF(I, points)` και `featuresHOG(I, points)`, οι οποίες δέχονται την εικόνα τον παραπάνω πίνακα σημείων ενδιαφέροντος και επιστρέφουν ένα διάνυσμα ή ιστόγραμμα με τα χαρακτηριστικά κάθε τέτοιου σημείου. Συνολικά, η `FeatureExtraction(...)` αναλαμβάνει να διαβάσει όλο το dataset με όλες τις εικόνες από κάθε κλάση, να εφαρμόσει κάποιο distortion ενδεχομένως, να τις κάνει grayscale και να εφαρμόσει ορισμένους μετασχηματισμούς όπως normalization και resizing 50%. Στη συνέχεια, εφαρμόζει στην εικόνα τις συναρτήσεις ανίχνευσης και περιγραφής, όπως τις είδαμε παραπάνω και αποθηκεύει τους περιγραφητές ανά κλάση και εικόνα. Τέλος, οι περιγραφητές που προκύπτουν από κάθε εικόνα έχουν μεταβλητό πλήθος, ανάλογα με το πόσα σημεία ενδιαφέροντος εντοπίστηκαν, και αυτό θα πρέπει να ληφθεί υπόψη στο επόμενο στάδιο της κατηγοριοποίησης. Να σημειωθεί, ότι με τη δυνατότητα `saveFile`, `loadFile` μπορέσαμε να αποθηκεύσουμε τοπικά την χρονοβόρα διαδικασία εξαγωγής χαρακτηριστικών για αποδοτική αναπαραγωγή και αξιοποίηση των αποτελεσμάτων.

3.1.2 Δημιουργία Train/Test sets - Bag-of-Words και Εκπαίδευση Ταξινομητή

Η δημιουργία training/test συνόλων γίνεται από τη `createTrainTest()`, η οποία φορτώνει από το `Fold_Indices.mat` τα προκαθορισμένα indices του εκάστοτε fold. Για κάθε κλάση εφαρμόζεται διαχωρισμός περίπου 70%/30% και στη συνέχεια ενώνονται τα δείγματα όλων των κλάσεων στα τελικά σύνολα training και testing.

Όπως προαναφέραμε κάθε εικόνα δίνει διαφορετικό αριθμό τοπικών descriptors, οπότε απαιτείται μετασχηματισμός σε διάνυσμα σταθερού μήκους πριν από την ταξινόμηση. Αυτό γίνεται μέσω της `BagOfWords()`. Η συνάρτηση συγκεντρώνει όλους τους training descriptors σε έναν κοινό πίνακα, ανακατεύει τυχαία τα στοιχεία και χρησιμοποιεί το

50% αυτού του συνόλου(`slice_ratio = 0.5`) και δημιουργεί το οπτικό λεξικό με τον αλγόριθμο συσταδοποίησης `kmeans` με `num_centers = 500` τα οποία γίνονται initialized τυχαία ώστε να καταλήξουμε σε διανύσματα σταθέρου μήκους για όλα τα δεδομένα, τα λεγόμενο global διανύσματα κοινού μήκους.

Μετά την εκπαίδευση του οπτικού λεξικού, για κάθε εικόνα του συνόλου `train` και `test` υπολογίζουμε την ελάχιστη ευκλείδεια απόσταση του κάθε τοπικού περιγραφητή από τα κέντρα που υπολογίστηκαν προηγουμένως. Στη συνέχεια ,για κάθε εικόνα σχηματίζεται ένα ιστόγραμμα 500 διαστάσεων, που προκύπτει από τη συχνότητα εμφάνισης των οπτικών λέξεων του λεξικού. Τέλος, το ιστόγραμμα κανονικοποιείται με L2 νόρμα για λόγους ομοιομορφίας. Προφανώς, τα τελικά global διανύσματα 500 διαστάσεων που προκύπτουν είναι συνήθως αρκετά αραιά(`sparse`), καθώς κάθε εικόνα έχει σχετικά λίγους τοπικούς περιγραφητές σε σύγκριση με το μέγεθος του λεξικού. Αυτό είναι πολύ θετικό καθώς είναι υπολογιστικά αποδοτικό για τον ταξινομητή.

Η ταξινόμηση υλοποιείται με έναν ταξινομητή `Support Vector Machine (SVM)` μέσα από τη συνάρτηση `svm()`, κατάλληλα προσαρμοσμένος για πολλαπλές κλάσεις αφού έχουμε 3 κλάσεις. Στο τέλος , υπολογίζεται το `accuracy` για κάθε fold (`k(5)-fold cross-validation`) και αναφέρεται ο μέσος όρος των 5 folds ως τελικό αποτέλεσμα-mean accuracy.

3.1.3 Μεθοδολογία Πειράματος

Εξετάστηκαν οι τέσσερις βασικοί συνδυασμοί `detector--descriptor`:

1. Harris-Laplacian + SURF,
2. Harris-Laplacian + HOG,
3. Hessian-Laplacian + SURF,
4. Hessian-Laplacian + HOG.

Επιπλέον, πειραματικά υλοποιήθηκαν και τρία μοντέλα `late fusion`, όπου συνενώνονται δύο BoVW διανύσματα($500+500=1000$ διαστάσεων) πριν από τον ταξινομητή και όχι πριν το BoVW για αυτό χαρακτηρίζονται ως `late` . Η ιδέα πίσω από τα `late fusion` πειράματα είναι ότι η συνένωση διαφορετικών BoVW αναπαραστάσεων μπορεί να προσφέρει συμπληρωματική πληροφορία και θέλουμε να εξετάσουμε αν αυτό μπορεί να βελτιώσει την απόδοση της κατηγοριοποίησης. Συγκεκριμένα, τα τρία `late fusion` πειράματα είναι:

1. Harris-SURF + Hessian-SURF,
2. Harris-HOG + Hessian-SURF,
3. Hessian-SURF + Hessian-HOG.

Το πρώτο late fusion πείραμα συνενώνει τα BoVW διανύσματα των δύο SURF ανιχνευτών και χρησιμοποιήθηκε γιατί όπως φάνηκε εκ των υστέρων στην ανάλυση μας ο SURF περιγραφητής έδωσε καλύτερα αποτελέσματα για το σύνολο δεδομένων. Οπότε ενσωματώνοντας τις πληροφορίες από τους 2 ανιχνευτές, θέλαμε να εξετάσουμε αν μπορούμε να βελτιώσουμε ακόμα περισσότερο την απόδοση. Το δεύτερο συνενώνει το HOG του Harris με το SURF του Hessian και χρησιμοποιήθηκε γιατί ο Harris ανιχνευτής ανιχνεύει καλύτερα τις γωνίες τις οποίες περιγράφει καλύτερα ο HOG, ενώ ο ανιχνευτής Hessian ανιχνεύει καλύτερα τα blobs που αποτελούνται από έντονες μεταβολές της φωτεινότητας τα οποία περιγράφει καλύτερα ο SURF, οπότε η συνένωση αυτή μπορεί να προσφέρει συμπληρωματική πληροφορία. Τέλος, το τρίτο συνενώνει το SURF και το HOG του Hessian γιατί ο Hessian ανιχνευτής έδωσε καλύτερα αποτελέσματα από τον Harris, οπότε θέλαμε να εξετάσουμε αν μπορούμε να βελτιώσουμε ακόμα περισσότερο την απόδοση συνενώνοντας τους δύο περιγραφητές που βασίζονται στον ίδιο ανιχνευτή.

Επίσης, για όλες τις παραπάνω μεθόδους έγινε σάρωση της παραμέτρου κλίμακας για να δούμε και την επίδραση της κλίμακας και την εύρεση της καλύτερης τιμής. Η σάρωση έγινε για

$$s \in \{1.0, 1.2, 1.5, 1.8, 2.0\}.$$

Για κάθε τιμή του s εκτελείται εξαγωγή χαρακτηριστικών, δημιουργία BoVW λεξικού, 5-fold αξιολόγηση και καταγραφή χρόνου εξαγωγής χαρακτηριστικών. Τέλος, θέσαμε στάθερο $\text{RANDOMSEED} = 42$ για την επαναληπτικότητα των αποτελεσμάτων.

Τελικά, έγινε σύγκριση των αποτελεσμάτων όλων των συνδυασμών και των late fusion πειραμάτων, τόσο σε επίπεδο accuracy όσο και σε επίπεδο χρόνου εξαγωγής χαρακτηριστικών, για να εξαχθούν συμπεράσματα σχετικά με την καλύτερη μέθοδο τόσο από άποψη απόδοσης όσο και από άποψη υπολογιστηρότητας και ταχύτητας, και τις επιπτώσεις της παραμέτρου κλίμακας.


3.1.4 Αποτελέσματα Πειράματος

Ο Πίνακας 3 συνοψίζει τα accuracies που καταγράφηκαν για όλους τους συνδυασμούς του Μέρους 3.1, μαζί με τα late-fusion πειράματα.

Πίνακας 3. Μέσο 5-fold accuracy (%) για όλους τους συνδυασμούς του Μέρους 3.1.

Μέθοδος	$s = 1.0$	$s = 1.2$	$s = 1.5$	$s = 1.8$	$s = 2.0$
Harris-Laplacian + SURF	72.69	70.62	73.10	72.41	69.93
Harris-Laplacian + HOG	61.24	60.97	64.83	64.28	63.86
Hessian-Laplacian + SURF	72.97	73.66	74.34	73.93	74.90
Hessian-Laplacian + HOG	63.17	65.66	64.55	65.93	65.24
Late fusion: Harris-SURF + Hessian-SURF	75.03	74.48	76.14	75.31	74.48
Late fusion: Harris-HOG + Hessian-SURF	73.52	73.38	75.59	74.07	75.17
Late fusion: Hessian-SURF + Hessian-HOG	73.10	73.66	74.90	73.24	75.31

Τα αποτελέσματα φαίνονται και πιο παραστατικά στο παρακάτω σχήμα, όπου παρουσιάζεται η accuracy ως προς τον λόγο κλιμάκων s για όλους τους συνδυασμούς :




Σχήμα 44. Accuracy ως προς τον λόγο κλιμάκων s για όλους τους συνδυασμούς που υλοποιεί το part3_1.py.

Συνεχίζοντας , προκειμένου να μπορούμε να κάνουμε μια ολοκληρωτική ανάλυση σχετικά με την απόδοση των μεθόδων ,τα αποτελέσματα των χρώων εξαγωγής χαρακτηριστικών για όλες τις μεθόδους φαίνονται στον παρακάτω πίνακα και πιο παραστατικά στο σχήμα που ακολουθεί:


Πίνακας 4. Χρόνος εξαγωγής χαρακτηριστικών (s) για όλους τους συνδυασμούς του Μέρους 3.1.

Μέθοδος	$s = 1.0$	$s = 1.2$	$s = 1.5$	$s = 1.8$	$s = 2.0$
Harris-Laplacian + SURF	104.83	145.86	220.84	391.41	596.23
Harris-Laplacian + HOG	124.33	151.22	223.49	397.30	597.13
Hessian-Laplacian + SURF	70.41	95.74	170.34	337.21	573.98
Hessian-Laplacian + HOG	112.63	106.93	184.88	351.98	558.27
Late fusion: Harris-SURF + Hessian-SURF	175.24	241.60	391.17	728.62	1170.22
Late fusion: Harris-HOG + Hessian-SURF	194.75	246.96	393.83	734.52	1171.11
Late fusion: Hessian-SURF + Hessian-HOG	183.05	202.67	355.21	689.19	1132.25




Σχήμα 45. Χρόνος εξαγωγής χαρακτηριστικών ως προς το s για όλους τους συνδυασμούς του Μέρους 3.1.

Τέλος, παρατίθενται οι confusion matrices για τις 4 βασικές μεθόδους για όλες τις τιμές του s προκειμένου να εντοπίσουμε σε ποια κλάση γίνονται οι περισσότερες λανθασμένες ταξινομήσεις (κλάση 0 = person, κλάση 1 = car, κλάση 2 = bike):



Σχήμα 46. Confusion matrices για $s = 1.0$ και $s = 1.2$.

Σχήμα 47. Confusion matrices για $s = 1.5$, $s = 1.8$ και $s = 2.0$.

3.1.5 Σύνοψη και Ερμηνεία Αποτελεσμάτων

Σύγκριση HOG vs SURF: Το βασικό συμπέρασμα είναι ότι ο περιγραφητής SURF υπερέχει σταθερά του HOG, ανεξάρτητα από τον ανιχνευτή και τη κλίμακα. Ειδικότερα, όπως αναμέναμε και από τη θεωρητική ανάλυση των δύο περιγραφητών, ο SURF είναι ένας πιο αποδοτικός αλγόριθμος ο οποίος λόγω των χαμηλότερης διάστασης διανυσμάτων που παράγει είναι ταχύτερος στη διαδικασία εξαγωγής χαρακτηριστικών όπως φαίνεται και από τον πίνακα 4 για όλες τις κλίμακες και τους ανιχνευτές. Επίσης, από τον πίνακα 3 και το σχήμα 1 φαίνεται η ξεκάθαρη υπεροχή του SURF (70-75%) σε σχέση με τον HOG (60-66%) αναφορικά με το mean accuracy με διαφορά που κυμαίνεται στο 15% περίπου, γεγονός που υποδηλώνει ότι ο SURF περιγραφητής είναι πιο κατάλληλος για το συγκεκριμένο σύνολο δεδομένων και πρόβλημα κατηγοριοποίησης. Αυτό μπορεί να οφείλεται στο γεγονός ότι η πολυδιαστατικότητα του HOG δεν συνεισφέρει στην εύρεση βέλτιστων κεντών για το οπτικό λεξικό καθώς και στη πολυπλοκότητα των πραγματικών εικόνων που εξετάζουμε όπου το περίγραμμα που εξετάζει ο HOG δεν αποδίδει τόσο καλά όσο η υφή και τα τοπικά μοτίβα του SURF. Τέλος, για τον SURF ο καλύτερος συνδυασμός επιτυγχάνεται από το **Hessian-Laplacian + SURF** με **74.90%** για $s = 2.0$ και για τον HOG, ο **Harris-Laplacian + HOG** ακολουθεί χαμηλότερα, με **65.93%** για $s = 1.8$.

Η επίδραση της κλίμακας s : Ο πίνακας 3 επιβεβαιώνει ότι η παράμετρος s επηρεάζει μεν την απόδοση, αλλά όχι δραματικά. Γενικά, δεν μπορούμε να εξάγουμε ένα μονοσήματο συμπέρασμα για την επίδραση της κλίμακας s στην απόδοση. Αυτό που παρατηρούμε γενικά είναι ότι ο Harris-Laplacian επωφελείται από την αύξηση του λόγου κλίμακας μέχρι ένα σημείο στο 1.5 γεγονός αναμενόμενο, καθώς το έντονο Gaussian blur αλλοιώνει (στρογγυλοποιεί) τις γωνίες ενώ ο Hessian-Laplacian παρατηρούμε ότι αυξάνεται μαζί με τη κλίμακα καθώς τα blobs έχουν μεγαλύτερη ανθεκτικότητα στην εξομάλυνση. Παρόλα αυτά, παρατηρούμε από τον πίνακα 4 και το σχήμα 2 ότι η αύξηση του s συνεπάγεται σημαντική αύξηση του χρόνου εξαγωγής χαρακτηριστικών λόγω της αύξησης των διαστάσεων των φίλτρων και της πολυπλοκότητας των συνελίξεων, γεγονός που υποδηλώνει ότι η βελτίωση της απόδοσης δεν είναι πάντα ανάλογη με το επιπλέον υπολογιστικό κόστος. Συνεπώς, το $s = 1.5$ παραμένει ένα ισχυρό σημείο λειτουργίας με

παρόμοια επίδοση και χαμηλότερο κόστος, άρα είναι επίσης αντιπροσωπευτική επιλογή για ποιοτική ανάλυση και αυτό θα χρησιμοποιήσουμε στο ερώτημα 3.2.5.

Το πείραμα των late-fusion περιγραφητών: Τα late-fusion πειράματα δίνουν οριακά καλύτερα αποτελέσματα από τους βασικούς συνδυασμούς, αλλά όχι θεαματική βελτίωση. Η καλύτερη συνολική τιμή του πειράματος είναι **76.14%** για τον συνδυασμό Harris-SURF + Hessian-SURF στο $s = 1.5$. Παρόλα αυτά, η αύξηση της απόδοσης δεν είναι ανάλογη με το επιπλέον υπολογιστικό κόστος, καθώς οι χρόνοι εξαγωγής για τα late-fusion πειράματα είναι σχεδόν διπλάσιοι από τους βασικούς συνδυασμούς. Οπότε, ενώ γενικά η συνένωση διαφορετικών BoVW αναπαραστάσεων μπορεί να προσφέρει συμπληρωματική πληροφορία αυξάνοντας ελαφρώς την απόδοση των ταξινομητών μας, το επιπλέον υπολογιστικό κόστος που συνεπάγεται δεν δικαιολογεί αυτή τη μικρή βελτίωση ειδικά σε εφαρμογές όπου ο χρόνος απόκρισης είναι κρίσιμος.

Ανάλυση των confusion matrices: Γενικά, παρατηρούμε ότι οι confusion matrices για όλες τις μεθόδους μας δίνουν παρόμοια κατανομή ταξινομήσεων και συμπεραίνουμε ότι οι περισσότερες λανθασμένες ταξινομήσεις γίνονται στη κλάση person ενδεχομένως λόγω της μεγαλύτερης ποικιλίας στάσεων και εμφανίσεων των ανθρώπων σε σχέση με τα αυτοκίνητα και τα ποδήλατα, ενώ η κλάση των αυτοκινήτων εμφανίζει λιγότερες λανθασμένες ταξινομήσεις λόγω του συγκεκριμένου περιγράμματος της. Προφανώς, το σύνολο δεδομένων μας είναι αρκετά περιορισμένο για να εξάγουμε πολύ καλύτερα αποτελέσματα ωστόσο θα αναμέναμε ότι αν προσθέταμε ένα μεγαλύτερο βάρος στη κλάση person κατά την εκπαίδευση του SVM θα μπορούσαμε να βελτιώσουμε την απόδοση μας σε αυτή την κλάση.

3.2 Κατηγοριοποίηση με Χαρακτηριστικά από Συνελικτικό Νευρωνικό Δίκτυο

3.2.1 Φόρτωση Μοντέλου και Προεπεξεργασία Εικόνων

Φορτώθηκε το MobileNetV3-Small [7], ένα νευρωνικό δίκτυο φτιαγμένο από τη Google, μέσω της `torchvision.models.mobilenet_v3_small` με προ-εκπαιδευμένα βάρη IMAGENET1K_V1. Η αρχιτεκτονική σχεδιάστηκε για αποδοτικό inference σε συσκευές edge, καθώς συνδυάζει:

- **Depthwise separable convolutions:** Τεχνική που σπάει την κλασική συνέλιξη σε δύο στάδια: μια *depthwise* (επεξεργασία ανά κανάλι) και μια *pointwise* (1×1 μίξη), μειώνοντας δραστικά τις παραμέτρους και το υπολογιστικό κόστος.
- **Inverted residual blocks με squeeze-and-excitation:** Blocks που επεκτείνουν, επεξεργάζονται και συμπιέζουν τα κανάλια, με residual σύνδεση. Στα βαθύτερα στρώματα προστίθεται ένας μηχανισμός προσοχής (ο Squeeze and Excitation) που λειτουργεί ως ρυθμιστής έντασης των καναλιών βάσει global context.

- **Hard-swish activation:** Προσέγγιση της swish με $\text{h-swish}(x) = x \cdot \text{ReLU6}(x + 3)/6$, που είναι υπολογιστικά φθηνότερη καθώς αποφεύγει τον υπολογισμό sigmoid.

Μέσω της μεθόδου `named_modules()` επισκοπήθηκε η δομή του δικτύου. Η αρχιτεκτονική αποτελείται από δύο κύρια μέρη:

- **features:** μια αλυσίδα 13 στρωμάτων (`features.0–features.12`), κάθε ένα αποτελούμενο από `InvertedResidual` blocks. Κάθε block περιλαμβάνει `depthwise convolution`, `batch normalization`, `hard-swish` ή `ReLU` ενεργοποίηση και, στα βαθύτερα στρώματα, `squeeze-and-excitation modules`.
- **classifier:** δύο γραμμικά στρώματα με `hardswish` και `dropout`, που εκτελούν την τελική ταξινόμηση σε 1000 κλάσεις ImageNet.

Ανάμεσα στα δύο παρεμβάλλεται το `avgpool` (adaptive average pooling), που συμπύσσει τους χωρικούς χάρτες σε διάνυσμα 576 διαστάσεων. Στο δικό μας πείραμα transfer learning, το τμήμα `classifier` δεν χρησιμοποιείται — αντ' αυτού, κρατάμε την έξοδο του `avgpool` ως το feature vector που θα δώσουμε σαν είσοδο στον ταξινομητή μας.

Κάθε εικόνα φορτώθηκε ως RGB tensor και υπέστη την προεπεξεργασία που δίνει η `weights.transforms()`: `resize`, `crop` σε 224×224 και κανονικοποίηση με τα στατιστικά του ImageNet. Η αλυσίδα κανονικοποίησης αυτή αποθηκεύεται μαζί με τα βάρη, εξασφαλίζοντας συμβατότητα με τις συνθήκες εκπαίδευσης.

3.2.2 Εξαγωγή Χαρακτηριστικών

Αντί να χρησιμοποιηθεί η έξοδος του τελικού επιπέδου ταξινόμησης (1000 κλάσεις ImageNet), απομονώθηκε η έξοδος του επιπέδου `avgpool` μέσω του εργαλείου `create_feature_extractor` της `torchvision`. Το `avgpool` εφαρμόζει `global average pooling` στους χωρικούς χάρτες ενεργοποίησης, παράγοντας ένα διάνυσμα 576 διαστάσεων για κάθε εικόνα. Το `global average pooling` έχει το επιπλέον πλεονέκτημα ότι παρέχει εγγενή ανθεκτικότητα σε χωρικές μεταβολές, τις οποίες θα εξετάσουμε και στη συνέχεια, αφού συνοψίζει τη σημασιολογική πληροφορία κάθε καναλιού σε έναν αριθμό.

Τέλος το μοντέλο τέθηκε σε κατάσταση αξιολόγησης (`model.eval()`) ώστε να απενεργοποιηθούν τα `Dropout` και να σταθεροποιηθεί η `BatchNorm`.


3.2.3 Δημιουργία Συνόλων Δεδομένων, Εκπαίδευση Ταξινομητή και Αξιολόγηση

Για τη δημιουργία των συνόλων εκπαίδευσης/δοκιμής χρησιμοποιήθηκε η έτοιμη συνάρτηση `createTrainTest()` από τα `utils` του Μέρους 3.1, η οποία φορτώνει τα προκαθορισμένα `fold indices` από το `Fold_Indices.mat` και χωρίζει τα δεδομένα σε αναλογία 70%/30%. Με τον τρόπο αυτό εξασφαλίζεται ομοιομορφία στην αξιολόγηση μεταξύ των δύο μερών της εργασίας.

Πραγματοποιήθηκε **5-fold cross-validation**: σε κάθε fold, τα χαρακτηριστικά 576 διαστάσεων κανονικοποιήθηκαν μέσω του `StandardScaler` και ταξινομήθηκαν με τη συνάρτηση

`svm()` των `utils` (η οποία πρόκειται για γραμμικό SVM, $C = 1$, στρατηγική one-vs-rest). Η μέση ακρίβεια στα 5 folds ήταν **94.34%** ($\pm 1.47\%$).

Για τη λεπτομερέστερη ανάλυση που ακολουθεί (σύγκριση μεθόδων, ανθεκτικότητα, Grad-CAM), κρατήθηκε το **τελευταίο fold** (fold 5), στο οποίο η ακρίβεια του baseline (frozen + linear SVM) ήταν **96.55%**. Ο παρακάτω Confusion Matrix (μέσος όρος των 5 folds) δείχνει ότι οι λανθασμένες ταξινομήσεις είναι ομοιόμορφα κατανεμημένες μεταξύ κλάσεων, χωρίς συστηματική σύγχυση ανάμεσα σε συγκεκριμένα ζεύγη.




Σχήμα 48. Confusion Matrix του MobileNetV3-Small + SVM στο test set. Κάθε γραμμή αντιστοιχεί στην αληθινή κλάση και κάθε στήλη στην προβλεπόμενη.

Η υψηλή ακρίβεια επιβεβαιώνει ότι τα χαρακτηριστικά `avgpool` του MobileNetV3 είναι επαρκώς διακριτικά ακόμη και για κλάσεις που δεν υπήρχαν στο ImageNet ως ξεχωριστές κατηγορίες, ακόμα και με απλό γραμμικό SVM. Αυτό οφείλεται στο ότι το δίκτυο έχει μάθει γενικές αναπαραστάσεις σχήματος, υφής και δομής, οι οποίες μεταφέρονται αποτελεσματικά μέσω transfer learning.


3.2.4 Οπτικοποίηση Ενεργοποιήσεων Ενδιάμεσων Επιπέδων (Feature Maps)

Για να κατανοηθεί τι αναπαριστούν τα χαρακτηριστικά σε κάθε βάθος του δικτύου, οπτικοποιήθηκαν τα πρώτα 3 κανάλια χαρτών ενεργοποίησης από τα επίπεδα `features.1`, `features.3`, `features.6` και `features.12`, για ένα αντιπροσωπευτικό δείγμα κάθε κλάσης.




Σχήμα 49. Χάρτες ενεργοποίησης (3 κανάλια) για τα επίπεδα `layer_1`, `layer_3`, `layer_6`, `layer_12` για τη κλάση: `car`.

Στο `layer_1` διακρίνεται καθαρά το περίγραμμα του αυτοκινήτου: οι ακμές του καπό, ο προφυλακτήρας και η πινακίδα φαίνονται ως έντονες αντιθέσεις. Από την άλλη, στο `layer_12` η ενεργοποίηση συγκεντρώνεται σε λίγα pixels που αντιστοιχούν στο κεντρικό σώμα του αυτοκινήτου, αγνοώντας πλήρως το background.



Σχήμα 50. Χάρτες ενεργοποίησης (3 κανάλια) για τα επίπεδα layer_1, layer_3, layer_6, layer_12 για τη κλάση: person.

Στο layer_1 φαίνονται ακμές από τα πρόσωπα και τα άκρα των ανθρώπων μέσα σε ένα πολύπλοκο background. Στο layer_6 οι ενεργοποιήσεις γίνονται πιο επιλεκτικές, τονίζοντας τις περιοχές με ανθρώπινα χαρακτηριστικά. Στο layer_12 παρατηρείται ένα μεγάλο block ενεργοποίησης (ειδικά στο ch2) που καλύπτει ολόκληρη την περιοχή που όντως βρίσκεται ένας άνθρωπος, δείχνοντας ότι το δίκτυο αναγνωρίζει τη σημασιολογική κατηγορία της κλάσης "person" σε επίπεδο περιοχής.



Σχήμα 51. Χάρτες ενεργοποίησης (3 κανάλια) για τα επίπεδα layer_1, layer_3, layer_6, layer_12 για τη κλάση: bike.

Στο layer_1 φαίνονται οι ακμές του πλαισίου και των τροχών του ποδηλάτου. Στο layer_3 οι ενεργοποιήσεις γίνονται πιο θολές αλλά διατηρούν τη γενική δομή. Στο layer_12 η ενεργοποίηση συγκεντρώνεται σε μια οριζόντια ζώνη που αντιστοιχεί στο ποδήλατο, με έντονα κίτρινα pixels, σημάδι ότι το δίκτυο έχει εντοπίσει το αντικείμενο και αγνοεί το υπόλοιπο της εικόνας.

Συνολικά, παρατηρείται σαφής ιεραρχική δομή: τα πρώτα επίπεδα ανιχνεύουν ακμές και τοπικές αντιθέσεις, τα μεσαία κωδικοποιούν υφές και μέρη αντικειμένων, και τα βαθύτερα δείχνουν αραιές ενεργοποιήσεις εστιασμένες στο αντικείμενο ενδιαφέροντος. Οι χάρτες του layer_12 διαφέρουν ποιοτικά μεταξύ κλάσεων, δικαιολογώντας τη διακριτική ισχύ των avgpool χαρακτηριστικών που εξάγουμε.

3.2.5 Πειράματα Ανθεκτικότητας

Για να αξιολογηθεί η ανθεκτικότητα των CNN χαρακτηριστικών, επαναλήφθηκε το πείραμα εξαγωγής χαρακτηριστικών και εκπαίδευσης SVM σε δύο παραλλαγές παραμόρφωσης:

- **Gaussian θόρυβος:** Πρόσθεση θορύβου $\mathcal{N}(0, 0.1^2)$ στον κανονικοποιημένο τανυστή εικόνας, πριν τη διέλευση από το δίκτυο.
- **Τυχαία περιστροφή:** Περιστροφή κατά τυχαία γωνία $\theta \sim \mathcal{U}(-45^\circ, 45^\circ)$.

Τα αποτελέσματα συνοψίζονται παρακάτω:

- **Baseline (χωρίς παραμόρφωση):** 96.55%
- **Gaussian θόρυβος ($\sigma = 0.1$):** 94.02%
- **Τυχαία περιστροφή (εώς $\pm 45^\circ$):** 95.11%

Και οι δύο παραμορφώσεις προκαλούν μικρή μόνο πτώση ($\approx 1\text{--}2.5\%$), γεγονός που αποδεικνύει τη γενική ανθεκτικότητα των CNN χαρακτηριστικών. Η περιστροφή επηρεάζει ελαφρώς λιγότερο από τον θόρυβο, κάτι που αναμένεται: το global average pooling της avgpool συνοψίζει τη χωρική πληροφορία κάθε καναλιού σε έναν μόνο αριθμό, παρέχοντας εγγενή ανθεκτικότητα σε χωρικές μεταβολές. Ο Gaussian θόρυβος, από την άλλη, διαταράσσει άμεσα τις ενεργοποιήσεις όλων των καναλιών, παρόλο που οι BatchNorm και τα διαδοχικά pooling εξομαλύνουν μέρος της επίδρασής του.

3.2.6 Bonus: Σύγκριση Μεθόδων (LoRA & MLP)

Για να εξεταστεί αν η προσαρμογή του backbone στα νέα δεδομένα βελτιώνει την απόδοση, υλοποιήθηκε fine-tuning μέσω **LoRA** (Low-Rank Adaptation) [8]. Αντί να τροποποιηθούν άμεσα τα βάρη του δικτύου, το LoRA εισάγει δύο πίνακες χαμηλής τάξης $A \in \mathbb{R}^{r \times d}$ και $B \in \mathbb{R}^{d \times r}$ παράλληλα σε κάθε γραμμικό επίπεδο, ώστε η ενημέρωση $\Delta W = BA$ να έχει τάξη $r \ll d$. Με $r = 8$ ενεργοποιούνται μόνο **28,992** από τις 2,571,848 παραμέτρους (1.13%) του MobileNet, διατηρώντας τα υπόλοιπα βάρη "παγωμένα".

Εκπαιδεύτηκε επίσης ένα **MLP** τριών κλάσεων ($576 \rightarrow 256 \rightarrow 128 \rightarrow 3$) με Adam optimizer, cosine annealing και dropout 0.3, τόσο πάνω στα παγωμένα χαρακτηριστικά όσο και πάνω στα χαρακτηριστικά που παράγει το LoRA-aligned backbone. Συνολικά συγκρίνονται πέντε μέθοδοι στο τελευταίο fold εκ των 5 (Πίνακας 52):

4-Way Comparison: Feature Extractor × Classifier


Method	Accuracy	F1-Score	Training Time
Frozen + Linear SVM	96.55%	0.9632	0.1s
Frozen + RBF SVM	97.93%	0.9801	0.0s
LoRA + SVM	96.55%	0.9632	27.6s
Frozen + MLP	96.55%	0.9632	15.8s
LoRA + MLP	96.55%	0.9632	43.7s

Σχήμα 52. Σύγκριση πέντε μεθόδων ως προς ακρίβεια, F1-Score και χρόνο εκπαίδευσης.

Παρατηρούμε λοιπόν πως το **Frozen + RBF SVM** επιτυγχάνει την υψηλότερη ακρίβεια (97.93%, $F1 = 0.9801$) με μηδενικό ουσιαστικά χρόνο εκπαίδευσης, αποδεικνύοντας ότι τα χαρακτηριστικά του frozen MobileNetV3 που εξάγουμε είναι ήδη εξαιρετικά διακριτικά για το classification πρόβλημα μας. Το LoRA δεν βελτιώνει περαιτέρω: τα LoRA + SVM και LoRA + MLP δεν ξεπερνούν αντίστοιχα τον Frozen + Linear SVM και τον Frozen + MLP, ενώ κοστίζουν και σε χρόνο εκπαίδευσης. Αυτό είναι αναμενόμενο: το dataset είναι σχετικά μικρό και οι κλάσεις είναι ήδη καλά αναπαραστάσιμες από τα ImageNet χαρακτηριστικά, οπότε η ελάχιστη προσαρμογή του LoRA δεν αρκεί για να αλλάξει ουσιαστικά τον χώρο χαρακτηριστικών.

3.2.7 Οπτικοποίηση Χώρου Χαρακτηριστικών (PCA)

Για να αξιολογηθεί όμως και οπτικά η επίδραση του LoRA στη δομή του χώρου χαρακτηριστικών, εφαρμόστηκε PCA (Principal Component Analysis) μείωση από 576 σε 2 διαστάσεις, τόσο στα χαρακτηριστικά του frozen backbone όσο και σε αυτά του LoRA-aligned.



Σχήμα 53. PCA (με 2 διαστάσεις) των avgpool χαρακτηριστικών 576-dim για τον frozen backbone (αριστερά) και τον LoRA-aligned (δεξιά).

Και στις δύο περιπτώσεις παρατηρούμε πως οι τρεις κλάσεις σχηματίζουν διακριτά clusters στον χώρο των δύο κύριων συνιστωσών, επιβεβαιώνοντας ότι τα χαρακτηριστικά avgpool διαχωρίζουν φυσικά τις κατηγορίες. Η δομή των clusters δεν αλλάζει αισθητά μετά το LoRA: το car (πράσινο) και το bike (μπλε) εμφανίζουν κάποια επικάλυψη και στις δύο αναπαραστάσεις, συνάδοντας με τα 5 λανθασμένα δείγματα που προέκυψαν στο τελευταίο fold.

3.2.8 Grad-CAM: Σύγκριση Παγωμένου και LoRA Backbone

Προκειμένου να οπτικοποιήσουμε τη περιοχή στην οποία έδωσε περισσότερη σημασία το backbone μας (στη περίπτωση όπου τα βάρη είναι frozen, και συγκρίνοντάς την με την περίπτωση όπου το backbone έχει προσαρμοστεί μέσω LoRA), εφαρμόστηκε η τεχνική Grad-CAM. Το Grad-CAM (Gradient-weighted Class Activation Mapping) [9] οπτικοποιεί τις περιοχές της εικόνας που επηρέασαν περισσότερο την απόφαση για μια συγκεκριμένη κλάση. Για κάθε pixel (i, j) του χάρτη ενεργοποίησης του επιπέδου features.12, το βάρος κάθε καναλιού k υπολογίζεται ως ο μέσος της κλίσης ως προς αυτό:


$$\alpha_k = \frac{1}{HW} \sum_{i,j} \frac{\partial s^c}{\partial A_{ij}^k} \quad (24)$$

και ο τελικός χάρτης είναι:


$$\text{CAM} = \text{ReLU} \left(\sum_k \alpha_k A^k \right) \quad (25)$$

όπου s^c είναι το logit της κλάσης c και A^k ο χάρτης ενεργοποίησης του καναλιού k .


Και οι δύο εκδοχές (παγωμένος και LoRA backbone) συνδέθηκαν με το αντίστοιχο εκπαιδευμένο MLP τριών κλάσεων. Παρακάτω παρουσιάζονται τα heatmaps για ένα αντιπροσωπευτικό δείγμα κάθε κλάσης, καθώς και η επικάλυψη του LoRA heatmap πάνω στην αρχική εικόνα.



Σχήμα 54. Grad-CAM για κλάση *person*.




Σχήμα 55. Grad-CAM για κλάση *car*.



Σχήμα 56. Grad-CAM για κλάση *bike*.

Τα heatmaps του παγωμένου και του LoRA backbone είναι σχεδόν πανομοιότυπα και στις τρεις κλάσεις, κάτι που συνάδει με την αμελητέα διαφορά απόδοσης μεταξύ τους. Το δίκτυο επιβεβαιώνουμε πως εστιάζει σε σημασιολογικά συνεκτικές περιοχές: για *person* ενεργοποιείται κυρίως ο άνθρωπος, για *car* το κεντρικό σώμα του οχήματος και για *bike* η οριζόντια ζώνη του πλαισίου.

Παράχθηκαν επίσης Grad-CAM για τα 5 λανθασμένα δείγματα του τελευταίου fold (Σχήμα 57). Στο πιο χαρακτηριστικό παράδειγμα (Truth: *person*, Predicted: *car*), ο χάρτης CAM ενεργοποιείται στη σήμανση και τον δρόμο αντί στον άνθρωπο — ο οποίος βρίσκεται στο άκρο της εικόνας μπροστά σε έντονο αστικό background. Η εστίαση αυτή εξηγεί πλήρως το λάθος: το δίκτυο «βλέπει» χαρακτηριστικά που συνδέει με αστικό περιβάλλον/οχήματα.



Σχήμα 57. Grad-CAM για λανθασμένα ταξινομημένο δείγμα: αληθινή κλάση *person*, προβλεπόμενη *car*. Ο χάρτης CAM εστιάζει στον δρόμο και τη σήμανση αντί στον άνθρωπο.

Αναφορές

- [1] D. Marr and E. Hildreth, Theory of edge detection, *Proceedings of the Royal Society of London B*, vol. 207, pp. 187--217, 1980.
- [2] Π. Μαραγκός, Όραση Υπολογιστών: Κεφ. 7 - Τελεστές Δυναδικών Εικόνων & Σχημάτων, EMII, 2005.
- [3] Π. Μαραγκός, Όραση Υπολογιστών: Κεφ. 10 Ανίχνευση Χαρακτηριστικών, *Feature Detection, Image Enhancement and Descriptors*, EMII, 2005.
- [4] C. Harris and M. Stephens, *A Combined Corner and Edge Detector*, Proceedings of the 4th Alvey Vision Conference, pp. 147--151, 1988.
- [5] T. Lindeberg, *Feature Detection with Automatic Scale Selection*, *International Journal of Computer Vision*, vol. 30, no. 2, pp. 79--116, 1998.
- [6] K. Mikolajczyk and C. Schmid, *Scale & Affine Invariant Interest Point Detectors*, *International Journal of Computer Vision*, vol. 60, no. 1, pp. 63--86, 2004.
- [7] A. Howard et al., *Searching for MobileNetV3*, *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 1314--1324, 2019.
- [8] E. J. Hu et al., *LoRA: Low-Rank Adaptation of Large Language Models*, arXiv:2106.09685, 2021.
- [9] R. R. Selvaraju et al., *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*, *International Journal of Computer Vision*, vol. 128, pp. 336--359, 2020. arXiv:1610.02391.